

Zobacz dyskusje, statystyki i profile autorów tej publikacji pod adresem: <https://www.researchgate.net/publication/349975907>

Wyszukiwanie Igrzysk śmierci: wizje, koncepcja, wdrożenie, głęboka analiza, perspektywy i zmiany w wydajności (przyznane powtarzalną odznakę przez platformę Code Ocean i Exp...

Artykuł w systemach eksperckich z aplikacjami · Marzec 2021

CYTATY

75

4 autorów:



Yutao Yang

Uniwersytet Wenzhou

4 PUBLIKACJE 143 CYTATY

ZOBACZ PROFIL



Ali Asghar Heidari

Narodowy Uniwersytet w Singapurze

152 PUBLIKACJE 7812 CYTATÓW

ZOBACZ PROFIL

ODCZYTY

6,343



Huiling Chen

Uniwersytet Wenzhou

268 PUBLIKACJE 12 336 CYTATÓW

ZOBACZ PROFIL



Amir H Gandomi

Politechnika Sydney

440 PUBLIKACJE 22 213 CYTATÓW

ZOBACZ PROFIL

Niektórzy z autorów tej publikacji pracują również nad tymi powiązanymi projektami:



Inteligencja roju [Zobacz projekt](#)



Międzynarodowa (online) konferencja na temat postępów w mechanice konstrukcji i zastosowaniach (ASMA-2021) [Zobacz projekt](#)

Igrzyska śmierci Szukaj: wizje, koncepcja, realizacja, Głęboka analiza, perspektywy i w kierunku zmian wydajności

Yutao Yang¹, Huiling Chen^{1*}, Ali Asghar Heidari^{2,3}, Amir H Gandomi⁴

¹Wyższa Szkoła Informatyki i Sztucznej Inteligencji, Uniwersytet Wenzhou, Wenzhou, Zhejiang 325035,
Chiny

yutaoyang.style@foxmail.com, chenhuiling.jlu@gmail.com, _

²Szkoła Geodezji i Inżynierii Geoprzestrzennej, College of Engineering, University of Teheran, Teheran
1439957131, Iran

as_heidari@ut.ac.ir, aliasghar68@gmail.com

³ Department of Computer Science, School of Computing, National University of Singapore, Singapur 117417,
Singapur

aliasgha@comp.nus.edu.sg, t0917038@u.nus.edu

⁴ Wydział Inżynierii i Technologii Informatycznych, University of Technology Sydney, NSW 2007, Australia
gandomi@uts.edu.au

□ Autor do korespondencji: Huiling Chen

E-mail: chenhuiling.jlu@gmail.com (Huiling Chen)

Abstrakcyjny

W ostatnich latach opublikowano zestaw nadużywanych metod populacyjnych.

Pomimo swojej popularności, w wyniku zmanipulowanego systematycznego marketingu internetowego, łączenia produktów i technik reklamowych, większość z nich ma niepewną, niedojrzałą wydajność, częściowo przeprowadzone weryfikacje, podobne nadużywane metafory, podobne niedojrzałe komponenty i operacje związane z eksploracją i eksploatacją oraz niepewny kompromis między trendami eksploracyjnymi i eksploatacyjnymi w większości nowych przypadków rzeczywistych. Dlatego wszyscy użytkownicy muszą szeroko modyfikować i dostosowywać swoje operacje w oparciu o główne metody ewolucyjne, aby osiągnąć szybszą konwergencję, bardziej stabilną równowagę i wysokiej jakości wyniki. Aby przenieść społeczność optymalizacyjną o krok do przodu w kierunku większego skupienia się na wydajności, a nie na zmianie metafory, ogólna technika optymalizacji oparta na populacji o nazwie Igrzyska Śmierci

W tych badaniach zaproponowano poszukiwanie (HGS) o prostej strukturze, specjalnych cechach stabilności i bardzo konkurencyjną wydajność, aby skuteczniej realizować rozwiązania zarówno ograniczonych, jak i nieograniczonych problemów. Proponowany HGS został zaprojektowany zgodnie z działaniami powodowanymi głodem i wyborem behawioralnym zwierząt. Ta dynamiczna, pod kątem sprawności fizycznej metoda wyszukiwania opiera się na prostej koncepcji „głodu” jako najważniejszej homeostatycznej motywacji i przyczyny zachowań, decyzji i działań w życiu wszystkich zwierząt, aby proces optymalizacji był bardziej zrozumiały i spójny dla nowych użytkowników i decydentów. ten

Hunger Games Search włącza pojęcie głodu do procesu fabularnego; innymi słowy, waga adaptacyjna oparta na pojęciu głodu została zaprojektowana i zastosowana w celu symulowania wpływu głodu na każdym etapie wyszukiwania. Jest zgodny z zasadami logiki obliczeniowej (gry) wykorzystywane przez prawie wszystkie zwierzęta, a te rywalizujące czynności i gry są często adaptacyjne, ewolucyjne, zapewniając większe szanse na przeżycie i zdobycie pożywienia. Główną cechą tej metody jest jej dynamiczny charakter, prosta konstrukcja oraz wysoka wydajność w zakresie zbieżności i akceptowalnej jakości rozwiązań, która okazuje się bardziej efektywna niż dotychczasowa optymalizacja metody. Skuteczność HGS została zweryfikowana poprzez porównanie HGS z obszernym zestawem popularnych i zaawansowanych algorytmów na 23 dobrze znanych funkcjach optymalizacyjnych oraz zestawem testów porównawczych IEEE CEC 2014. Ponadto HGS został zastosowany do kilku problemów inżynierskich, aby zademonstrować jego przydatność. Wyniki potwierdzają skuteczność proponowanego optymalizatora w porównaniu z popularnymi podstawowymi optymalizatorami, kilkoma zaawansowanymi wariantami istniejących metod oraz kilkoma zwycięzcami CEC i potężną ewolucją różnicową (DE)- metody oparte na skrótach LSHADE, SPS_L_SHADE_EIG, LSHADE_cnEpSi, SHADE, SADE, MPEDE i JDE w obsłudze wielu problemów jednocelowych.

Zaprojektowaliśmy tę metodę opartą na populacjach typu open source, aby była standardowym narzędziem do optymalizacji w różnych obszarach sztucznej inteligencji i uczenia maszynowego z kilkoma nowymi funkcjami eksploracyjnymi i eksploatacyjnymi, wysoką wydajnością i dużymi możliwościami optymalizacji. Metoda jest bardzo elastyczna i skalowalna, aby można ją było rozszerzyć w celu dopasowania do większej liczby przypadków optymalizacji zarówno w aspektach konstrukcyjnych, jak i po stronie aplikacji. Kody źródłowe tego artykułu, pliki dodatkowe, pliki źródłowe lateksowe i biurowe, źródła wątków, skrócona wersja i pseudokod oraz zestaw narzędzi oprogramowania open source do rozwiązywania problemów z optymalizacją za pomocą Hunger Games Search i usługi sieciowej online w przypadku jakichkolwiek pytań, opinii, sugestii, a pomysł na algorytm HGS będzie dostępny publicznie pod adresem <https://aliasgharheidari.com/HGS.html>.

Słowa kluczowe

Wyszukiwanie igrzysk głodowych; Optymalizacja; Inteligencja roju; Metaheurystyka; Inżynierskie problemy projektowe

1. Wstęp

Rzeczywiste aplikacje w systemach eksperckich, systemach informatycznych i systemach opartych na wiedzy często mają ograniczoną przestrzeń funkcji i ograniczenia wynikające z priorytetów i ograniczeń budżetowych właścicieli projektów. Decydenci, programiści i informatycy muszą znaleźć wykonalne, możliwe do wyjaśnienia i wystarczające szczegóły i rozwiązania w rozsądnym czasie przy użyciu dowolnej rodziny deterministycznych lub przybliżonych algorytmów dla problemów w różnych obszarach, takich jak optymalizacja operacji (E. Liu, Lv, Yi, & Xie, 2019), segmentacja obrazu (Abd Elaziz, Heidari, Fujita i Moayedi, 2020; Zhao, Liu, Yu, Heidari, Wang, Liang i in., 2020; Zhao, Liu, Yu, Heidari, Wang, Oliva, i in., 2020), systemy śledzenia celów (Yan, Pu, Zhou, Liu, &

Bao, 2020), usługi lokalizacyjne (X. Li, Zhu, & Wang, 2019), obrazowe big data (Q. Zhu, 2019), sieci oportunistyczne (Fu, Fortino, Li, Pace, & Yang, 2019), routing wielościeżkowy (Fu, Fortino, Pace, Aloï i Li, 2020), rozwój łańcucha dostaw (Y. Chen, He, Guan, Lu i Li, 2017), systemy hydrotermalne (Deng, Zhang, Sharma i Nie, 2019), systemy śledzenia sprzętu (C. Wu, Wang, Chen, & Kim, 2019), systemy kompletacji zamówień (Ran, Liu, & Zhang, 2020), ulepszanie obrazu (Yue, Wang, Chen, Cai, & Jin, 2020), systemy sieciowe Lurie (Shi, et al., 2018) oraz systemy komunikacji bezprzewodowej i sieci (Xiong, et al., 2020), by wymienić kilka potencjalnych obszarów dla przyszłych użytkowników w społeczności zajmującej się optymalizacją i sztuczną inteligencją (AI). Z drugiej strony, skuteczność i złożoność opracowanych solverów jest głównym problemem, gdy charakterystyka problemów staje się bardziej dynamiczna lub skomplikowana pod względem multimodalności, niepewności i niejasności przestrzeni cech. Na przykład możemy wskazać zestaw zastosowań w dziedzinach przekrojowych i informatyki, takich jak optymalizacja parametrów (Cai, Wu, et al., 2020), optymalizacja temperatury (Cai, Gao, et al., 2020), smart grid (X. Wang, Liu i Choo, 2020), optymalizacja wdrażania (Cao, Zhao, Gu, Fan i Yang, 2019), optymalna alokacja zasobów (Yan, Pu, Zhou, Liu, & Greco, 2020), inteligentne rolnictwo (J.

Song i in., 2020) oraz inteligentne zarządzanie ruchem (Y. Liu, Yang i Sun, 2020).

Optymalizacja jest „powinna” kryć się za większością problemów związanych ze sztuczną inteligencją i przemysłem w różnych dyscyplinach, takich jak sieci neuronowe (Huazhou Chen i in., 2020) i głębokie uczenie (Xu i in., 2018). Może mieć formę pojedynczego celu (Hanxin Chen i in., 2020; L. Yang i Chen, 2019), że musimy przygotować wszystkie cele w jednej znanej funkcji, ale została ona rozszerzona do wielu innych form takie jak wielocelowy (Cao, Zhao, Yang i in., 2019), solidna optymalizacja (Qu, Han, Wu i Raza, 2020), wiele celów (Cao, Dong i in., 2020; Cao, Wang, Zhang, Song i Lv, 2020), optymalizacja rozmyta (Huang i in., 2019), optymalizacja na dużą skalę (Cao, Fan i in., 2020; Cao, Zhao, Gu, Ling i Ma, 2020) oraz metody memetyczne (Fu, Pace, Aloï, Yang i Fortino, 2020). Istnieją również dwa filozoficzne punkty widzenia dotyczące rozwiązywania problemów i modeli matematycznych, z których jeden opiera się na wykorzystaniu równań gradientowych i deterministycznych podczas rozwiązywania problemu (Long, Wu i Wang, 2015; Zeng, Liu i Wang, 2019). a inny punkt widzenia ma charakter prób i błędów, wykorzystując rekurencyjne wykrywanie i ocenę krajobrazu problemu w oparciu o pewne przybliżone metryki i informacje o basenie problemu lub w sposób stochastyczny. W tej klasie szeroko stosowanym podejściem jest ewolucyjna i rojowa metoda optymalizacji lub metody metaheurystyczne

(Huiling Chen, Shimin Li i in., 2020; Huiling Chen, Wang i Zhao, 2020; Huiling Chen, Xu, Wang i Zhao, 2019; Luo i in., 2019; Luo i in., 2018; S. Song i in., 2020; Xinyu Wang i in., 2020; H. Yu, Zhao, Wang, Chen i Li, 2020; X. Zhang i in., 2020; Y. Zhang i in. al. al., 2020).

Znalezienie optymalnych rozwiązań problemów z rotacją multimodalną lub kompozycyjnych jest trudnym zadaniem bez posiadania jakichkolwiek informacji o gradientach dotyczących funkcji celu. W ciągu ostatnich kilku lat użytkownicy zaczęli bardziej interesować się szacowaniem najlepszych rozwiązań, a następnie wykorzystywaniem tych rozwiązań w zależności od ich poziomu dokładności. Dlatego też algorytmy metaheurystyczne (MA) przyciągnęły znaczną uwagę i zostały zastosowane w różnych dziedzinach uczenia maszynowego, inżynierii i nauki. Głównym powodem takiego trendu jest to, że istnieje

przepełnienie nowych problemów w rzeczywistym świecie i w związku z tym rosnące wymagania wobec tych rozwiązań, gdy problemy stają się trudniejsze. Cechy MA, takie jak unikanie optymalizacji lokalnej, prostota i kroki bez gradientu, umożliwiają zapewnienie zadowalających rozwiązań tak złożonych problemów, które zazwyczaj mają wiele optymów lokalnych i trudnej przestrzeni wyszukiwania. Zajmowanie się przestrzeniami multimodalnymi z iteracyjnymi procedurami eksploracyjnymi i eksploatacyjnymi jest główną cechą wszystkich MA w literaturze.

Niemniej jednak istnieją również pewne luki, obawy i wady w poprzednich metodach optymalizacji opartych na roju. Ostatnio zaproponowano popularne metody oparte na charakterach zwierząt, takich jak wilki (Mirjalili, Aljarah, Mafarja, Heidari i Faris, 2020), wieloryby (Mirjalili i Lewis, 2016) oraz ćmy (S. Mirjalili, 2015), a nawet funkcji sinus cosinus (Mirjalili, 2016). Jednak różne badania wykazały, że te metody wydajności nie zostały dokładnie zbadane w oryginalnej pracy (Niu, Niu i Chang, 2019), a ich modele matematyczne również cierpią na wady strukturalne, przeciętne działanie, problematyczne metody weryfikacji (Niu, et al., 2019), widoczne podobieństwo w ich budowie i nieznacznie zmodyfikowane komponenty. Na przykład bardzo popularny optymalizator szarego wilka (GWO) ma defekty i jest podatny na niepewne działanie w przypadku problemów z optimum w dowolnej lokalizacji, a nie w centrum współrzędnej (Niu i in., 2019). Ponadto mechanizmy okrążania w metodzie optymalizatora wielorybów (WOA) i metodzie płomienia ćmy (MFO) są takie same jak w przypadku GWO, z niewielkimi różnicami w zakresie wyszukiwania (Tzanetos i Dunias, 2020).

Zgodnie z naszym bogatym doświadczeniem w zakresie tych metod (Hao Chen, Heidari, Zhao, Zhang i Chen, 2020; Huiling Chen, Yang, Heidari i Zhao, 2019; C. Yu, Heidari i Chen, 2020), takie problemy mają wpływ na ich niezawodność w społeczności optymalizacyjnej bez wystarczającej uwagi na aspekty wydajnościowe, złożoność, dostrajanie parametrów, porównanie z zaawansowanymi i zaawansowanymi technologicznie optymalizatorami, weryfikację za pomocą zestawów konkurencji CEC i mądre interakcje między komponentami. Aspekty te odgrywają znaczącą rolę, gdy decydenci lub praktycy muszą uporać się z niektórymi problemami w świecie rzeczywistym. Spory te zmotywowały nas do dalszego badania zachowań algorytmicznych i rozwijania bardziej stabilnej logiki, zwłaszcza biorąc pod uwagę, że te popularne metody wymagają wiele wysiłku i modyfikacji, aby wyskoczyć z lokalnych optymów i stagnacji oraz ich wad. Chociaż zwykli użytkownicy w branży i niedoświadczeni użytkownicy kodu ledwo mogą wykryć te problemy, metody te są nadal trudne do zrozumienia.

Dlatego staraliśmy się podkreślić więcej aspektów w tym badaniu i porównać je z innymi metodami, aby przesunąć preferencje pola w kierunku wydajności.

Celem prawie wszystkich metod jest iteracyjna ewolucja populacji, która pojawiła się w algorytmie genetycznym (GA) (Holland, 1992) i optymalizatorze roju cząstek (PSO), które później podzielono na algorytm ewolucyjny (EA) i inteligencję roju (SI).) optymalizatory.

Biologiczne operacje ewolucyjne wspierają logikę algorytmów ewolucyjnych i mogą rozwiązywać problemy optymalizacji za pomocą trzech operacji: selekcji, reorganizacji i mutacji. GA (Holland, 1992) jest podstawowym EA zaproponowanym przez Hollanda w oparciu o teorię ewolucji Darwina.


Symulowanie ewolucji organizmów lub idealne rozwiązanie można przeprowadzić w przestrzeni rozwiązań.

Proces ewolucyjny algorytmu Differential Evolution (DE) (Storn & Price, 1997)

jest bardzo podobny do tego z GA, ale jego specyficzna definicja działania jest inna. W tym samym

czas wykorzystuje współpracę między jednostkami w grupie i inteligencję roju generowaną przez rywalizację, aby kierować kierunkiem ewolucji. Poza tym EA obejmuje Programowanie Genetyczne (GP) (Koza i Rice, 1992), Strategię Ewolucji (ES) (Hansen, Müller i Koumoutsakos, 2003) oraz Programowanie Ewolucyjne (EP) (Yao, Liu i Lin, 1999).

SI głównie symuluje zbiorowe zachowania organizmów naturalnych i wykorzystuje mądrość społeczną do wspólnego poszukiwania optymalnej przestrzeni poszukiwań. Ant Colony Optimization (ACO) (Dorigo & Blum, 2005) symuluje zbieranie pokarmu prowadzone w koloniach mrówek i jest stosowane w wielu odrębnych problemach. PSO (Kennedy i Eberhart, 1995) naśladuje regularność działań skupisk ptaków, wykorzystując wymianę informacji między jednostkami w grupie do poruszania całej grupy. Oprócz powyższych dwóch reprezentatywnych algorytmów, nowsze algorytmy SI to optymalizacja oparta na biogeografii (BBO) (Simon, 2008), algorytm inspirowany nietoperzem (BA) (X.-S. Yang, 2010), optymalizacja motyla monarchy (MBO) (G.-G. Wang, Deb i Cui, 2019), Poszukiwanie kukulek (CS) (X.-S. Yang i Deb, 2009), Sztuczna kolonia pszczół (ABC) (Karaboga i Basturk, 2007), i Harris Hawk Optimizer (HHO)¹ (Heidari i in., 2019). Inną obiecującą metodą jest algorytm śluzowatej formy (SMA)² (S. Li, Chen, Wang, Heidari i Mirjalili, 2020), który został niedawno opracowany w oparciu o śluzowatą pleśń i zyskuje coraz większe zainteresowanie ekspertów. Na rysunku 1 przedstawiono klasyfikację metod opartych na zachowaniach algorytmicznych. Proszę odnieść się do oryginalnych badań przedstawionych przez Moline i in. [25] dla pełnych danych i dalszych badań.



Rysunek 1 Klasyfikacja optymalizatorów na podstawie taksonomii behawioralnej.

¹ Informacje i kody źródłowe algorytmu HHO są publicznie dostępne pod [adresem https://aliasgharheidari.com/HHO.html](https://aliasgharheidari.com/HHO.html).

² Informacje i kody źródłowe algorytmu SMA są publicznie dostępne pod [adresem https://aliasgharheidari.com/SMA.html](https://aliasgharheidari.com/SMA.html).

Chociaż MA są podzielone na kilka kategorii, mają te same cechy, ponieważ etapy wyszukiwania składają się z eksploracji i eksploatacji. W pierwszym etapie musimy zadbać o jak największą losowość poszukiwań i szeroko eksplorować przestrzeń poszukiwań. W drugim etapie musimy dokładnie skoncentrować się na określonych obszarach przestrzeni funkcji znalezionej w poprzednim etapie. Obiecujący obszar koncentruje się na lokalnej zdolności wyszukiwania, więc zrównoważenie tych dwóch etapów ma kluczowe znaczenie dla wydajności algorytmu.

Chociaż zaproponowano wiele MA, nie ma na świecie darmowego obiadu (Wolpert i Macready, 1997) i żaden algorytm nie jest w stanie rozwiązać wszystkich problemów optymalizacyjnych jako najlepsza metoda. Ponieważ każdy algorytm wykazuje przewagę w pewnych określonych problemach optymalizacyjnych, badacze nieustannie pracują nad badaniem i opracowywaniem lepszych algorytmów. W związku z tym w niniejszej pracy zaproponowano nowy algorytm metaheurystyczny, Hunger Games Search (HGS), który jest inspirowany wspólnym zachowaniem zwierząt społecznych, w którym aktywność poszukiwawcza jest proporcjonalna do poziomu ich głodu. Algorytm ten został zaprojektowany i zaimplementowany w oparciu o wspólne cechy mediów społecznościowych zwierzęta i ich poszukiwanie żywności.

Pozostała część tego artykułu ma następującą strukturę. Rozdział 2 wyjaśnia oświecenie HGS i ustanawia odpowiedni model matematyczny. Rozdział 3 przedstawia eksperymenty zaangażowane w tę pracę, analizę jakościową i porównanie z tradycyjnymi i zaawansowanymi algorytmami na 23 funkcjach testowych i funkcjach testowych IEEE CEC oraz zastosowanie do problemów inżynierskich. Sekcja 4 podsumowuje pełny tekst i

kierunek przyszłych badań.

2 Wyszukiwanie Igrzysk Śmierci (HGS)

W tym rozdziale szczegóły algorytmu HGS, wraz z jego modelem matematycznym, zostaną wprowadzone.

2.1 Logika wyszukiwania, wyboru behawioralnego i gier napędzanych głodem

Zwierzęta podążają za ich informacjami sensorycznymi w oparciu o pewne zasady obliczeniowe i w interakcji ze swoim środowiskiem (jako częścią środowiska), które stanowią podstawę ich decyzji i wyborów oraz wspierają ewolucję ich architektury poznawczej. Potwierdzono, że te logiczne, obliczeniowe reguły wykorzystywane przez zwierzęta będą często ewolucyjnie adaptacyjne, zapewniając większe szanse na przeżycie, rozmnażanie i zdobywanie pożywienia (Real, 1991). Głód odpowiada za jedną z najważniejszych homeostatycznych motywacji i przyczyn zachowań, decyzji i działań w życiu zwierząt. Pomimo szerokiej gamy bodźców i konkurencyjnych wymagań, które zawsze iz pewnością rzutują na jakość życia zwierząt, powinny one wybierać i poszukiwać źródeł pożywienia, gdy stają w obliczu niedoboru kalorii. Aby poradzić sobie z tą homeostatyczną nierównowagą, muszą regularnie szukać pożywienia i poruszać się po swoim otoczeniu w sposób, który wymaga przełączania się między czynnościami eksploracyjnymi, defensywnymi i konkurencyjnymi, co wskazuje na niesamowitą płynność strategii żywieniowych (Burnett i in., 2016).

Wybór behawioralny i wybór działania jest powszechny w monarchii zwierzęcej i jest podstawowym prawem zachowań zorientowanych na cel, których świadkami jest natura. Na zachowanie gatunków wpływają różne czynniki lub ich kombinacja, a obserwowane zachowania są uzależnione od istniejącego stanu motywacyjnego i występowania bodźców w ich lokalizacji (Reppucci i Veenema, 2020). W przypadku każdego zwierzęcia neuronaukowcy zgadzają się, że głód³ jest silną siłą motywującą do aktywności, uczenia się i poszukiwania pożywienia i działa jako siła w kierunku zmiany warunków życia na bardziej stabilny⁴ (Sutton i Krashes, 2020). Głód może przewyższać i wpływać na stany rywalizujących popędów, takie jak pragnienie, nerwowość, strach przed myśliwymi i wymagania społeczne, zgodnie z eksperymentami w „Hunger-Driven Motivational State Competition” opublikowanym w Neuron (Burnett i in., 2016). Dlatego neurobiolodzy odkryli, że głód prawdopodobnie znajduje się na szczycie hierarchii motywacji⁵. Głód przebija również społeczne pragnienia zwierząt, kiedy mogą one znaleźć pożywienie i je skosztować (Burnett i in., 2016).

Życie społeczne pomaga zwierzętom unikać drapieżników i znajdować źródła pożywienia, zarówno innych zwierząt, jak i warzyw, ponieważ działają one w naturalnej współpracy, co zwiększa ich szanse na przeżycie. Taka jest natura ewolucji, dzięki której zdrowsze zwierzęta mogą lepiej znajdować źródła pożywienia i mają większą szansę na przeżycie niż zwierzęta słabsze. Można to nazwać igrzyskami głodowymi w naturze. Każda zła decyzja może zmienić wynik gry, prowadząc do śmierci pojedynczego osobnika, a nawet wyginięcia całego gatunku. Na przykład po polowaniu kruki i szczury mówią swoim towarzyszom, że ich następny posiłek zmniejsza niepewność następnego posiłku (Jarvandi, Booth i Thibault, 2007). Na codzienne zachowanie zwierząt duży wpływ mają niektóre sytuacje motywacyjne, takie jak głód i nerwowość przed zabiciem przez myśliwych (Gotceitas i Godin, 1991). Głód jest cechą „niejedzenia” przez długi czas (E Miller, J Bailey i AF Stevenson, 1950), przy czym im silniejszy głód, tym silniejsze pragnienie jedzenia i tym bardziej aktywny będzie organizm w poszukiwaniu na jedzenie w krótkim czasie, zanim zrobi się za późno i spowoduje głód lub śmierć (I. Friedman i Stricker, 1976). W przeciwnym razie szansa na przeżycie będzie zbyt mała, a zwierzę umrze. Stąd, gdy źródło pożywienia jest ograniczone,

istnieje logiczna gra między głodnymi zwierzętami, aby znaleźć źródło pożywienia i wygrać sytuację (O'Brien, Browman i Evans, 1990). Gra opiera się więc na logicznych decyzjach i ruchach gatunków.

2.2 Model matematyczny

W tym podrozdziale szczegółowo opisano model matematyczny i proponowaną metodę HGS. Należy pamiętać, że jesteśmy zmuszeni zbudować model matematyczny zgodnie z działaniami powodowanymi głodem i wyborem behawioralnym, który powinien być tak prosty, jak to tylko możliwe, a jednocześnie najbardziej wydajny.

³ Zainteresowani czytelnicy mogą również odnieść się do głębokiego znaczenia słowa głód (Cannon i Washburn, 1912)

⁴ Aby przeczytać więcej o motywacjach, preferencjach i wyborach zwierząt, zainteresowani czytelnicy mogą przeczytać więcej na: <https://www.nature.com/scitable/knowledge/library/measuring-animal-preferences-and-choice-behavior-23590718/>

⁵ Aby uzyskać więcej informacji i nauki, zainteresowani czytelnicy mogą obejrzeć dodatkowy film na <https://tinyurl.com/aliasgharheidaridotcom> lub <https://www.sciencedirect.com/science/article/pii/S0896627316305256>

2.2.1 Podejdz do jedzenia

Zwierzęta towarzyskie często współpracują ze sobą podczas żerowania, ale istnieje możliwość, że niewielu osób nie uczestniczy we współpracy nie jest wykluczone (Clutton-Brock, 2009).

Poniższe instrukcje gry przedstawiają centralne równanie algorytmu HGS dla indywidualna komunikacja kooperacyjna i zachowanie żerowania:

$$\begin{aligned}
 & \text{gdzie } \mathbf{p}_i = \begin{pmatrix} p_{i1} \\ p_{i2} \\ p_{i3} \end{pmatrix} \text{ należy do zakresu } [0, 1]; \quad \mathbf{p}_i \text{ oraz } \mathbf{p}_j \text{ reprezentują dwie liczby losowe z zakresu } [0, 1]; \\
 & \quad (1) \text{ jest liczbą losową spełniającą rozkład normalny;} \\
 & \quad \text{wskazuje aktualne iteracje;} \\
 & \quad \mathbf{p}_1 \text{ oraz } \mathbf{p}_2 \text{ przedstawiają ciężary głodu; które zaprojektowaliśmy w oparciu o fakt} \\
 & \quad \text{sygnały głodu (Betley i in., 2015);} \\
 & \quad \text{reprezentuje lokalizację najlepszego osobnika w tej iteracji;} \\
 & \quad (i) \text{ reprezentuje lokalizację każdej osoby;}
 \end{aligned} \tag{2.1}$$

gdzie \mathbf{p}_i należy do zakresu $[0, 1]$; 2

\mathbf{p}_1 oraz \mathbf{p}_2 reprezentują dwie liczby losowe z zakresu $[0, 1]$;

(1) jest liczbą losową spełniającą rozkład normalny;

wskazuje aktualne iteracje;

\mathbf{p}_1 oraz \mathbf{p}_2 przedstawiają ciężary głodu; które zaprojektowaliśmy w oparciu o fakt

sygnały głodu (Betley i in., 2015);

reprezentuje lokalizację najlepszego osobnika w tej iteracji;

(i) reprezentuje lokalizację każdej osoby;

wartość i zostanie omówiona w eksperymencie z ustawianiem parametrów i jest to parametr, który ma na celu ulepszenie algorytmu. $(1 + (i))$

(1) przedstawia sposób, w jaki agent może chcieć i losowo szukać pożywienia w obecnej lokalizacji;

$\mathbf{p}_i(i)$ modeluje zakres aktywności aktualnej jednostki w aktualnym czasie i jest to

pomnożone przez 2 wpływać na wpływ głodu na zasięg działania. Ponieważ osoba

przestanie szukać, gdy nie będzie już głodny, to kontroler zakresu dodawany do limitu jest

zakres działalności, w którym zakres stopniowo zmniejszany do 0. Dodawanie lub odejmowanie

zakres działalności oparty na 1 symuluje aktualną osobę poinformowaną przez swoich rówieśników

po przybyciu do miejsca jedzenia, a następnie ponownie szuka jedzenia w bieżącej lokalizacji

po nabyciu jedzenia. w rzeczywistości. \mathbf{p}_1 jest wprowadzany jako błąd w uchwyceniu aktualnej pozycji, która

Definicja formuły, jest kontrolą zmienności dla wszystkich pozycji, jest

następująco:

$$\mathbf{p}_i = s(|\mathbf{p}_i| - |\mathbf{p}_j|) \tag{2.2}$$

gdzie $\mathbf{p}_1, \mathbf{p}_2, \dots, \mathbf{p}_n$, (i) reprezentuje wartość sprawności każdego osobnika; jest

najlepszą sprawnością uzyskaną w obecnym procesie iteracji (do tej pory);

Sech jest funkcją hiperboliczną ($\text{sech}(i) = \frac{2}{1 + e^{2i}}$).

Wzór na następująco:

$$\mathbf{p}_i = 2 \times h \times \mathbf{p}_j \tag{2.3}$$

$$h_i = 2 \times (1 - \mathbf{p}_i) \tag{2.4}$$


gdzie r_i jest liczbą losową z zakresu $[0,1]$; i oznacza maksymalną liczbę iteracji.

Rysunek 2 przedstawia proces wyszukiwania i logiki HGS w przestrzeniach w oparciu o reguła w równaniu (2.1).

Jak widać na wykresie kierunki wyszukiwania można podzielić na dwie kategorie według klasyfikacji punktów źródłowych:

1. Szukaj na podstawie X : Pierwsza instrukcja gry symuluje samodzielną, która nie ma ducha pracy zespołowej, nie jest zaangażowana w fazę współpracy i po prostu chce łapczywie szukać pożywienia.
2. Szukaj na podstawie X_b : Druga instrukcja gry jest ściśle związana z X . Poprzez udoskonalenie zmienne r_1 oraz r_2 tych trzech czynników, pozycja jednostki może ewoluować w przestrzeni funkcji. Metoda ta symuluje współpracę kilku podmiotów w poszukiwaniu pożywienia.

Prawa lub zasady w równaniu (2.1) pozwala jednostkom na eksplorację możliwych lokalizacji w pobliżu rozwiązania optymalnego i lokalizacji oddalonych od rozwiązania optymalnego, co w pewnym stopniu gwarantuje przeszukanie wszystkich lokalizacji w granicach przestrzeni rozwiązania (dywersyfikacja). Ta sama koncepcja może być również zastosowana do wielowymiarowej przestrzeni poszukiwań.



Rysunek 2 Logika algorytmu Hunger Games Search (HGS) podczas optymalizacji.

2.2.2 Rola głodu

W tej części zaproponowany model symuluje cechy głodu poszukiwanych osób.

Formuła

1 w równaniu (2.1) przedstawia się następująco:

$$1() = \frac{()}{\sum_{i=1}^n ()} \times \frac{4,3}{3} < \quad (2.5)$$

Formuła

2 w równaniu (2.1) pokazano w następujący sposób:

$$= (1 - \frac{()}{h 2()}) \times \frac{()}{5} \times 2 \quad (2.6)$$

gdzie g_i reprezentuje głód każdego człowieka;

h_i reprezentuje liczbę osobników; to suma

głodu wszystkich osobników, czyli 5 to losowe liczby z (h_i) ;

3, 4 oraz przedziału $[0,1]$.

Wzór na h_i (i) znajduje się poniżej:

$$h_i = \begin{cases} 0, & \text{jeśli } g_i \leq 0 \\ h_i + g_i, & \text{jeśli } g_i > 0 \end{cases} \quad (2.7)$$

gdzie g_i (i) zachowuje przydatność każdej osoby w bieżącej iteracji. W każdej iteracji głód najlepszego osobnika został ustawiony na 0. W przypadku innych osobników nowy głód (i) jest dodawany na podstawie pierwotnego głodu. Stąd rozumiemy, że odpowiadające H z różne osoby będą różne.

Wzór na g_i można zobaczyć w następujący sposób:

$$g_i = \frac{(h_i - 0)}{h_i} \times 6 \times 2 \times (1 - \alpha) \quad (2.8)$$

$$g_i = \begin{cases} \alpha \times (1 + \alpha), & \text{jeśli } g_i > 0 \\ \alpha \times (1 - \alpha), & \text{jeśli } g_i \leq 0 \end{cases} \quad (2.9)$$

gdzie α jest liczbą losową z przedziału $[0,1]$; (i)

reprezentuje wartość sprawności każdego osobnika;

g_i jest najlepszą sprawnością uzyskaną w obecnym procesie iteracji (do tej pory);

WF oznacza najgorsze dopasowanie uzyskane w obecnym procesie iteracji (jak dotąd);

α i wskazać odpowiednio górną i dolną granicę przestrzeni cech.

Uczucie głodu (Friedman, Ulrich, & Mattes, 1999) jest ograniczone do dolnej granicy, α . Aby algorytm działał lepiej, kontrolujemy górną i dolną granicę głodu, a wartość zostanie omówiona w eksperymencie ustawiania parametrów.

Ponieważ głód może mieć zarówno pozytywny, jak i negatywny wpływ na zakres działalności, 1 oraz 2 są symulowane.

W równaniu (2.8), różnica między UB i LB służy do odzwierciedlenia największego głodu jednostki w różnych środowiskach; (i) oznacza ilość pożywienia, której dana osoba nadal nie musi być głodna; W każdej iteracji zmienia się głód jednostki.

α daje całkowitą zdolność żerowania osobnika w bieżącym procesie;

$\frac{(h_i - 0)}{h_i}$ reprezentuje wskaźnik głodu;

6×2 podaje pozytywny lub negatywny wpływ czynników środowiskowych na głód.

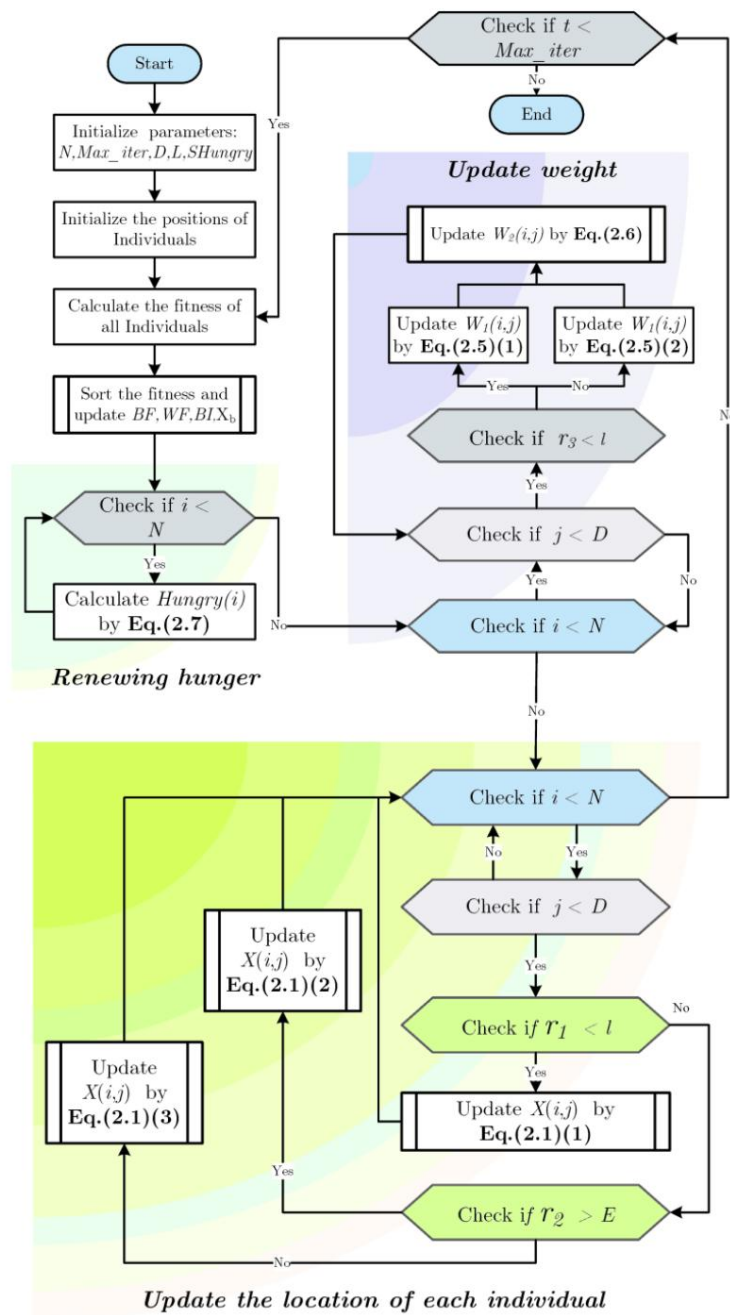
Chociaż zaproponowany algorytm HGS może zapewnić powszechność zwierząt społecznych, wciąż ma wiele do zrobienia. Na przykład algorytm można ulepszyć, mapując go zgodnie z żywym organizmem i integrując unikalne cechy żywego organizmu.

Można go również ulepszyć, dodając inne mechanizmy. Maksymalnie upraszczamy algorytm, aby zmaksymalizować jego skalowalność.

Algorytm 1 pokazuje pseudokod proponowanego Wyszukiwania Igrzysk Śmierci. Również schemat blokowy przedstawiono na rysunku 3.

Algorytm 1 Pseudo-kod gry Hunger Games Search (HGS)

Zainicjuj parametry, α , β , γ , δ , ϵ , ζ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω , φ , η , θ , ι , κ , λ , μ , ν , ξ , \omicron , π , ρ , σ , τ , υ , ϕ , χ , ψ , ω ,



Rysunek 3 Schemat blokowy algorytmu Hunger Games Search (HGS).

2.3 Teoretyczne i strukturalne cechy poszukiwań Głodowych Igrzysk

Jako pozbawiony gradientów, populacyjny optymalizator, proponowany HGS wykazuje wydajną wydajność dzięki do następujących wyjątkowych zalet:

- Jest to metoda populacyjna ze stochastycznymi elementami przełączającymi, która wzbogaca jej główne zachowania eksploracyjne i eksploatacyjne oraz elastyczność HGS w radzeniu sobie z trudnymi krajobrazami problemowymi.
- Adaptacyjne i zmienne w czasie mechanizmy HGS pozwalają tej metodzie obsługiwać wiele modalności i lokalne problemy optima skuteczniej.
- Uwzględnienie wskaźnika głodu i wpływu głodu na zakres działalności sprawia, że HGS jest bardziej elastyczny i zdolny do zmiany wydajności w sposób fitnessowy.

- Zastosowanie indywidualnych wartości sprawności umożliwia HGS uwzględnienie informacji historycznych, jeśli jest to konieczne do zmiany zachowania.
- Parametry i pomagają HGS w rozwijaniu pozycji początkowych i trybu wyszukiwania, aby zapewnić eksplorację całej przestrzeni rozwiązań tak dalece, jak to możliwe i w dużym stopniu zwiększyć zdolność dywersyfikacji algorytmu.
- Głód waży 1 oraz 2 zwiększyć perturbację HGS podczas procesu wyszukiwania i zapobiec pułapce algorytmu w lokalnym optimum.
- Parametr zapewnia, że krok wyszukiwania HGS jest redukowany w określonym tempie; w ten sposób zaspokajając potrzebę zbadania docelowej przestrzeni rozwiązania w szerokim zakresie na wczesnym etapie i wykorzystania głębokości docelowego basenu poszukiwań w późniejszych etapach.
- Wyszukiwanie Igrzysk śmierci może ewoluować agentów wyszukiwania pod kątem najlepszych rozwiązań (X_b) i normalnych rozwiązań (X), co jest prostym pomysłem na zapewnienie większej liczby wzorców eksploracji i większego zasięgu ukrytych obszarów przestrzeni funkcji.
- Struktura i logika Hunger Games Search są proste i można je łatwo zintegrować z innymi mechanizmami ewolucyjnymi w celu radzenia sobie z nowymi praktycznymi problemami w nauce i inżynierii.
- Pomimo prostych równań i w porównaniu z istniejącymi metodami, Hunger Games Search ma bardzo lepszą wydajność z wysokiej jakości wynikami w porównaniu ze znanymi podstawowymi i zaawansowanymi metodami dla badanych problemów porównawczych.
- Kody Hunger Games Search będą publicznie dostępne w różnych językach, a użytkownicy będą mogli łatwo uzyskać dostęp do kodów oprogramowania i zastosować je do docelowego problemu w oparciu o programowanie funkcjonalne. □ Za wszystkich użytkowników odpowiedzialna będzie publiczna usługa internetowa pod adresem <https://aliasgharheidari.com/HGS.html> w zakresie wszelkiej pomocy i wymaganych materiałów uzupełniających.

2.4 Analiza złożoności obliczeniowej

Proponowana wyszukiwarka Igrzysk śmierci obejmuje głównie następujące części: inicjalizacja, fitness ocena, sortowanie, aktualizacja głodu, aktualizacja wagi i aktualizacja lokalizacji. W powiązanych wzorach wskazuje liczbę osobników w populacji, jest wymiarem problemu i reprezentuje maksymalną liczbę iteracji. Na początkowym etapie złożoność obliczeniowa oceny sprawności i aktualizacji głodu to (N) , złożoność obliczeniowa sortowania to (N^2) , a złożoność obliczeniowa aktualizacji wagi i lokalizacji to $(N \times N)$. Z powyższej analizy możemy wywnioskować złożoność całego algorytmu: $(N + N^2 + 2N^2)$.

3 eksperymenty i wyniki

W tym rozdziale, proponowany algorytm HGS jest porównywany z niektórymi dobrze znanymi odpowiednikami. Wszystkie eksperymenty przeprowadzono na systemie operacyjnym Windows Server 2008 R2 z procesorem Intel (R) Xeon (R) Processor E5-2650 v4 (2,20 GHz) i 128 GB pamięci RAM. Wszystkie algorytmy zostały zakodowane w MATLAB R2014b dla rzetelnego porównania.

3.1 Analiza jakościowa

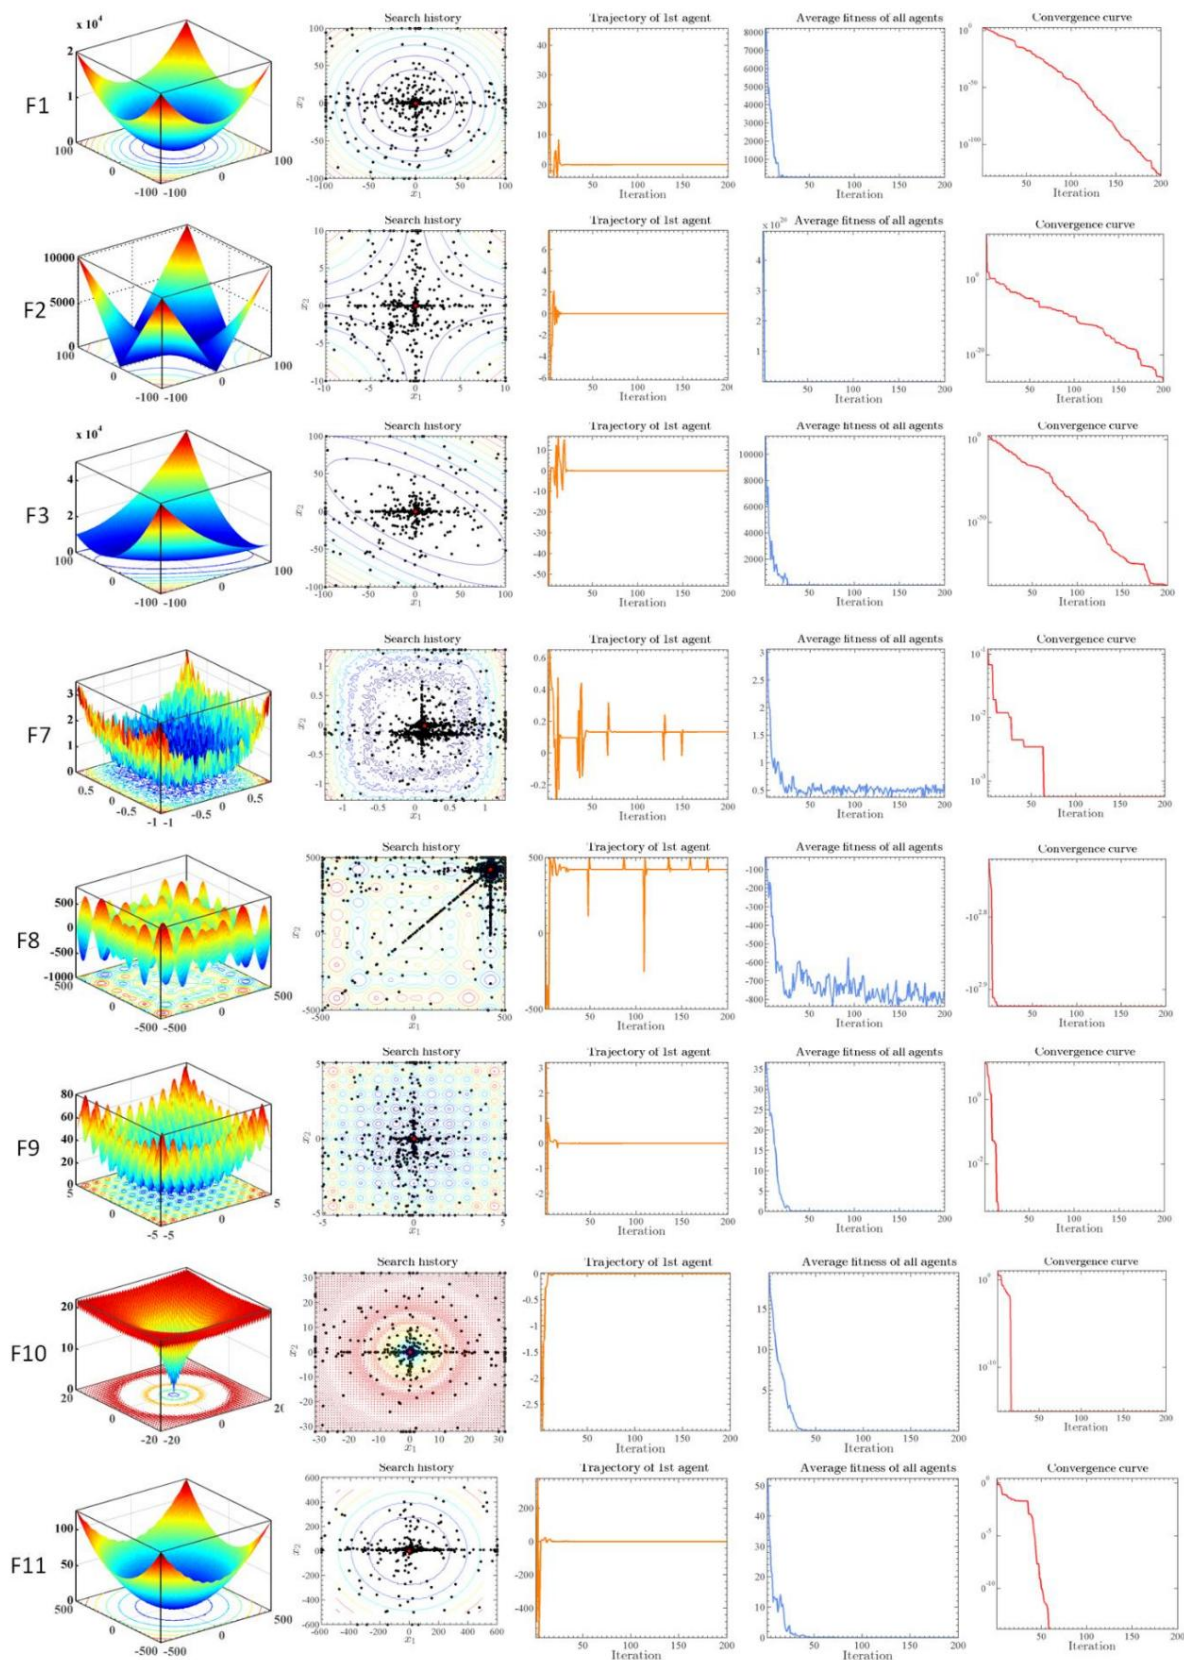
Rysunek 4 przedstawia analizę jakościową 23 dobrze znanych funkcji porównawczych za pomocą algorytmu HGS, która obejmuje historię wyszukiwania, trajektorię pierwszej osoby, średnią kondycję wszystkich osób oraz

zachowanie konwergencji. Historia wyszukiwania pokazuje lokalizację i rozmieszczenie osób w każdej iteracji. Trajektoria pierwszego osobnika ujawnia wzorce ruchu pierwszego osobnika w całym procesie iteracji. Średnia sprawność wszystkich osobników monitoruje, jak zmienia się średnia sprawność całej populacji podczas optymalizacji. Zachowanie konwergencji ujawnia zmieniający się trend optymalnego dostosowania i pośrednio pokazuje, jak dobrze trendy eksploracyjne zmieniają się w dryf eksploatacyjny.

Obserwując historyczną pozycję osoby, możemy najpierw zaobserwować, że osoba zbadała główne części przestrzeni wyszukiwania, pokazując, że algorytm ma silną zdolność wyszukiwania i może uniknąć popadnięcia w lokalnie optymalne rozwiązanie. Jednocześnie widzimy również, że większość lokalizacji wyszukiwania znajduje się wokół rozwiązania optymalnego, co wskazuje, że algorytm może dokładnie postępować w obszarze docelowym, a prędkość konwergencji jest duża. Algorytm ma dobry pomiar między dwiema fazami eksploracji i eksploatacji, w którym możemy wykryć zalety HGS.

Z wykresu trajektorii wynika, że osobniki mają silne fluktuacje w początkowej fazie poszukiwań, a zakres pokrycia fluktuacją przekracza 50% przestrzeni rozwiązania. Dowodzi to, że zdolność wyszukiwania algorytmu HGS jest bardzo silna i może koncentrować się na rozwiązaniach wysokiej jakości. Wraz ze wzrostem liczby iteracji fluktuacja staje się bardziej stabilna, co wskazuje, że algorytm znalazł obiecujący region i nadal go eksploruje. W przypadku niektórych funkcji, takich jak F7 i F8, oczywiste jest, że fluktuacja ma tendencję do stabilizacji, a następnie pojawia się oscylacja, co oznacza, że algorytm HGS może wyskoczyć z lokalnego optimum i uniknąć popadania w lokalne optima, co jest również potwierdzeniem zrównoważonego wykonanie proponowanego algorytmu.

Algorytm ma tendencję do bardzo szybkiej konwergencji na wczesnych etapach iteracji poprzez monitorowanie ogólnej średniej sprawności. Chociaż trend spadkowy spowalnia wraz z iteracją i towarzyszą mu wariacje, średnia sprawność stopniowo spada, odzwierciedlając dobrze przygotowane wyszukiwanie i wysokie możliwości wyszukiwania algorytmu. Krzywa zbieżności pokazuje szybkość zbieżności algorytmu i punkt czasowy konwersji między eksploracją a eksploatacją. Krzywe zbieżności pokazują, że HGS może wykazywać szybką tendencję w radzeniu sobie z F8-F10 i nie ma problemu ze stagnacją.



Rysunek 4 Analiza jakościowa HGS dla niektórych typowych funkcji

3.2 Walidacja powszechnie używanych funkcji wzorcowych

W tej części przetestowaliśmy proponowany algorytm HGS na 23 wzorcowych funkcjach unimodalnych i multimodalnych. Szczegóły tych 23 funkcji można znaleźć w Tabeli 1, gdzie Dim oznacza wymiary

funkcji, Zakres odnosi się do dziedziny definicji funkcji, a

ujawnia optymalne rozwiązanie

funkcja.

Jeden punkt jest tak krytyczny w weryfikacji metod inteligencji obliczeniowej, a jest nim szczegółowy raport użytych parametrów do rzetelnej, uzasadnionej analizy porównawczej i tych samych warunków testu (Hao Chen, Ali Asghar Heidari, Huiling Chen, et al., 2020; Shi i wsp., 2018; Shi, Wang, Tang i Zhong, 2020; Shi, Wang, Zhong, Tang i Cheng, 2020). Chodzi o to, aby wyniki dowolnego rodzaju algorytmu były gromadzone w tych samych warunkach i bez uprzedzeń w stosunku do jakiegokolwiek konkretnej metody, która wykorzystywała lepsze warunki testowania, jak wynika z literatury referencyjnej (Fan i in., 2020; Huang i wsp., 2020; Ni i wsp., 2020; S. Yang i wsp., 2019; Zhang i wsp.).

Dla wiarygodności wyników eksperymentów, wszystkie eksperymenty przeprowadzono w tych samych warunkach: liczebność populacji ustalono na 30; a maksymalne iteracje i wymiary ustawiono odpowiednio na 1000 i 30. Jednocześnie, aby wykluczyć wpływ czynników losowych, każdy algorytm testowaliśmy 30 razy. W niniejszej pracy zastosowano test Friedmana (Derrac, García, Molina i Herrera, 2011) oraz test rang znaków Wilcoxona (García, Fernández, Luengo i Herrera, 2010) w celu zidentyfikowania istotnych różnic algorytmów. Test Friedmana to nieparametryczny program statystyczny, który pozwala na przeprowadzenie dalszej analizy poprzez ranking średniej wydajności algorytmu. Test rang znaków Wilcoxona jest używany jako test istotności statystycznej, w którym wartość p niższa niż 0,05 pokazuje, że HGS działa znacznie lepiej niż jego konkurenci.

Tabela 1 Opis 23 funkcji benchmarku

ID	Równanie funkcji	Nic	Zakres	fmin
F1	$f_1(x) = \sum_{i=1}^n x_i^2$	30	[-100,100]	0
F2	$f_2(x) = \sum_{i=1}^n x_i + \prod_{i=1}^n x_i $	30	[-10,10]	0
F3	$f_3(x) = \sum_{i=1}^n (x_i - 1)^2$	30	[-100,100]	0
F4	$f_4(x) = \sum_{i=1}^n \{ x_i , 1 - x_i \} + \sum_{i=1}^n x_i^2$	30	[-100,100]	0
F5	$f_5(x) = \sum_{i=1}^n [100(1 + (x_i - 1)^2)^2 (1 + x_i^2)]$	30	[-30,30]	0
F6	$f_6(x) = \sum_{i=1}^n (x_i + 0.5)^2$	30	[-100,100]	0
F7	$f_7(x) = \sum_{i=1}^n (x_i - 1)^4 + \sum_{i=1}^n (x_i - 1)^2$	30	[-1,28,1,28]	0
F8	$f_8(x) = \sum_{i=1}^n (x_i - 1)^2 + \sum_{i=1}^n (x_i - 1)$	30	[-500,500]	-418.982
F9	$f_9(x) = \sum_{i=1}^n (x_i - 1)^2 - 10(2 + x_i)$	30	[-5,12,5.12]	0
F10	$f_{10}(x) = -20 \sum_{i=1}^n \{ \sum_{j=1}^n x_j^2 \} + \sum_{i=1}^n (x_i - 1)^2$	30	[-32,32]	0
F11	$f_{11}(x) = \frac{1}{4000} \sum_{i=1}^n \sum_{j=1}^n x_i^2 x_j^2 + \sum_{i=1}^n (x_i - 1)^2$	30	[-600,600]	0
F12	$f_{12}(x) = \sum_{i=1}^n \{ 10(x_i - 1)^2 + \sum_{j=1}^n (x_j - 1)^2 \} + \sum_{i=1}^n x_i^2$	30	[-50,50]	0
F13	$f_{13}(x) = \sum_{i=1}^n \{ 10(1 + x_i^2) + \sum_{j=1}^n (x_j - 1)^2 \} + \sum_{i=1}^n x_i^2$	30	[-50,50]	0

F14	$14() = \frac{1}{25} + \frac{1}{11} + \frac{1}{15} + \frac{1}{16} + \frac{1}{17} + \frac{1}{18} + \frac{1}{19} + \frac{1}{20} + \frac{1}{21} + \frac{1}{22} + \frac{1}{23} + \frac{1}{24} + \frac{1}{25}$	2	[-65,65]	1
F15	$15() = \frac{1}{11} + \frac{1}{15} + \frac{1}{16} + \frac{1}{17} + \frac{1}{18} + \frac{1}{19} + \frac{1}{20} + \frac{1}{21} + \frac{1}{22} + \frac{1}{23} + \frac{1}{24} + \frac{1}{25}$	4	[-5,5]	0,00030
F16	$16() = \frac{1}{11} + \frac{1}{15} + \frac{1}{16} + \frac{1}{17} + \frac{1}{18} + \frac{1}{19} + \frac{1}{20} + \frac{1}{21} + \frac{1}{22} + \frac{1}{23} + \frac{1}{24} + \frac{1}{25}$	2	[-5,5]	-1,0316
F17	$17() = \frac{1}{11} + \frac{1}{15} + \frac{1}{16} + \frac{1}{17} + \frac{1}{18} + \frac{1}{19} + \frac{1}{20} + \frac{1}{21} + \frac{1}{22} + \frac{1}{23} + \frac{1}{24} + \frac{1}{25}$	2	[-5,5]	0,398
F18	$18() = \frac{1}{11} + \frac{1}{15} + \frac{1}{16} + \frac{1}{17} + \frac{1}{18} + \frac{1}{19} + \frac{1}{20} + \frac{1}{21} + \frac{1}{22} + \frac{1}{23} + \frac{1}{24} + \frac{1}{25}$	2	[-2,2]	3
F19	$19() = \frac{1}{11} + \frac{1}{15} + \frac{1}{16} + \frac{1}{17} + \frac{1}{18} + \frac{1}{19} + \frac{1}{20} + \frac{1}{21} + \frac{1}{22} + \frac{1}{23} + \frac{1}{24} + \frac{1}{25}$	3	[1,3]	-3,86
F20	$20() = \frac{1}{11} + \frac{1}{15} + \frac{1}{16} + \frac{1}{17} + \frac{1}{18} + \frac{1}{19} + \frac{1}{20} + \frac{1}{21} + \frac{1}{22} + \frac{1}{23} + \frac{1}{24} + \frac{1}{25}$	6	[0,1]	-3,32
F21	$21() = \frac{1}{11} + \frac{1}{15} + \frac{1}{16} + \frac{1}{17} + \frac{1}{18} + \frac{1}{19} + \frac{1}{20} + \frac{1}{21} + \frac{1}{22} + \frac{1}{23} + \frac{1}{24} + \frac{1}{25}$	4	[0,10]	-10.1532
F22	$22() = \frac{1}{11} + \frac{1}{15} + \frac{1}{16} + \frac{1}{17} + \frac{1}{18} + \frac{1}{19} + \frac{1}{20} + \frac{1}{21} + \frac{1}{22} + \frac{1}{23} + \frac{1}{24} + \frac{1}{25}$	4	[0,10]	-10.4028
F23	$23() = \frac{1}{11} + \frac{1}{15} + \frac{1}{16} + \frac{1}{17} + \frac{1}{18} + \frac{1}{19} + \frac{1}{20} + \frac{1}{21} + \frac{1}{22} + \frac{1}{23} + \frac{1}{24} + \frac{1}{25}$	4	[0,10]	-10,5363

3.2.1 Porównanie z podstawowymi optymalizatorami

W tej części HGS porównano z 15 innymi metodami, które można podzielić na dwie klasy: metody dobrze znane i metody najnowsze. Najnowsze metody⁶ obejmują algorytm sinusoidalny (SCA) (Mirjalili, 2016), Algorytm Salp Swarm (SSA) (Mirjalili, et al., 2017), Grey Wolf Optimizer (GWO) (Mirjalili, Mirjalili, & Lewis, 2014), Moth-flame Optimization (MFO) (S. Mirjalili, 2015), Algorytm optymalizacji wielorybów (WOA) (Mirjalili & Lewis, 2016), Algorytm optymalizacji konika polnego (GOA) (Saremi, Mirjalili i Lewis, 2017), Algorytm Dragonfly (DA) (Seyedali Mirjalili, 2015b), Optymalizator Ant Lion (ALC) (Seyedali Mirjalili, 2015a) i Multi-Verse Optimizer (MVO) (Mirjalili, Mirjalili i Hatamlou, 2015). Ugruntowane metody obejmują optymalizację opartą na biogeografii (BBO) (Simon, 2008), optymalizację roju cząstek (PSO) (Kennedy i Eberhart, 1995), ewolucję różnicową (DE) (Storn i Price, 1997), algorytm świetlika (FA) (X.S. Yang, 2009), Algorytm nietoperzy (BA)⁷ (X.-S. Yang, 2010) oraz Algorytm zapylania kwiatów (FPA) (X.-S. Yang, Karamanoglu i Xingshi, 2014). Aby uzyskać pełne opisy tych

⁶ Nie możemy zweryfikować oryginalności i nowego wkładu niektórych z tych ostatnich metod opartych na metaforach, a istnieją pewne otwarte dyskusje na podobieństwo tych modeli, takie jak podobieństwo SCA, MFO i WOA do GWO (Tzanetos i Dunias, 2020).

⁷ Nie weryfikujemy innowacyjności algorytmu BA. W 2020 roku potwierdzono, że BA był hybrydowym wariantem PSO i symulowanego wyżarzania (SA) (Gagnon, kwiecień i Abran, 2020).

metody, proszę odnieść się do oryginalnych badań. Ustawienia parametrów tych algorytmów są pokazane w Tabeli 2.

Tabela 2 Ustawienia parametrów zaangażowanych IZ

Klasa	Ustawienia parametrów algorytmu			
Dobrze ugruntowane	BBO	$= 2; = 2;$	$= 0; = 1; = 6; = 1$	$= 1$
	PSO	$1 = 2; \quad 2$		
	Z		$= 0,5;$	$= 0,5$
	FA	$= 0,5; = 0,2; = 1$		
	BA	$= 0,5; = 0,5$		
Najnowsze metody	FPA	$\sim (0, \cdot); \sim (0,1); = 0,5$		
	SCA	$= 2$		
	W	$1 [0 \ 1]; = \quad 2 [0 \ 1];$		
	ŚWIETNIE	$[2,0]$		
	MFO	$= 1; = [-1,1]; \quad \square \quad \square [1, \quad 2]$		
	WOA	$1 = [2,0]; = [\square 2, \quad 1]; = 1$		
	GOA	$= 1; \quad = 0,00001; = 1$		
	DAJE	$\beta = 1,5$		
	WITAJ	$= 500$		
	MVO		$\square [0,2 \ 1];$	$[0,6 \ 1]$

Dane w Tabeli 3 przedstawiają wyniki porównania HGS z innymi tradycyjnymi MA, gdzie „+”, „-” i „=” wskazują, że HGS działa odpowiednio lepiej, gorzej i tak samo jak odpowiedni algorytm. Avg, czyli średni wynik rankingowy algorytmu, jest oparty na teście Freidmana. Z tabeli intuicyjnie możemy stwierdzić, że HGS zajmuje pierwsze miejsce. Każdemu przeciwnikowi trudno jest pokonać HGS na większości 23 funkcji testowych. Chociaż DE pokonuje HGS w największej liczbie funkcji, tylko pięć, a inne algorytmy nawet nie pokonują HGS na nikim. Średnia wartość naszej metody to tylko 2,17, czyli znacznie mniej niż inne algorytmy. W porównaniu z drugim w rankingu DE, średnia wartość HGS wynosi około połowy DE. Możemy stwierdzić, że wydajność HGS jest lepsza od innych

odpowiedniki.

Tabela A.1 w Dodatku A pokazuje konsekwencje testu rang Wilcoxona wykonanego przez HGS i inne algorytmy. Większość wartości p jest mniejsza niż 0,05, co stanowi 93,0% wszystkich danych. Nawet w SCA, PSO, BA i FPA wszystkie wartości p są mniejsze niż 0,05. Chociaż liczby wartości p, które są wyższe niż 0,05, są największe w DE i MFO, istnieje tylko pięć przypadków. Fakt ten dodatkowo pokazuje, że HGS ma silne znaczenie statystyczne w porównaniu z innymi metodami.

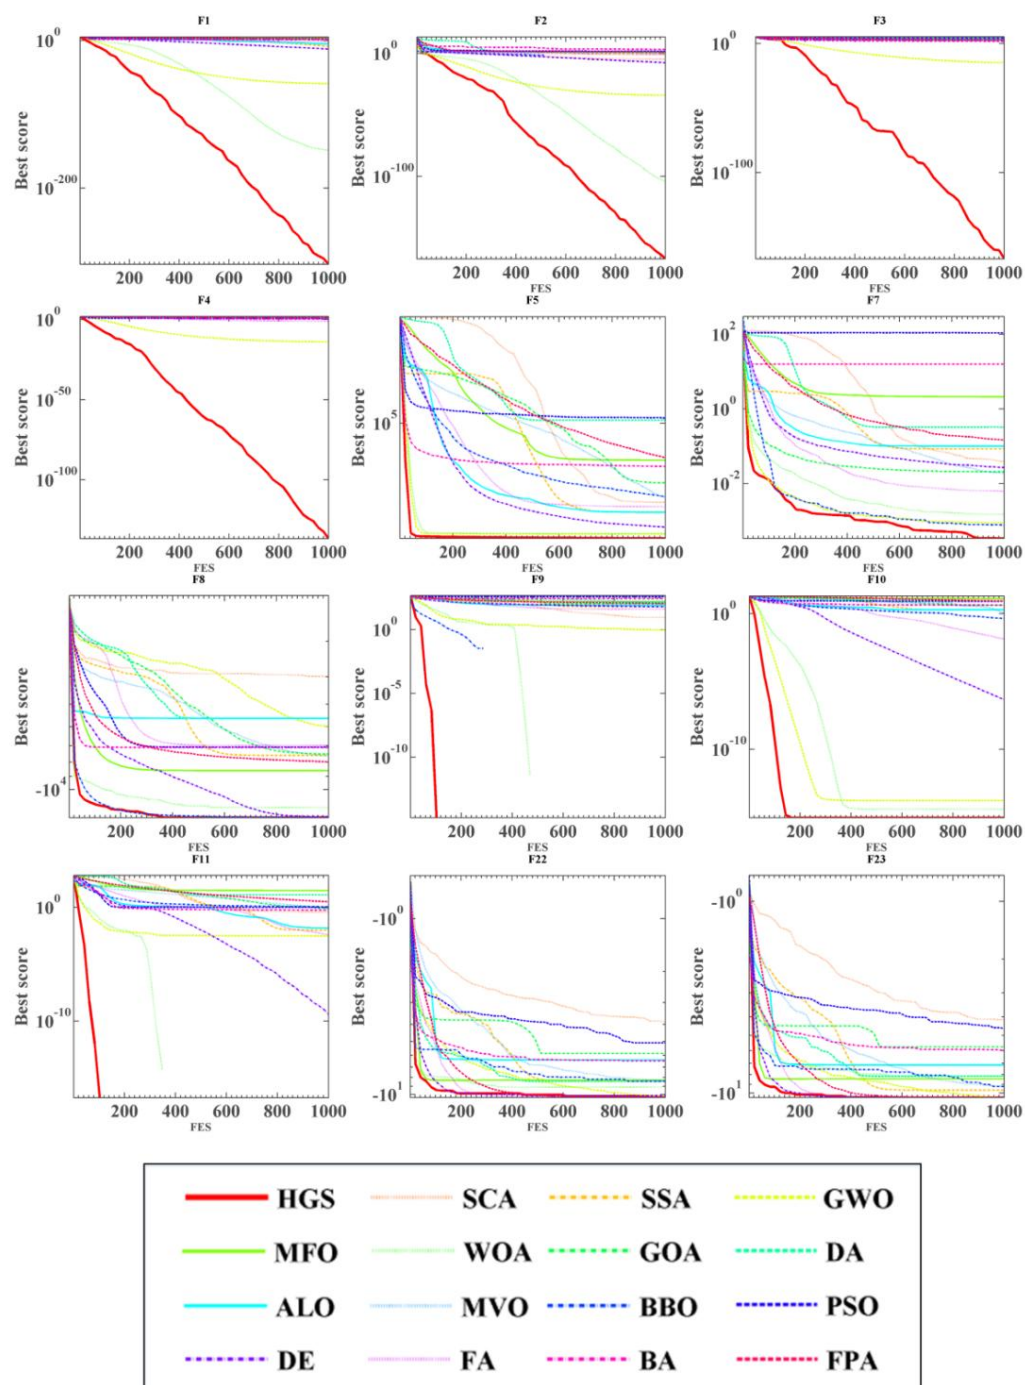
Tabela 3 Porównanie wyników algorytmu HGS na 23 funkcjach benchmarku z tradycyjnymi algorytmami

Algorytm	F1		F2		F3	
	AVG	GODZINY	AVG	GODZINY	AVG	GODZINY
HGS	5.10E-304	0,00E + 00	6.00E-168	0,00E + 00	1.20E-167	0,00E + 00
SCA	7.19E-02	2,66E-01	2.65E-05	5.47E-05	3.76E+03	3.61E+03
W	1.15E-08	2,52E-09	7.03E-01	5.97E-01	2,73E+02	1,96E+02
ŚWIETNIE	3,85E-59	6.10E-59	1.20E-34	1.48E-34	2.00E-15	4.12E-15

MFO	2,67E+03	4.50E+03	3,57E+01	1.98E+01	2.28E+04	1.41E+04
WOA	8.30E-150	3,40E-149	8.10E-105	1.90E-104	1.92E+04	1.15E+04
GOA	7,90E+00	5.18E+00	8.00E + 00	1.05E+01	2,05E+03	9.88E+02
DAJE	1.10E+03	5.10E+02	1.48E+01	5.47E+00	1.20E+04	7.10E+03
WITAJ	1.25E-05	8.89E-06	4.26E + 01	4.93E+01	1.22E+03	5.52E+02
MVO	3.03E-01	8.98E-02	3.71E-01	1.03E-01	4.49E+01	1.89E+01
BBO	1.28E+01	5.11E+00	0,00E + 00	0,00E + 00	7,72E+03	2,67E+03
PSO	1,26E + 02	1,52E+01	7.29E+01	1,56E+01	4.20E+02	8.46E+01
Z	2.86E-12	1.42E-12	3.71E-08	1.17E-08	2,46E+04	4.20E+03
FA	2.81E-03	7.78E-04	1.47E-01	7.82E-02	7.93E+02	3.95E+02
BA	1.48E+01	2.02E+00	2,53E+03	1,37E+04	6.70E+01	1.40E+01
FPA	2,41E+02	7.87E+01	1,56E+01	3.68E+00	3.67E+02	1,27E+02
	F4		F5		F6	
Algorytm AVG	GODZINY		AVG	GODZINY	AVG	GODZINY
HGS	2.50E-137	9.80E-137	1.92E+01	9.77E+01	7.78E-07	1.17E-06
SCA	1.95E+01	1.08E+01	2.80E+02	5.07E+02	4.63E+00	4.82E-01
W	8.97E+00	4.01E+00	1,37E+02	1,77E+02	1.17E-08	3.42E-09
ŚWIETNIE	1.31E-14	1.59E-14	2.68E+01	7.76E-01	6.34E-01	3.50E-01
MFO	6.86E + 01	7,66E+00	6.47E+03	2.27E+04	1.66E+03	4,59E+03
WOA	4.40E+01	2,89E+01	2,71E+01	4.67E-01	9.51E-02	1.14E-01
GOA	1.09E+01	3.50E+00	1.21E+03	1,50E+03	7.33E+00	6.11E+00
DAJE	2,42E+01	7.91E+00	1,25E+05	1,02E+05	1.20E+00	5.20E+02
WITAJ	1.18E+01	3.13E+00	1.34E+02	2.22E+02	8.28E-06	7.32E-06
MVO	9.40E-01	3.14E-01	3.98E+02	7,26E + 02	3.07E-01	9.51E-02
BBO	3.83E+01	1,25E+01	4.34E+02	2,46E+02	1.70E+01	8.78E+00
PSO	4.47E+00	1.95E-01	1.45E + 05	3.43E+04	1.30E+02	1,26E + 01
Z	1.92E+00	3,59E-01	4.46E+01	2.20E+01	2.62E-12	1.36E-12
FA	6.62E-02	1,51E-02	2.02E+02	3,94E+02	2.81E-03	8.27E-04
BA	1.90E+00	2.27E-01	4.05E+03	1.29E+03	1.47E+01	1,84E+00
FPA	1.59E+01	3.40E+00	7.52E+03	4,57E+03	2.22E+02	8.13E+01
	F7		F8		F9	
Algorytm AVG	GODZINY		AVG	GODZINY	AVG	GODZINY
HGS	3.43E-04	4.66E-04	-1,26E + 04	1.40E-01	0,00E + 00	0,00E + 00
SCA	3.95E-02	3.76E-02	-4,00 E + 03	3.04E+02	9.00 E + 00	1.23E+01
W	8.58E-02	2.84E-02	-7,58E+03	8.00E + 02	6.22E+01	2.09E+01
ŚWIETNIE	8.84E-04	4.59E-04	-5,98E+03	5.83E+02	9.40E-01	3.04E+00
MFO	2.12E+00	4.15E+00	-8,58E+03	9.21E+02	1,55E+02	3.86E + 01
WOA	1.50E+00	1.99E-03	-1,16E+04 4	1.30E+03	0,00E + 00	0,00E + 00
GOA	2.10E-02	8.21E-03	-7,49E+03	7,50E+02	9.61E+01	3.46E+01
DAJE	3.28E-01	1.74E-01	-5,61E+03	6.62E+02	1.48E+02	3.10E+02
WITAJ	1.01E-01	4.17E-02	-5,61E+03	5.34E+02	7,78E+01	1.95E+01
MVO	1.93E-02	8.42E-03	-7,59E+03	5.93E+02	1.08E+02	2,81E + 01
BBO	7.76E-04	8.31E-04	-1,25E+04	1.16E+01	0,00E + 00	0,00E + 00
PSO	1.10E+02	3.11E+01	-7.09E+03	8.76E+02	3.66E+02	2.13E+01
Z	2.72E-02	5.77E-03	-1,25E+04	9.61E+01	5.94E+01	6.45E + 00
FA	6.27E-03	2.27E-03	-6,98E+03	5.10E+02	4.01E+01	1.16E+01
BA	1.59E+01	9.77E+00	-7,11E+03	6.34E+02	2,63E+02	2.47E+01
FPA	1.47E-01	5.47E-02	-7,99E+03	1.87E+02	1.12E+02	2.08E+01
	F10		F11		F12	
Algorytm AVG	GODZINY		AVG	GODZINY	AVG	GODZINY
HGS	8.88E-16	0,00E + 00	0,00E + 00	0,00E + 00	1.07E-08	1.61E-08

SCA	1.47E+01	8.94E+00	3.79E-01	2.70E-01	5.98E+01	3.08E+02
W	1,99E+00	5.25E-01	1.04E-02	9.53E-03	5.65E+00	2.82E+00
ŚWIETNIE	1.59E-14	2,90E-15	3.07E-03	7.78E-03	4.04E-02	2.10E-02
MFO	1.28E+01	7.57E+00	3.01E+01	4,94E+01	8.53E+06	4.67E+07
WOA	3.61E-15	2.22E-15	0.00E + 00	0,00E + 00	7.51E-03	8.42E-03
GOA	4.18E+00	9.64E-01	8.04E-01	1.70E-01	6.05E+00	2.59E+00
DAJE	8.87E+00	1.69E+00	1.27E+01	7,85E+00	1.95E+02	6.17E+02
WITAJ	1.97E+00	5.68E-01	1.55E-02	1.49E-02	9.83E+00	4.73E+00
MVO	1.10E+00	7.29E-01	5.66E-01	1.35E-01	1.07E+00	1.20E+00
BBO	4,55E-01	4.17E-01	1.13E+00	5.14E-02	4,52E-02	4.21E-02
PSO	8.28E+00	4.02E-01	1.03E+00	1.08E-02	4,86E + 00	7.09E-01
Z	4.48E-07	1.20E-07	3.82E-10	1.38E-09	3,56E-13	2,55E-13
FA	1.38E-02	2.44E-03	4.00E-03	2.36E-03	2,51E-05	1.17E-05
BA	4.36E+00	1.90E-01	5.59E-01	6.27E-02	1.20E+01	4.37E+00
FPA	8.68E+00	1.09E+00	3.07E+00	6.95E-01	4.36E+00	1.03E+00
F13		F14		F15		
Algorytm AVG	GODZINY		AVG	GODZINY	AVG	GODZINY
HGS	9.91E-08	6.74E-08	1.97E+00	2.98E+00	6.80E-04	3.47E-04
SCA	1.01E+01	3.09E+01	1.66E+00	9.49E-01	9.00E-04	3.72E-04
W	3.09E+00	7,64E+00	9.98E-01	2.31E-16	1.54E-03	3,56E-03
ŚWIETNIE	5.40E-01	2.47E-01	4.07E+00	3.68E+00	5.10E-03	8.57E-03
MFO	1,37E+07	7.49E+07	2,81E + 00	2.01E+00	1.90E-03	3.76E-03
WOA	2.38E-01	2.08E-01	2,56E+00	3.33E+00	6.76E-04	3.49E-04
GOA	2.43E+01	1.43E+01	9.98E-01	4.03E-16	9.66E-03	1.26E-02
DAJE	3.38E+04	6.34E+04	9.98E-01	5.02E-10	2.59E-03	4.72E-03
WITAJ	8.36E-01	2.29E+00	1,62E+00	1,26E + 00	8.44E-04	2.07E-04
MVO	7.76E-02	5.78E-02	9.98E-01	9.70E-12	5.33E-03	8.44E-03
BBO	3.67E-01	2.06E-01	9.98E-01	5.65E-16	6.70E-02	1.54E-02
PSO	2.25E+01	3.34E+00	3,56E+00	2,49E+00	1.23E-03	4.14E-04
Z	1.69E-12	1.14E-12	1.16E+00	9.00 E + 00	6.91E-04	1.70E-04
FA	3.40E-04	1.80E-04	1.35E+00	5.98E-01	9.26E-04	1.16E-03
BA	2.25E+00	3.03E-01	4.43E+00	4.03E+00	8.79E-03	1.34E-02
FPA	2,56E+01	5.57E+00	9.98E-01	2.79E-08	4.38E-04	1.11E-04
F 16		F17		F18		
Algorytm AVG	GODZINY		AVG	GODZINY	AVG	GODZINY
HGS	-1,03E+00	5.45E-16	3.98E-01	0,00E + 00	3.00E + 00	3,56E-15
SCA	-1,03E+00	2.37E-05	3.98E-01	1.00E-03	3.00E + 00	3.93E-05
W	-1,03E+00	7,61E-15	3.98E-01	3,81E-15	3.00E + 00	4,50E-14
ŚWIETNIE	-1,03E+00	8.53E-09	3.98E-01	3.42E-07	3.00E + 00	1.03E-05
MFO	-1,03E+00	6.78E-16	3.98E-01	0,00E + 00	3.00E + 00	2.14E-15
WOA	-1,03E+00	1.44E-10	3.98E-01	8.35E-07	3.00E + 00	2.54E-05
GOA	-1,03E+00	2.39E-14	3.98E-01	2.59E-14	5.70E+00	1.48E+01
DAJE	-1,03E+00	1.88E-06	3.98E-01	9,99E-07	3.00E + 00	6.12E-05
WITAJ	-1,03E+00	5.83E-14	3.98E-01	1.30E-14	3.00E + 00	4.22E-13
MVO	-1,03E+00	9.74E-08	3.98E-01	2.59E-08	5.70E+00	1.48E+01
BBO	0,00E + 00	0,00E + 00	6.45E-01	0,00E + 00	3.00E + 00	0,00E + 00
PSO	-1,03E+00	1.28E-03	3.98E-01	6.87E-04	3.09E+00	7.39E-02
Z	-1,03E+00	6.78E-16	3.98E-01	0,00E + 00	3.00E + 00	1.21E-15
FA	-1,03E+00	1.31E-09	3.98E-01	6.21E-10	3.00E + 00	9.77E-09
BA	-1,03E+00	3.85E-04	3.98E-01	1.66E-04	3.04E+00	3.41E-02
FPA	-1,03E+00	1.09E-11	3.98E-01	3.69E-15	3.00E + 00	3.40E-12

	F19		F20		F21	
Algorytm	AVG	GODZINY	AVG	GODZINY	AVG	GODZINY
HGS	-3,86E + 00	2.45E-15	-3,25E+00	6.68E-02	-9,98E+00	9.31E-01
SCA	-3,86E + 00	2.34E-03	-2,80E+00	4.67E-01	-2,95E+00	1.86E + 00
W	-3,86E + 00	4,92E-14	-3,24E+00	5.66E-02	-7,72E+00	2,92E+00
ŚWIETNIE	-3,86E + 00	2.41E-03	-3,23E+00	1.09E-01	-9,48E+00	1,75E+00
MFO	-3,86E + 00	2,71E-15	-3,20E+00	4.90E-02	-7,06E+00	3.46E+00
WOA	-3,86E + 00	3.19E-03	-3,24E+00	1.17E-01	-9,29E+00	1.93E+00
GOA	-3,81E + 00	1.11E-01	-3,26E + 00	6.13E-02	-6,72E+00	3.39E+00
DAJE	-3,86E + 00	1.01E-04	-3,26E + 00	6.90E-02	-6,85E+00	2,81E + 00
WITAJ	-3,86E + 00	1.57E-14	-3,27E+00	6.03E-02	-7,30E+00	3.21E+00
MVO	-3,86E + 00	5.92E-07	-3,27E+00	5.95E-02	-7,71E+00	2,70E+00
BBO	-3,35E-01	1.69E-16	-1,66E-01	2.82E-17	-6,49E+00	3,57E+00
PSO	-3,86E + 00	1.05E-02	-2,78E+00	2.08E-01	-4,00 E + 00	1.23E+00
Z	-3,86E + 00	2,71E-15	-3,32E+00	9.45E-05	-9,63E+00	1.90E+00
FA	-3,86E + 00	3,91E-10	-3,29E+00	5.57E-02	-9,66E+00	1.90E+00
BA	-3,84E+00	1.27E-02	-2,91E+00	1.09E-01	-4,56E+00	2,41E+00
FPA	-3,86E + 00	2.09E-11	-3,32E+00	6.03E-03	-1,02E+01	6.87E-05
	F22		F23			
Algorytm	AVG	GODZINY	AVG	GODZINY	+/-/=	Średnia Ranga
HGS	-1,04E+01	1.07E-05	-1,05E+01	3,94E-15	~	2.17 1
SCA	-3,87E+00	1.95E+00	-4,14E + 00	1,77E+00	22/1/0	11,39 13
W	-8,38E+00	3.21E+00	-9,65E+00	2,35E+00	21.01.2011	6,83 6
ŚWIETNIE	-1,02E+01	9.70E-01	-1,05E+01	2.83E-04	20/0/3	6,48 4
MFO	-8,30E+00	3.27E+00	-8,43E+00	3.29E+00	18/0/5	11.13 12
WOA	-9,08E+00	2,46E+00	-8,16E+00	3.00E + 00	19/0/4	6,61 5
GOA	-5,84E+00	3.39E+00	-5,74E+00	3.80E+00	21/0/2	10.26 11
DAJE	-8,42E+00	2.87E+00	-8,17E+00	3.21E+00	21.01.2011	11,91 14
WITAJ	-6,37E+00	3.22E+00	-7,14E + 00	3.33E+00	21.01.2011	8.34 9
MVO	-8,33E+00	3.06E+00	-9,19E + 00	2,52E+00	21.01.2011	7,91 7
BBO	-8,42E+00	3.14E + 00	-9,23E+00	2.71E+00	20/2/1	9.22 10
PSO	-5,09E+00	1.27E+00	-4,61E+00	1.29E+00	23/0/0	12,96 16
Z	-1,02E+01	9.72E-01	-1,05E+01	5.41E-02	12/5/6	4.04 2
FA	-1,04E+01	8.88E-07	-1,05E+01	6.40E-07	19/2/2	5,74 3
BA	-6,45E + 00	2,76E+00	-6,02E+00	3.02E+00	23/0/0	12.09 15
FPA	-1,04E+01	2.54E-03	-1,05E+01	1.70E-03	19.04.0	8.30 8



Rysunek 5 Porównania między HGS a tradycyjnymi MA.

Analiza wyników na rysunku 5 pokazuje, że tempo konwergencji HGS jest szybkie. Od F1 do F4 widzimy, że HGS osiąga zbieżność najszybciej spośród wszystkich algorytmów, inne algorytmy są zbieżne dość wolno, a niektóre nawet osiągają lokalne optimum. F5 i F9-F11 wskazują, że HGS ma wysoką dokładność w rozwiązywaniu problemów i może szybko znaleźć globalne optimum na początku iteracji. Choć szybkość zbieżności niektórych algorytmów jest również bardzo konkurencyjna na niektórych etapach, dokładność rozwiązania tych metod nie jest tak wysoka jak w przypadku HGS, a rozwiązanie znalezione przez HGS ma wyższą jakość. Na podstawie wyników

F7 i F8, prędkość konwergencji HGS zwalnia, ale nadal znajduje globalne optimum jako pierwsze w porównaniu z innymi algorytmami. Niektóre algorytmy osiągają nawet lokalne optimum na początku iteracji.

Obserwując algorytmy wydajności na funkcjach F22 i F23, można wywnioskować, że HGS ma silną zdolność do globalnej eksploracji. L może skutecznie przełączać się między dwoma trybami głodu, a LH intuicyjnie określa minimalną wartość głodu jednostki. Aby zapobiec popadaniu HGS w lokalne optima w obliczu niektórych multimodalnych krajobrazów, oba z nich bezpośrednio wpływają na wagę głodu, co przyczynia się do poprawy wskaźników HGS w procesie iteracyjnym i lepszej równowagi między etapami wyszukiwania i odkrywania. W fazie poszukiwań przestrzeni rozwiązań może być przeszukiwana możliwie kompletnie, tak aby algorytm mógł osiągnąć efekt szybkiej zbieżności na wczesnym etapie. Na etapie wydobywania optymalne rozwiązanie można znaleźć w pobliżu, co zapewnia dokładność rozwiązania.

3.2.2 Porównanie z ulepszonymi metodami metaheurystycznymi

Aby dodatkowo zilustrować skuteczność algorytmu HGS, porównaliśmy HGS z dziesięcioma najnowocześniejszymi zaawansowanymi algorytmami: IWOA (Tubishat, Abushariah, Idris i Aljarah, 2018), OBWOA (Elsayed abd el aziz i Oliva, 2018), ACWOA (Khashan, El-Hosseini, Y. Haikal i Badawy, 2018), SCADE (Nenavath i Jatoth, 2018), CGSCA (Kumar, Hussain, Singh i Panigrahi, 2017), m_SCA (Gupta i Deep, 2018), RCBA (Liang, Liu, Shen, Li i Man, 2018), CBA (Adarsh, Raghunathan, Jayabarathi i Yang, 2016) oraz CDLOBA (Yong, He, Li i Zhou, 2018). Pełne nazwy tych metod oraz pełne opisy znajdują się w pracach oryginalnych.

Na podstawie danych testowych w Tabeli 4 można zauważyć, że HGS wykazuje potężne działanie w zakresie funkcji multimodalnych, zwłaszcza w przypadku funkcji multimodalnych o stałym wymiarze. Średnia wartość, oparta na wartości testu Friedmana, wynosi tylko 1,78, czyli znacznie mniej niż inne algorytmy i stanowi tylko około jednej piątej maksymalnej średniej CDLOBA. Żaden z pięciu algorytmów, IWOA, CGSCA, RCBA, CBA lub CDLOBA, nie jest w stanie pokonać HGS w 23 funkcjach testowych. Chociaż SCADE pokonuje HGS w niektórych funkcjach, jest tylko pięć przypadków. Ta obserwacja wyjaśnia, że HGS ma duże możliwości optymalizacji pod względem trendów poszukiwawczych i wydobywczych. Jednym ze skutecznych mechanizmów skutkujących udoskonaleniem rozwiązań proponowanego HGS jest to, że jest on wyposażony w dwie prędkości, I i E. Cechy te pomagają HGS w zmianie pozycji początkowych i trybu wyszukiwania, co zapewnia dogłębną eksplorację całości przestrzeni rozwiązań w jak największym stopniu i w dużym stopniu wzmacniają cechy eksploracyjne algorytmu. Ponadto wagi głodu mogą podkreślać trendy perturbacji optymalizatora HGS podczas iteracji. Ta cecha zmniejsza również zmianę stagnacji ze względu na istnienie kilku lokalnych optimów.

Tabela A.2 w Dodatku A ujawnia wartość p HGS i jej porównania we wszystkich funkcjach testowych. Z tabeli widzimy, że wszystkie wartości w CDLOBA są mniejsze niż 0,05. CGSCA, RCBA i CBA mają tylko jedną wartość danych większą niż 0,05 co najwyżej. Chociaż wartości OBWOA większe niż 0,05 są największe, jest tylko siedem przypadków. Z tabeli widać również, że różnica między wartościami wyższymi niż 0,05 i 0,05 nie jest znacząca. Te wyniki testów wskazują, że algorytm HGS jest znacznie lepszy w porównaniu z innymi algorytmami.

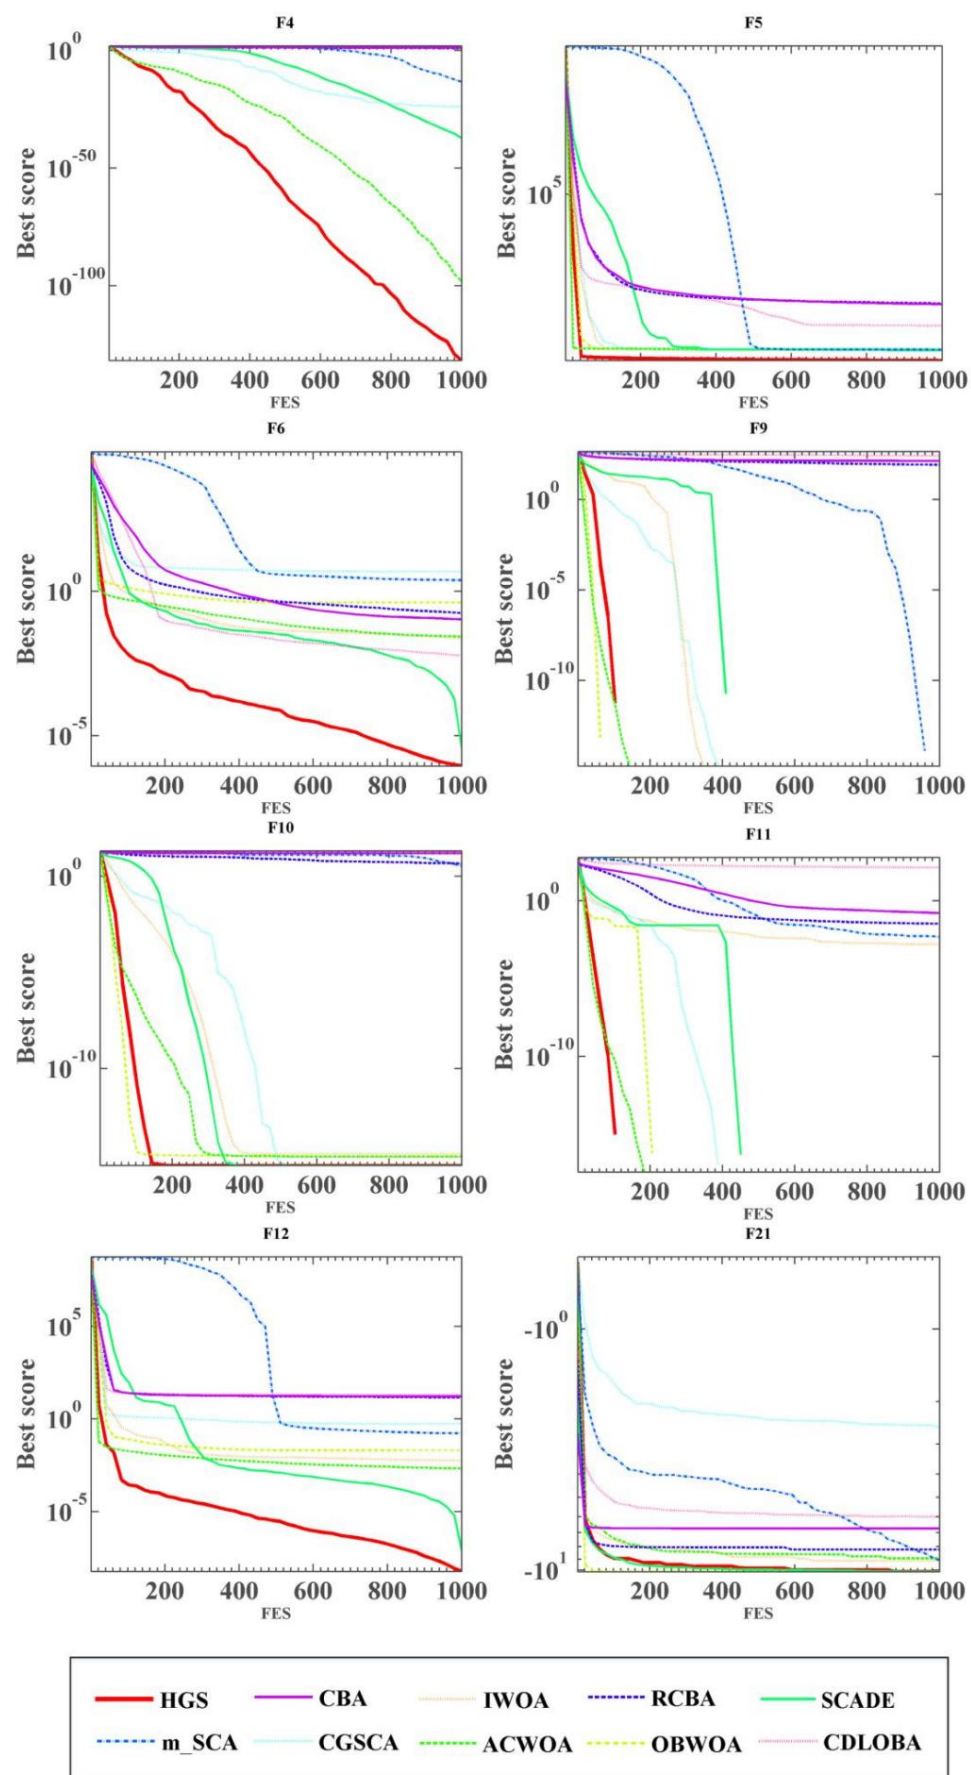
Tabela 4 Wyniki porównania 23 funkcji porównawczych z zaawansowanymi algorytmami

F1			F2		F3	
Algorytm	AVG	GODZINY	AVG	GODZINY	AVG	GODZINY
HGS	0,00E + 00	0,00E + 00	4,83E-166	0,00E + 00	1,54E-152	8.45E-152
IWOA	5.58E-150	2.2E-149	2,94E-102	9.1E-102	1.40E+04	6.03E+03
OBWOA	0.00E+00	0,00E + 00	6.25E-289	0,00E + 00	1.49E+04	1.09E+04
ACWOA	6.87E-222	0,00E + 00	1.15E-113	5.69E-113	8.95E-177	0,00E + 00
SCADE	8.94E-217	0,00E + 00	3,58E-124	1.96E-123	3.81E-183	0,00E + 00
CGSCA	1.07E-57	5.85E-57	7,92E-33	4.32E-32	6.71E-44	3,67E-43
m_SCA	8.40E-48	3.48E-47	2.86E-31	1,54E-30	1.05E-11	5.76E-11
RCBA	1.62E-01	5.90E-02	9.94E+00	2.74E+01	9.54E+01	3.12E+01
CBA	2.90E-02	1.38E-01	1.49E+02	6.65E+02	7.90E+01	4.02E+01
CDLOBA	6.17E-03	1.90E-03	3.95E+02	1.43E+03	4,55E-01	1.35E+00
F4			F5		F6	
Algorytm	AVG	GODZINY	AVG	GODZINY	AVG	GODZINY
HGS	2,32E-132	1,27E-131	1,52E+01	1.18E+01	8.72E-07	1.16E-06
IWOA	1.09E+01	1,75E+01	2,67E+01	7.48E-01	2.30E-02	6.25E-02
OBWOA	3.24E + 01	1.90E+01	2.72E+01	7.07E-01	4.13E-01	2.57E-01
ACWOA	8.81E-99	3,96E-98	2.68E+01	2.24E-01	2.72E-02	7.77E-03
PD	5.16E -38	1,84E-37	2,64E+01	7.18E+00	3.47E-06	2.65E-06
CGSCA	1.49E-24	8.18E-24	2.83E+01	5.00E-01	4.85E+00	2.43E-01
m_SCA	4.03E-14	1,29E-13	2.72E+01	8.29E-01	2.48E+00	5.24E-01
RCBA	1.01E+01	6.13E+00	3.11E+02	4,86E + 02	1.76E-01	4.19E-02
CBA	1.85E+01	7,79E+00	2.98E+02	4,86E + 02	1.07E-01	5.81E-01
CDLOBA	4.70E+01	8.78E+00	9.68E+01	1,39E+02	5.92E-03	1.67E-03
F7			F8		F9	
Algorytm	AVG	GODZINY	AVG	GODZINY	AVG	GODZINY
HGS	6.46E-04	9.46E-04	-1,25E+04	6.05E+02	0,00E + 00	0,00E + 00
IWOA	2.07E-03	2.36E-03	-1,08E+04	1,76E+03	0,00E + 00	0,00E + 00
OBWOA	1,53E-04	2.14E-04	-1.15E+04	1.29E+03	0,00E + 00	0,00E + 00
ACWOA	7.06E-05	5.92E-05	-1,26E + 04	4.09E+01	0,00E + 00	0,00E + 00
EXP	6.26E -04	3.29E-04	-1.24E+04	2,89E+02	0,00E + 00	0,00E + 00
CGSCA	5.28E-04	3.59E-04	-4,19E + 03	7.06E+02	0,00E + 00	0,00E + 00
m_SCA	7.87E-04	6.22E-04	-6,13E+03	8.70E+02	0,00E + 00	0,00E + 00
RCBA	5.38E-01	1.92E-01	-7,42E+03	7.53E+02	8.23E+01	2.18E+01
CBA	3.03E-01	2.38E-01	-7,17E+03	7.04E+02	1.36E+02	4.19E + 01
CDLOBA	2.82E+01	3.50E+01	-7,40E+03	7,95E+02	2.59E+02	4.39E+01
F10			F11		F12	
Algorytm	AVG	GODZINY	AVG	GODZINY	AVG	GODZINY
HGS	8.88E-16	0,00E + 00	0,00E + 00	0,00E + 00	5.87E-09	6.40E-09
IWOA	3.49E-15	2.27E-15	1.64E-03	6.28E-03	5.57E-03	1.07E-02
OBWOA	2,55E-15	2.03E-15	0,00E + 00	0,00E + 00	2.06E-02	1.06E-02
ACWOA	2.55E-15	1.80E-15	0,00E + 00	0,00E + 00	2.13E-03	1.12E-03
PD	8.88E -16	0,00E + 00	0,00E + 00	0,00E + 00	8.11E-08	1.09E-07
CGSCA	8.88E-16	0,00E + 00	0,00E + 00	0,00E + 00	5.40E-01	7.60E-02
m_SCA	3.44E+00	7,60E+00	4.93E-03	2.70E-02	1.68E-01	5.98E-02
RCBA	4,54E+00	4.97E+00	3.45E-02	1.75E-02	1.46E+01	6.07E+00
CBA	1,56E+01	2,51E+00	1.67E-01	1.33E-01	1.66E+01	6.48E+00
CDLOBA	1.95E+01	9.51E-01	1.41E+02	9.60E+01	2.01E+01	5.45E + 00
F13			F14		F15	
Algorytm	AVG	GODZINY	AVG	GODZINY	AVG	GODZINY

HGS	6.55E-03	3.59E-02	1.65E+00	2.48E+00	6.45E-04	2.24E-04	
IWOA	1,53E-01	1.61E-01	2.34E+00	2,95E+00	6.30E-04	3.14E-04	
OBWOA	7.36E-01	3.04E-01	3.29E+00	3,51E+00	6.90E-04	3.27E-04	
ACWOA	5.65E-02	3.41E-02	2.01E+00	2,49E+00	3.35E-04	4.31E-05	
SCADE	1.05E -06	7.27E-07	9.98E-01	3.13E-08	3.15E-04	2.84E-06	
CGSCA	2.49E+00	9.86E-02	1.66E+00	9.51E-01	8.74E-04	4.41E-04	
m_SCA	1.64E+00	2.36E-01	1.39E+00	8.07E-01	8.21E-04	4.20E-04	
RCBA	9.86E-02	4.12E-02	5.88E+00	4.90E+00	7.26E-03	1.25E-02	
CBA	4.63E+01	1,67E+01	3.32E+00	3.48E+00	4.85E-03	7.89E-03	
CDLOBA	3.99E+01	1.43E+01	2,91E+00	1,51E+00	4.20E-03	7.36E-03	
F 16			F17		F18		
Algorytm	AVG	GODZINY	AVG	GODZINY	AVG	GODZINY	
HGS	-1,03E+00	5.13E-16	3.98E-01	0,00E + 00	3.00E + 00	2.16E-15	
IWOA	-1,03E+00	8.70E-11	3.98E-01	2.98E-07	3.00E + 00	3.01E-06	
OBWOA	-1,03E+00	6.51E-09	3.98E-01	1.11E-06	3.00E + 00	3.68E-05	
ACWOA	-1,03E+00	2.49E-04	4.01E-01	1.11E-02	3.00E + 00	1.29E-03	
WYgasa	-1,03E + 00	1.57E-05	3.98E-01	1.90E-04	3.00E + 00	1.26E-03	
CGSCA	-1,03E+00	4.16E-05	3.99E-01	1.78E-03	3.00E + 00	2.06E-05	
m_SCA	-1,03E+00	4.76E-08	3.98E-01	8.72E-07	3.00E + 00	5.70E-06	
RCBA	-1,03E+00	1.58E-06	3.98E-01	3.71E-07	3.00E + 00	7.90E-05	
CBA	-1,03E+00	1.92E-05	3.98E-01	7.20E-06	3.00E + 00	7.49E-04	
CDLOBA	-1,03E + 00	2.48E-04	3.98E-01	8.03E-05	3,01E+00	9.31E-03	
F19			F20		F21		
Algorytm	AVG	GODZINY	AVG	GODZINY	AVG	GODZINY	
HGS	-3,86E + 00	2,40E-15	-3,27E+00	7.29E-02	-1,02E+01	5.68E-15	
IWOA	-3,86E + 00	2.42E-06	-3,26E + 00	6.38E-02	-9,14E + 00	2,35E+00	
OBWOA	-3,86E + 00	4.26E-06	-3,28E+00	6.72E-02	-1,02E+01	9.54E-05	
ACWOA	-3,86E + 00	3.74E-03	-3,21E+00	1.14E-01	-8,94E+00	2.18E+00	
EXP	-3,86E + 00	3.17E-03	-3,19E + 00	6.82E-02	-1,02E+01	2.01E-04	
CGSCA	-3,85E+00	2.11E-03	-2,87E+00	3.43E-01	-2,58E+00	2.15E+00	
m_SCA	-3,86E + 00	2.29E-03	-3,21E+00	8.39E-02	-9,13E+00	2,05E+00	
RCBA	-3,86E + 00	4.30E-04	-3,27E+00	6.11E-02	-8,22E+00	2,86E + 00	
CBA	-3,86E + 00	1.04E-03	-3,25E+00	7.79E-02	-6,71E+00	3.19E + 00	
CDLOBA	-3,85E+00	8.20E-03	-2,98E+00	9.97E-02	-6,01E+00	3.34E+00	
F22			F23				
Algorytm	AVG	GODZINY	AVG	GODZINY	+/-/=	Średnia	Ranga
HGS	-1,04E+01	1.19E-15	-1,02E+01	1,37E+00	~	1,78	1
IWOA	-8,65E+00	2.77E+00	-8,47E+00	3.04E+00	19/0/4	4,57	5
OBWOA	-1.04E+01	9.23E-05	-1,05E+01	9.49E-05	15/1/7	4,00	3
ACWOA	-9,85E+00	1,61E+00	-1,05E+01	8.14E-02	16/3/4	4,09	4
EXP	-1,04E + 01	1.58E-04	-1,05E+01	1.64E-04	14/4/5	3,39	2
CGSCA	-3,78E+00	2.07E+00	-3,85E+00	1.86E + 00	19/0/4	6,52	7
m_SCA	-9,52E+00	2.00E + 00	-9,82E+00	1.85E+00	19.01.2013	5,57	6
RCBA	-7,82E+00	3.30E+00	-8,49E+00	3.25E+00	22/01	7,00	8
CBA	-6,86E + 00	3.68E+00	-6,63E+00	4.01E+00	21/0/2	7,87	9
CDLOBA	-6,76E+00	3.48E+00	-6,25E+00	3.83E+00	23/0/0	8.65	10

Krzywe zbieżności HGS przedstawiono na rysunku 6, który pokazuje, że szybkość i dokładność HGS są lepsze niż u konkurentów. W funkcji testowej F4 współczynnik konwergencji HGS jest stosunkowo

stałe, a globalne optymalne rozwiązanie znajduje się w bardzo szybkim tempie podczas całego procesu. W tym samym czasie, gdy HGS znajduje optymalne rozwiązanie, niektóre algorytmy właśnie zaczęły zbliżać się do pewnych rozwiązań. Z krzywych F5 i F9-F11 można zaobserwować, że HGS znajduje optymalne rozwiązanie z bardzo dużą prędkością podczas początkowych iteracji, ale niektóre z porównywanych algorytmów spadły do lokalnego optimum. Z tych wyników możemy wywnioskować, że HGS ma silną skłonność do poszukiwań i poszukiwań, a dwie fazy mają doskonałą stabilność ze względu na wpływ L i LH. W fazie poszukiwań oboje rozszerzają zakres poszukiwań tak bardzo, jak to możliwe i zapewniają, że osoba może szukać w małym zasięgu na etapie wydobywania.



Rysunek 6 Porównania między HGS a zaawansowanymi MA.

3.3 Walidacja funkcji IEEE CEC2014

Aby dodatkowo zilustrować wydajność algorytmu HGS, przetestowaliśmy go na zestawie benchmarków IEEE CEC2014. Zbiór danych jest podzielony na funkcje jednomodalne, proste funkcje multimodalne, funkcje hybrydowe i funkcje kompozycji. Szczegóły funkcji można znaleźć w tabeli 5. W tej części, dla wiarygodności eksperymentu, warunki związane z testem zostały dostosowane tak samo jak poprzednio: maksymalna liczba iteracji została ustalona na 1000, liczebność i wymiar zostały ustawione na 30, a zaangażowany algorytm był testowany 30 razy losowo na każdej funkcji. Do oceny wyników eksperymentalnych wykorzystano test Friedmana [32] i test rang znaków Wilcoxon [33].

Tabela 5 Opis funkcji IEEE CEC2014

Równanie funkcji ID	Nic	Zakres	F _{min}
Funkcje jednomodalne			
F1 Obrócona, wysoko uwarunkowana funkcja eliptyczna	30	[-100 100]	100
Funkcja obracanego wygiętego cygara F2	30	[-100 100]	200
Funkcja obracania dysku F3	30	[-100 100]	300
Proste funkcje multimodalne			
F4 przesunięta i obrócona funkcja Rosenbrocka	30	[-100 100]	400
F5 przesunięta i obrócona funkcja Ackleya	30	[-100 100]	500
F6 przesunięta i obrócona funkcja Weierstrassa	30	[-100 100]	600
F7 przesunięta i obrócona funkcja Griewanka	30	[-100 100]	700
F8 przesunięta funkcja Rastrigina	30	[-100 100]	800
F9 przesunięta i obrócona funkcja Rastrigina	30	[-100 100]	900
F10 przesunięta funkcja Schwefela	30	[-100 100]	1000
F11 przesunięta i obrócona funkcja Schwefela	30	[-100 100]	1100
F12 przesunięta i obrócona funkcja Katsuura	30	[-100 100]	1200
F13 Przesunięta i obrócona funkcja HappyCat	30	[-100 100]	1300
F14 przesunięta i obrócona funkcja HGBat	30	[-100 100]	1400
F15 przesunięty i obrócony rozszerzony Griewank plus Funkcja Rosenbrocka	30	[-100 100]	1500
F16 przesunięta i obrócona funkcja F6 rozszerzonego szkieletu	30	[-100,100]	1600
Funkcje hybrydowe			
F17 Funkcja hybrydowa 1 (N = 3)	30	[-100 100]	1700
F18 Funkcja hybrydowa 2 (N = 3)	30	[-100 100]	1800
F19 Funkcja hybrydowa 3 (N = 4)	30	[-100 100]	1900
F20 Funkcja hybrydowa 4 (N = 4)	30	[-100 100]	2000
F21 Funkcja hybrydowa 5 (N = 5)	30	[-100 100]	2100
F22 Funkcja hybrydowa 6 (N = 5)	30	[-100 100]	2200
Funkcje kompozycji			
F23 Funkcja kompozycji 1 (N = 5)	30	[-100 100]	2300
F24 Funkcja kompozycji 2 (N = 3)	30	[-100 100]	2400
F25 Funkcja kompozycji 3 (N = 3)	30	[-100 100]	2500
F26 Funkcja kompozycji 4 (N = 5)	30	[-100 100]	2600
F27 Funkcja kompozycji 5 (N = 5)	30	[-100 100]	2700
F28 Funkcja kompozycji 6 (N = 5)	30	[-100 100]	2800
F29 Funkcja kompozycji 7 (N = 3)	30	[-100 100]	2900
F30 Funkcja kompozycji 8 (N = 3)	30	[-100 100]	3000

3.3.1 Porównanie z innymi optymalizatorami

Proponowany HGS porównano z 12 tradycyjnymi MA w zbiorze danych IEEE CEC 2014, w tym SCA (Mirjalili, 2016), SSA (Mirjalili, et al., 2017), GWO (Mirjalili, et al., 2014), MFO (S. Mirjalili, 2015), WOA (Mirjalili i Lewis, 2016), GOA (Saremi i in., 2017), DA (Seyedali Mirjalili, 2015b), ALO (Seyedali Mirjalili, 2015a), PSO (Kennedy i Eberhart, 1995), DE (Sun, Yang, Yang i Xu, 2019), BA i FPA (X.-S. Yang i in., 2014). Ustawienia parametrów wspomnianych algorytmów zestawiono w tabeli 2.

Szczegółowe wyniki porównania przedstawiono w Tabeli 6. Odkryliśmy, że HGS zajmuje pierwsze miejsce wśród wszystkich algorytmów, ze znacznie mniejszą średnią. HGS wykazuje silną umiejętność wyszukiwania optymalnych rozwiązań w przypadku większości funkcji. Powszechnie wiadomo, że DE wykazuje doskonałą wydajność w zestawach danych zawodów, ale pokonuje HGS tylko w ośmiu funkcjach, podczas gdy HGS pokonuje HGS w 19 funkcjach. Jako stałowymiarowa funkcja wielomodalna, funkcje składu mają dużą liczbę lokalnych optimów, co wymaga algorytmu o doskonałej wydajności. HGS zajmuje pierwsze miejsce pod względem funkcji złożonych, w tym F23, F24, F25, F27, F28 i F30, co pokazuje, że ogólna wydajność HGS jest potężna, dzięki czemu może działać płynniej przejście między trendami poszukiwawczymi i poszukiwawczymi.

Tabela A.3 w Załączniku A przedstawia wartość p HGS w porównaniu z innymi algorytmami. Wśród 360 zbiorów danych 318 to mniej niż 0,05, co stanowi 88,1% wszystkich danych. Warto zauważyć, że te zestawy danych są znacznie mniejsze niż 0,05. Chociaż w ALO jest więcej niż 0,05 danych, jest tylko 7 zestawów danych. Ich liczba w SCA i DA jest nawet zredukowana do jednego. To pokazuje, że HGS ma przewagę statystyczną nad innymi konkurencyjnymi MA.

Tabela 6 Wyniki porównania funkcji CEC2014 z tradycyjnymi MA

F1			F2		F3	
Algorytm	AVG	GODZINY	AVG	GODZINY	AVG	GODZINY
HGS	9.56E+06	7.25E+06	4,53E+06	1.46E+07	1,62E+04	1.57E+04
SCA	4.24E+08	1.39E+08	2,57E+10	4.62E+09	5.95E+04	1.06E+04
W	2.39E+07	1.41E+07	9.64E+03	9.52E+03	7.31E+04	2.22E+04
WIELKA 9.07E + 07	5.57E+07		3.16E+09	2.60E+09	4,55E+04	1.07E+04
MFO	8.69E+07	9.20E+07	1,41E+10	1.08E+10	1.09E+05	6.24E+04
WOA	1.31E+08	3.88E+07	2.26E + 09	1.15E+09	9.91E+04	4,99E+04
GOA	3.29E+07	1.45E + 07	1.87E+07	1.11E+07	6.58E+04	2,69E+04
DAJE	3.48E+08	1.93E+08	5.37E+09	3.23E+09	1.57E+05	2,77E+04
WITAJ	1.43E+07	7.01E+06	1.08E+04	7.92E+03	1.48E+05	3.72E+04
PSO	1,75E+07	5.95E+06	1.96E+08	2.46E+07	4.12E+04	1.10E+04
Z	1.01E+08	3.01E+07	2.13E+03	4.05E+03	3,02E+03	2,46E+03
BA	9.52E+06	4.20E+06	2.28E+07	4.00 E + 06	8.77E+04	2,46E+04
FPA	7.38E+06	4.03E+06	2.07E+09	1.10E+09	2,96E+04	7.20E+03
F4			F5		F6	
Algorytm	AVG	GODZINY	AVG	GODZINY	AVG	GODZINY
HGS	5.25E+02	4.11E+01	5.20E+02	9.51E-02	6.20E+02	3.26E + 00
SCA	2,42E+03	7.11E+02	5.21E+02	5.65E-02	6.37E+02	2,89E+00
W	5.50E+02	4.66E+01	5.20E+02	1.27E-01	6.26E + 02	3.47E+00
WIELKA 7.02E + 02	1,55E+02		5.21E+02	5.54E-02	6.16E+02	3.10E+00
MFO	1.44E+03	9.57E+02	5.20E+02	1.95E-01	6.24E+02	3,55E+00
WOA	8.72E+02	1,56E+02	5.21E+02	1.25E-01	6.37E+02	3.15E+00
GOA	5.35E+02	4.00E + 01	5.20E+02	7.82E-02	6.22E+02	3.67E+00
DAJE	1,37E+03	5.52E+02	5.21E+02	8.22E-02	6.37E+02	3.50E+00
WITAJ	5.46E+02	3,55E+01	5.20E+02	1,52E-01	6.26E + 02	3.76E+00
PSO	4,82E+02	3.87E+01	5.21E+02	5.30E-02	6.25E+02	2.98E+00
Z	5.50E+02	1,86E + 01	5.21E+02	5.32E-02	6.29E+02	1.27E+00
BA	5.08E+02	3.11E+01	5.21E+02	5.96E-02	6.36E+02	3.06E+00
FPA	6,79E+02	7.50E+01	5.21E+02	5.08E-02	6.32E+02	1,32E+00
F7			F8		F9	
Algorytm	AVG	GODZINY	AVG	GODZINY	AVG	GODZINY

HGS	7.01E+02	2.34E+00	8.26E + 02	1.01E+01	1.04E+03	3.16E+01
SCA	9.33E+02	3.28E+01	1.07E+03	2.43E+01	1.20E+03	2,61E+01
W	7.00E + 02	1.37E-02	9.52E+02	3.86E + 01	1.05E+03	3.87E+01
WIELKA 7.22E + 02		2.18E+01	8.97E+02	2,37E+01	1.01E+03	2.16E+01
MFO	7,90E+02	6.93E+01	9.42E+02	4,51E+01	1.09E+03	4.24E+01
WOA	7.13E+02	6.46E+00	1.01E+03	4.77E+01	1.17E+03	4.25E+01
GOA	7.01E+02	1.19E-01	9.51E+02	4.05E+01	1.07E+03	4.85E+01
DAJE	7,75E+02	3.13E+01	1.09E+03	5.48E+01	1.21E+03	5.89E+01
WITAJ	7.00E + 02	8.36E-03	9.23E+02	3.29E+01	1.05E+03	4.32E+01
PSO	7.03E+02	2.09E-01	9.87E+02	2.14E + 01	1.14E + 03	2.72E+01
Z	7.00E + 02	1.82E-02	8.51E+02	5.28E+00	1.07E+03	1.28E+01
BA	7.01E+02	3.01E-02	1.03E+03	4.05E+01	1.17E+03	5.55E+01
FPA	7.21E+02	8.15E+00	9.78E+02	2.74E+01	1.11E+03	3.19E + 01
F10		F11		F12		
Algorytm AVG	GODZINY	AVG	GODZINY	AVG	GODZINY	
HGS	1,62E+03	3,00 E + 02	4.27E+03	5.46E+02	1.20E+03	1.09E-01
SCA	7.54E+03	4.61E+02	8.65E+03	4.29E+02	1.20E+03	4.10E-01
W	4,91E+03	7.59E+02	5.21E+03	8.92E+02	1.20E+03	3.93E-01
WIELKA 3.64E + 03		6.95E+02	4,45E + 03	5,73E+02	1.20E+03	1,25E+00
MFO	4.62E+03	7,61E+02	5.52E+03	6.54E+02	1.20E+03	2.38E-01
WOA	5,79E+03	7.30E+02	6.95E+03	8.14E + 02	1.20E+03	5.47E-01
GOA	5.13E+03	7.35E+02	5.36E+03	7.23E+02	1.20E+03	5.15E-01
DAJE	7.01E+03	8.11E+02	7,61E+03	6.85E+02	1.20E+03	6.23E-01
WITAJ	4,55E+03	6.54E+02	5.43E+03	7.00E + 02	1.20E+03	3.24E-01
PSO	5.46E+03	4.70E+02	6.44E+03	6.44E+02	1.20E+03	3.80E-01
Z	2.02E+03	1.71E+02	7.17E+03	3.13E+02	1.20E+03	2.05E-01
BA	5.86E + 03	8.22E+02	6.04E+03	6.73E+02	1.20E+03	3.43E-01
FPA	4,49E+03	2,32E+02	5.54E+03	3.38E+02	1.20E+03	2.09E-01
F13		F14		F15		
Algorytm AVG	GODZINY	AVG	GODZINY	AVG	GODZINY	
HGS	1.30E+03	1.46E-01	1,40E+03	3.27E-01	1,52E+03	4.76E+00
SCA	1.30E+03	3.85E-01	1.47E+03	1,58E+01	1.80E+04	1.07E+04
W	1.30E+03	1.31E-01	1,40E+03	1.89E-01	1,51E+03	3.87E+00
WIELKA 1,30E + 03		4.13E-01	1.41E+03	1.02E+01	1.92E+03	6.96E+02
MFO	1.30E+03	1.43E+00	1.43E+03	2.11E+01	1.22E+05	2.74E+05
WOA	1.30E+03	1.00E-01	1,40E+03	5.18E+00	1,76E+03	1,58E+02
GOA	1.30E+03	1.47E-01	1,40E+03	3.06E-01	1,52E+03	4.78E+00
DAJE	1.30E+03	9.87E-01	1.42E+03	1.04E+01	8.86E + 03	1.08E+04
WITAJ	1.30E+03	8.46E-02	1,40E+03	6.71E-02	1,51E+03	4.22E+00
PSO	1.30E+03	1.01E-01	1,40E+03	1.93E-01	1,52E+03	1,89E+00
Z	1.30E+03	5.45E-02	1,40E+03	7.80E-02	1,52E+03	1.30E+00
BA	1.30E+03	1.28E-01	1,40E+03	4.87E-02	1,53E+03	3,53E+00
FPA	1.30E+03	7.47E-02	1,40E+03	5.02E+00	1,58E+03	4.59E+01
F 16		F17		F18		
Algorytm AVG	GODZINY	AVG	GODZINY	AVG	GODZINY	
HGS	1,61E+03	5.62E-01	1,75E+06	1.30E+06	1.08E+04	9.18E+03
SCA	1,61E+03	2.84E-01	1.59E+07	7.68E+06	2.78E+08	1.17E+08
W	1,61E+03	7.18E-01	1.35E+06	9,67E+05	8.53E+03	7.14E + 03
WIELKA 1,61E + 03		7.40E-01	4.02E+06	4.60E+06	1,82E+07	2,64E+07
MFO	1,61E+03	5.11E-01	3.46E+06	3.36E+06	8.78E+06	4.71E+07
WOA	1,61E+03	4.15E-01	1,51E+07	9.17E+06	5.03E+05	4.83E+05

GOA	1,61E+03	4.80E-01	1,27E+06	1.11E+06	1.09E+04	2.03E+04
DAJE	1,61E+03	3.02E-01	1,37E+07	9.24E+06	1,81E + 07	3.42E+07
WITAJ	1,61E+03	5.78E-01	1.44E+06	9.30E+05	4,59E+03	2,46E+03
PSO	1,61E+03	4.09E-01	8.01E+05	5.69E+05	3.69E+06	9.03E+05
Z	1,61E+03	2.38E-01	4,99E+06	1,84E+06	2,64E+05	2.01E+05
BA	1,61E+03	2.48E-01	6.09E+05	3.60E+05	4.29E+05	1.49E+05
FPA	1,61E+03	1.97E-01	4,59E+04	3,75E+04	7,70E+03	3.84E+03
F19			F20		F21	
Algorytm AVG	GODZINY		AVG	GODZINY	AVG	GODZINY
HGS	1.93E+03	3.97E+01	3.26E + 04	1,84E+04	8.03E+05	7.29E+05
SCA	2.03E+03	3.35E+01	4.36E+04	1,75E+04	3,75E+06	2,51E+06
W	1.92E+03	1.08E+01	2,54E+04	1.29E+04	4.00 E + 05	4.31E+05
WIELKA 1,95E + 03		2.80E+01	2.88E+04	1,52E+04	1.08E+06	2.00E + 06
MFO	1.97E+03	6.66E+01	6.13E+04	4.23E+04	7.91E+05	5.50E+05
WOA	1,99E+03	4.26E + 01	1.47E+05	1.43E+05	7.03E+06	5.92E+06
GOA	1.92E+03	1,86E + 01	1.74E+04	1.48E+04	3.41E+05	2,52E+05
DAJE	1,99E+03	5.67E+01	1.50E+05	1.41E+05	4.21E+06	6.33E+06
WITAJ	1.92E+03	2,26E + 01	4.20E+04	2.13E+04	4.23E+05	3.63E+05
PSO	1.92E+03	2,49E+00	1,78E+04	8.48E+03	2.72E+05	1,84E+05
Z	1.91E+03	4.12E+00	1.21E+04	4.78E+03	8.01E+05	3.62E+05
BA	1.92E+03	1.59E+01	2,58E+04	1.35E+04	2.38E+05	1,58E+05
FPA	1.92E+03	9.13E+00	9.83E+03	4.28E+03	1.45E + 04	3.40E+03
F22			F23		F24	
Algorytm AVG	GODZINY		AVG	GODZINY	AVG	GODZINY
HGS	2,96E+03	2,40E+02	2.50E+03	0,00E + 00	2.60E+03	1.30E-03
SCA	3.27E+03	1,67E+02	2,71E+03	2,26E + 01	2,61E+03	1.90E+01
W	2,81E + 03	1.91E+02	2,63E+03	7,71E+00	2,64E+03	6.13E+00
ŚWIETNE 2,68E + 03		1.91E+02	2,64E+03	9.93E+00	2.60E+03	1.08E-02
MFO	3.01E+03	2.59E+02	2,66E+03	5.12E+01	2.68E+03	2.32E+01
WOA	3.10E+03	2,79E+02	2.68E+03	2,46E+01	2,61E+03	6.86E + 00
GOA	2.80E+03	1.88E+02	2,64E+03	1.05E+01	2,64E+03	7,77E+00
DAJE	3,37E+03	2,85E+02	2.72E+03	3,51E+01	2,67E+03	1.04E+01
WITAJ	3.03E+03	2,77E+02	2,63E+03	7.06E+00	2,66E+03	1.05E+01
PSO	2.97E+03	2.20E+02	2,62E+03	1.50E+00	2,63E+03	4.71E+00
Z	2,64E+03	1.11E+02	2,62E+03	2.91E-03	2,63E+03	2.20E+00
BA	3,45E + 03	3.22E+02	2,62E+03	1,61E+00	2,66E+03	2.41E+01
FPA	2,79E+03	1,20E+02	2,63E+03	4,54E+00	2,65E+03	2,91E+00
F25			F26		F27	
Algorytm AVG	GODZINY		AVG	GODZINY	AVG	GODZINY
HGS	2,70E+03	0,00E + 00	2,74E+03	4,94E+01	2,90E+03	0,00E + 00
SCA	2,74E+03	1.13E+01	2,70E+03	4.01E-01	3.87E+03	2.88E+02
W	2.72E+03	5.28E+00	2,70E+03	1.38E-01	3,57E+03	1,50E+02
WIELKA 2.71E + 03		5.50E+00	2,74E+03	4.93E+01	3,37E+03	1.49E+02
MFO	2.72E+03	8.26E + 00	2,70E+03	1.18E+00	3.60E+03	2.22E+02
WOA	2.72E+03	1,81E + 01	2,73E+03	6.52E+01	3.84E+03	3.69E+02
GOA	2,71E+03	3,99E+00	2,78E+03	5.52E+01	3.44E+03	2,36E+02
DAJE	2,75E+03	1.80E+01	2,74E+03	4.96E+01	3.65E+03	3.98E+02
WITAJ	2,73E+03	6.88E+00	2,73E+03	4,52E+01	3,56E+03	2.50E+02
PSO	2.72E+03	6.28E+00	2,78E+03	4.08E+01	3.46E+03	3.21E+02
Z	2.72E+03	3.45E + 00	2,70E+03	6.78E-02	3.48E+03	1.38E+02
BA	2,73E+03	1.28E+01	2,71E+03	5.60E+01	4.00E + 03	3.15E+02

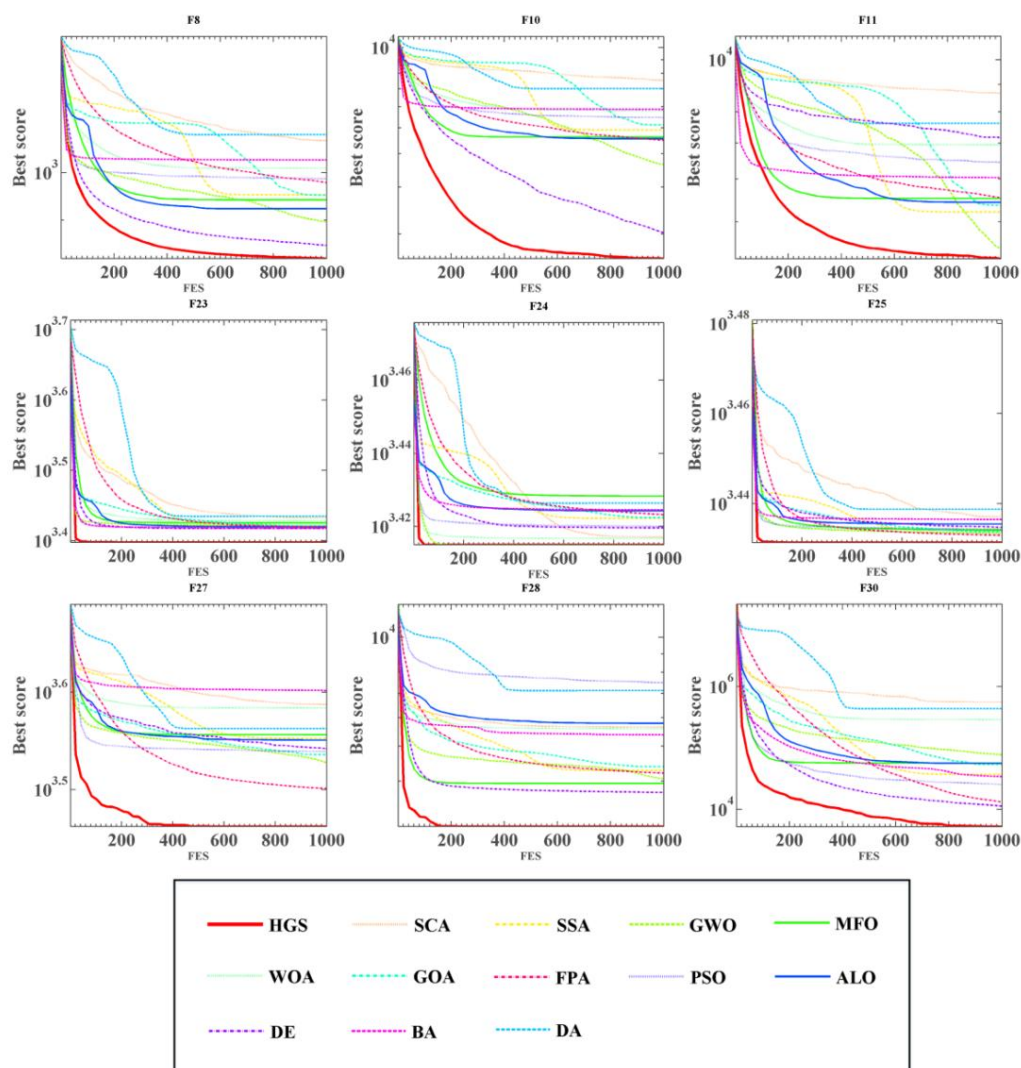
FPA	2,71E+03	2.74E+00	2,70E+03	2.46E-01	3.17E+03	5.32E+01
	F28		F29		F30	
Algorytm AVG	GODZINY		AVG	GODZINY	AVG	GODZINY
HGS	3,00 E + 03	0,00E + 00	8.55E+05	2.59E+06	5,23E+03	2,63E+03
SCA	5.65E+03	4.49E+02	3.25E+07	1,51E+07	5.59E+05	2.18E+05
W	4.28E+03	4.16E+02	4,81E + 06	7.30E+06	3.71E+04	2.10E+04
WIELKA 4.06E + 03		3,53E+02	2.05E+06	4.36E+06	7,75E+04	4.45E + 04
MFO	3,95E+03	2.04E+02	3,54E+06	4.04E+06	5.66E+04	5.40E+04
WOA	5.59E+03	6.37E+02	1.35E+07	9.72E+06	2,91E+05	2,41E+05
GOA	4.39E+03	4.04E+02	3.30E+06	1.02E+07	5.36E+04	2,94E+04
DAJE	7.12E+03	1,00 E + 03	6.70E+07	5,00E + 07	4.34E+05	2,79E+05
WITAJ	5,79E+03	5.15E+02	5.49E+07	1.11E+08	5.61E+04	1.12E+05
PSO	7,49E+03	1.03E+03	9.87E+04	2,92E+05	2,54E+04	1.87E+04
Z	3.72E+03	2.88E+01	1.07E+04	1,37E+04	1.13E+04	2.17E+03
BA	5.37E+03	7,26E + 02	7.36E+07	5.70E+07	3.41E+04	5.59E+04
FPA	4.21E+03	2,53E+02	3,56E+05	1.70E+06	1.31E+04	5.43E+03

Algorytm +/- Avg	Ranga		
HGS	~	3,73	1
SCA	29/01	11,33	12
W	16/8/6	5,00	3
WIELKA 22/4/4		6,73	8
MFO	26/0/4	8.30	10
WOA	26/2/2	9.47	11
GOA	18/6/6	5,63	5
DAJE	29/01	11.60	13
WITAJ	17/6/7	5,67	6
PSO	21/6/3	6.40	7
Z	19.08.03	4,63	2
BA	20/6/4	7,50	9
FPA	20/7/3	5,00	3

Zgodnie z analizą z rysunku 7 widzimy, że prędkość zbieżności HGS w F8, F10 i F11 jest duża, a dokładność rozwiązania jest bardzo wysoka. Niektóre algorytmy osiągają nawet lokalne optimum w połowie iteracji. F23-F25, F27, F28, F30 są funkcjami złożonymi o dużej liczbie optymów lokalnych. Co ciekawe, możemy zaobserwować, że szybkość konwergencji algorytmu HGS jest większa i szybka w tego typu problemach. Region docelowy można znaleźć w początkowym okresie iteracji, co pokazuje, że trendy eksploracyjne HGS są wpływowe i mogą skutecznie uniknąć spadku do lokalnego optimum. Te wskaźniki bardziej intuicyjnie pokazują, że HGS ma właściwe poczucie równowagi między eksploracją a eksploatacją.

Przypadki złożone mogą stanowić wyzwanie dla zdolności stosowanych metod do harmonizowania głównych faz poszukiwań. Wyniki pokazują, że HGS zapewnia doskonałe wyniki i zadowalającą wydajność. Powodem zadowalającej skuteczności HGS jest duża zdolność tej metody do harmonizowania różnorodności rozwiązań i koncentrowania się na lokalizacji rozwiązań wysokiej jakości w późniejszych fazach. Te dwa powody są oparte na L oraz parametry LH , które ważą zmianę indywidualnego zakresu wyszukiwania w procesie iteracji. HGS ma przydatną funkcję, która zapewnia skoncentrowanie etapów wyszukiwania HGS w oparciu o konkretną

wskaźnik. Ta funkcja pomaga tej metodzie w dogłębnej eksploracji przestrzeni rozwiązań, podczas gdy na początkowych etapach intensywnie bada ona przestrzeń funkcji.



Rysunek 7 Porównania między HGS a tradycyjnymi MA.

3.3.2 Porównanie z zaawansowanymi MA

Aby dodatkowo udowodnić skuteczność proponowanego HGS, porównaliśmy HGS z pewnym stanem najnowocześniejsze zaawansowane algorytmy funkcji porównawczych CEC2014.

Tabela 7 przedstawia porównanie między HGS a zaawansowanymi MA w zestawie testowym CEC2014. Jak pokazują wyniki, możemy intuicyjnie zauważyć, że HGS zajmuje pierwsze miejsce wśród dziesięciu algorytmów i pierwsze na 17 funkcjach, co stanowi 56,7% całkowitej liczby funkcji, koncentrując się na prostych funkcjach multimodalnych i funkcjach kompozycji. Od tego momentu widzimy, że HGS ma doskonałą wydajność.

Średnia wartość HGS wynosi tylko 2,37, co stanowi około połowę średniej wartości m_SCA, która zajmuje drugie miejsce. Wskazuje to, że zdolność wyszukiwania HGS jest wydajna i pozwala uniknąć popadania w lokalne optimum.

Tabela A.4 w Załączniku A wymienia wartość p HGS w porównaniu z innymi zaangażowanymi MA. Zestawy danych poniżej 0,05 w tabeli A.4 w załączniku A stanowiły 91,1% całości, co pokazuje, że HGS ma wyraźną przewagę statystyczną w porównaniu z konkurentami. W przypadku IWOA HGS ma znaczenie statystyczne we wszystkich funkcjach.

Tabela 7 Wyniki porównania funkcji CEC2014 z zaawansowanymi algorytmami

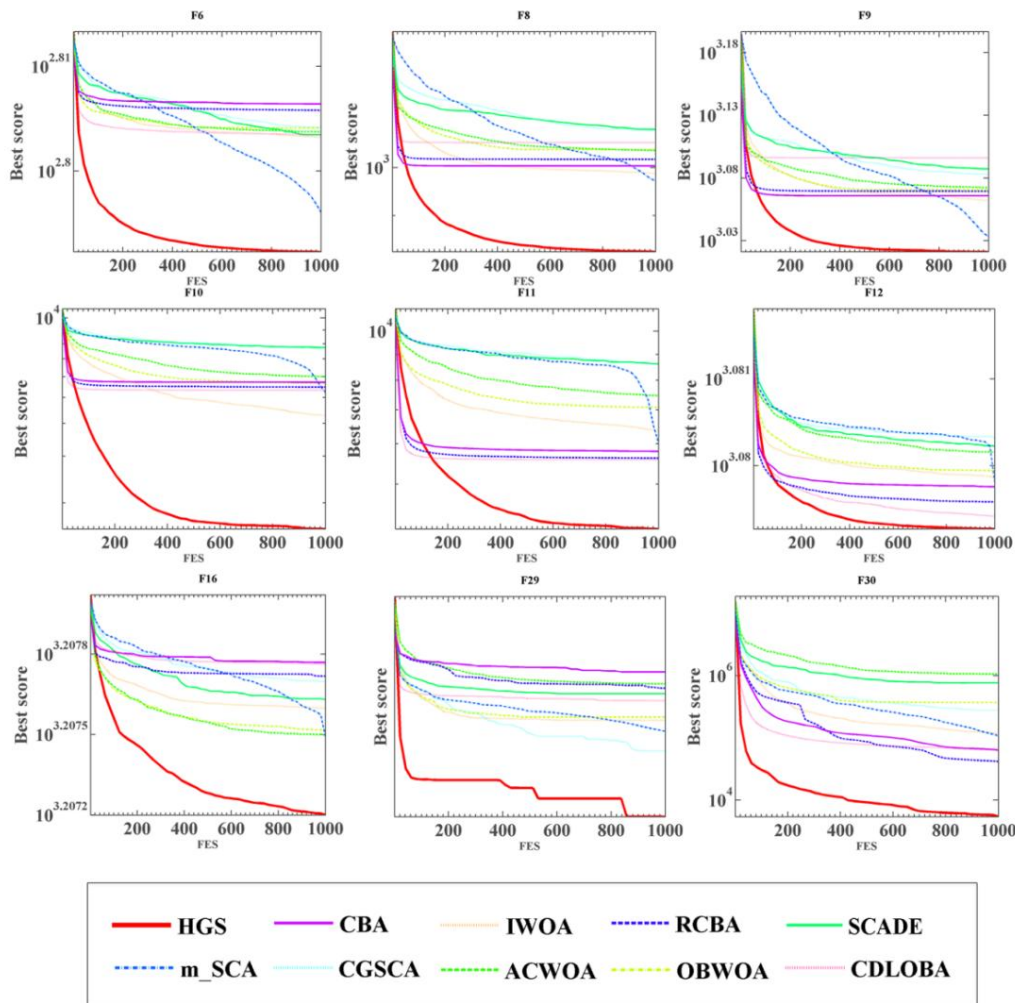
F1			F2		F3	
Algorytm	AVG	GODZINY	AVG	GODZINY	AVG	GODZINY
HGS	1.13E+07	8.82E+06	7.84E+07	4.28E+08	2.11E+04	1.95E+04
IWOA	9.18E+07	3.89E+07	1.17E+09	1.19E + 09	6.42E+04	3.26E + 04
OBWOA	2.50E+08	1,51E+08	5.05E+09	2,43E+09	6.58E+04	2.30E+04
ACWOA	2,67E+08	5.76E+07	2,06E+10	4.93E+09	6.74E+04	7.29E+03
SCADE	5.71E + 08	1.01E+08	3.90E+10	5.66E+09	6.55E+04	5.78E+03
CGSCA	4.73E+08	1.28E+08	3,00 E + 10	4.90E+09	6.11E+04	6.93E+03
m_SCA	1.25E+08	7.83E+07	1,27E+10	4.72E+09	4.16E+04	8.98E+03
RCBA	6.02E+06	2.07E+06	3.31E+05	8.07E+04	8.18E+04	2,81E + 04
CBA	1,37E+07	5.83E+06	9.63E+05	2.21E+06	1.31E+05	3.63E+04
CDLOBA	5.81E+06	4,51E+06	1,84E+04	1.10E+04	1,27E+05	3.24E+04
F4			F5		F6	
Algorytm	AVG	GODZINY	AVG	GODZINY	AVG	GODZINY
HGS	5.27E+02	3,05E+01	5.20E+02	5.99E-02	6.20E+02	2,42E+00
IWOA	7.51E+02	1.17E+02	5.21E+02	1.35E-01	6.36E+02	3.42E+00
OBWOA	1.30E+03	6.16E+02	5.21E+02	7.76E-02	6.37E+02	2,65E+00
ACWOA	2.09E+03	4.11E+02	5.21E+02	9.28E-02	6.36E+02	2,51E+00
EXP	3,67E + 03	8.98E+02	5.21E+02	4.17E-02	6.36E+02	2,70E+00
CGSCA	2,79E+03 m_SCA	6.10E+02	5.21E+02	7.53E-02	6.37E+02	2.19E + 00
9,97E+02		2.82E+02	5.21E+02	9.85E-02	6.25E+02	2.73E+00
RCBA	5.09E+02	3.82E+01	5.20E+02	1.35E-01	6.39E+02	3,58E+00
CBA	5.10E+02	3.09E+01	5.20E+02	2,53E-01	6.40E+02	3.60E+00
CDLOBA	5.04E+02	3.90E+01	5.21E+02	8.92E-02	6.36E+02	3.19E + 00
F7			F8		F9	
Algorytm	AVG	GODZINY	AVG	GODZINY	AVG	GODZINY
HGS	7.02E+02	3.95E+00	8.31E+02	1.65E+01	1.05E+03	2,66E+01
IWOA	7.06E+02	2.19E + 00	9.88E+02	3.40E+01	1.15E+03	5.24E+01
OBWOA	7.30E+02	2,46E+01	1.04E+03	3.84E+01	1.18E+03	4.62E+01
ACWOA	8.39E+02	3.89E+01	1.04E+03	3.44E+01	1.18E+03	2.82E+01
PD	9,73E + 02	4.14E + 01	1.09E+03	1.30E+01	1.22E+03	2.04E+01
CGSCA	9.67E+02	4.72E+01	1.09E+03	1,73E+01	1.21E+03	1.87E+01
m_SCA	7.88E+02	3.66E+01	9.72E+02	2.50E+01	1.08E+03	2.98E+01
RCBA	7.01E+02	1.25E-01	1,02E+03	6.47E+01	1.17E+03	5.66E+01
CBA	7.00E + 02	1.65E-01	1,00 E + 03	5.48E+01	1.16E+03	7.33E+01
CDLOBA	7.00E+02	1.21E-02	1.06E+03	5.24E+01	1,25E+03	5.52E+01
F10			F11		F12	
Algorytm	AVG	GODZINY	AVG	GODZINY	AVG	GODZINY
HGS	1.59E+03	2,57E+02	4.08E+03	5,73E+02	1.20E+03	8.38E-02
IWOA	4.27E+03	6.70E+02	6.37E+03	6,45E + 02	1.20E+03	5.27E-01
OBWOA	5.68E + 03	7,69E+02	7.08E+03	8.67E+02	1.20E+03	5.71E-01
ACWOA	6.00E+03	6.50E+02	7.47E+03	9.30E+02	1.20E+03	6.24E-01
EXP	7,73E + 03	2,71E+02	8.62E+03	3.42E+02	1.20E+03	3.17E-01
CGSCA	7.66E+03	4.46E+02	8.61E+03	4.07E+02	1.20E+03	3.28E-01
m_SCA	5.22E+03	7,60E+02	6.02E+03	5.98E+02	1.20E+03	5.33E-01
RCBA	5.48E+03	6.67E+02	5.62E+03	6,81E + 02	1.20E+03	3.96E-01
CBA	5.72E+03	8.05E+02	5.80E+03	6.13E+02	1.20E+03	7.78E-01
CDLOBA	5.34E+03	6.88E+02	5.58E+03	5.70E+02	1.20E+03	2.86E-01
F13			F14		F15	
Algorytm	AVG	GODZINY	AVG	GODZINY	AVG	GODZINY

HGS	1.30E+03	1.44E-01	1,40E+03	3.37E-01	1,51E+03	3.83E+00
IWOA	1.30E+03	1.15E-01	1,40E+03	1,83E+00	1,62E+03	8.55E+01
OBWOA 1.30E+03		6.21E-01	1.42E+03	1.10E+01	5.86E + 03	7.68E+03
ACWOA 1.30E+03		4.47E-01	1.46E+03	1.31E+01	3.63E+03	1.15E+03
PD 1,30E + 03		4.19E-01	1,51E+03	1,25E+01	3,75E+04	1.19E + 04
CGSCA 1.30E+03		4.29E-01	1.48E+03	1,53E+01	2,66E+04	1,73E+04
m_SCA 1.30E+03		9.94E-01	1.43E+03	1.23E+01	3.82E+03	3.40E+03
RCBA	1.30E+03	1.54E-01	1,40E+03	9.53E-02	1,54E+03	8.65E+00
CBA	1.30E+03	1.56E-01	1,40E+03	1.66E-01	1.57E+03	1,72E+01
CDLOBA 1.30E+03		1.25E-01	1,40E+03	1.10E-01	1,72E+03	7.39E+01
F 16			F17		F18	
Algorytm AVG		GODZINY	AVG		AVG	
HGS	1,61E+03	8.07E-01	1.96E+06	1.74E+06	1.65E+04	1.10E+04
IWOA	1,61E+03	5.60E-01	1.12E+07	8.85E+06	1,72E+05	2.73E+05
OBWOA 1.61E+03		3.90E-01	1,72E+07	1,58E+07	9.68E+06	1,84E+07
ACWOA 1,61E + 03 PD 1,61E		5.28E-01	4.77E+07	2.06E+07	2.05E+08	1.06E+08
+ 03		1.92E-01	2.41E+07	1.06E+07	3.15E+08	2.12E+08
CGSCA 1.61E+03		1.82E-01	1.44E+07	5.09E+06	3.13E+08	2.18E+08
m_SCA 1.61E+03		5.20E-01	3,59E+06	2.74E+06	4.10E+07	4.92E+07
RCBA	1,61E+03	3.65E-01	6.30E+05	3.67E+05	9.35E+03	1.23E+04
CBA	1,61E+03	5.39E-01	9.21E+05	5.88E+05	2,42E+04	4,54E+04
CDLOBA 1.61E+03		3.26E-01	2.27E+05	2.14E + 05	1,54E+04	7.00E + 03
F19			F20		F21	
Algorytm AVG		GODZINY	AVG		AVG	
HGS	1.93E+03	3.94E+01	2.80E+04	1.96E+04	6.44E+05	5.18E+05
IWOA	1.97E+03	3,81E + 01	6.33E+04	4.90E+04	3.82E+06	3,79E+06
OBWOA 2.02E+03		6.08E+01	7,78E+04	3,55E+04	6.30E+06	5.52E+06
ACWOA 2.06E+03		5.10E+01	1.01E+05	4.48E+04	1,54E+07	1,25E+07
SCADE 2.05E + 03		2,51E+01	5.07E+04	2,44E+04	4.67E+06	2.50E+06
CGSCA 2.02E+03		2,35E+01	5.90E+04	2,70E+04	4.15E+06	1.99E+06
m_SCA 1.97E+03		3.32E+01	2.20E+04	7,70E+03	6.38E+05	6.70E+05
RCBA	1.94E+03	3.64E+01	2,91E+04	1.48E+04	3.85E+05	3.23E+05
CBA	1.94E+03	3,54E+01	4,92E+04	2,75E+04	4.24E+05	3.66E+05
CDLOBA 1.98E+03		4.23E+01	4.91E+04	2,37E+04	1.59E+05	1.42E+05
F22			F23		F24	
Algorytm AVG		GODZINY	AVG		AVG	
HGS	2,93E+03	2,63E+02	2.50E+03	0,00E + 00	2.60E+03	1.18E-03
IWOA	3.09E+03	2,60E+02	2,64E+03	5.02E+01	2,62E+03	4.04E+01
OBWOA 3.17E + 03		2,91E+02	2,69E+03	2.09E+01	2.60E+03	4.12E+00
ACWOA 3.37E+03		3.34E+02	2,53E+03	7,94E+01	2.60E+03	7.79E-05
EXP 3,33E + 03 CGSCA 3,37E		1,62E+02	2.50E+03	0,00E + 00	2.60E+03	9.05E-06
+ 03		1,82E+02	2.50E+03	0,00E + 00	2.60E+03	3.13E-04
m_SCA 2.71E+03		1,78E+02	2,65E+03	1.46E+01	2.60E+03	5.70E-03
RCBA	3,52E+03	3,02E+02	2,62E+03	1,83E+00	2,69E+03	3.41E+01
CBA	3,52E+03	3.12E+02	2,62E+03	1.87E+00	2.68E+03	3.02E+01
CDLOBA 3.39E+03		2,42E+02	2,62E+03	5.52E+00	2.72E+03	4.80E+01
F25			F26		F27	
Algorytm AVG		GODZINY	AVG		AVG	
HGS	2,70E+03	0,00E + 00	2,74E+03	4,94E+01	2,90E+03	0,00E + 00
IWOA	2.72E+03	1,52E+01	2.72E+03	3.77E+01	3.84E+03	2,89E+02
OBWOA 2.71E+03		1,25E+01	2.72E+03	3.77E+01	3.46E+03	2,97E+02

ACWOA 2.70E + 03	0,00E + 00	2,76E+03	4.84E+01	3,89E+03	2.80E+02
SCADE 2,70E + 03	0,00E + 00	2,70E+03	6.94E-01	3.43E+03	3.83E+02
CGSCA 2,70E + 03	0,00E + 00	2,70E+03	4.96E-01	2,90E+03	0,00E + 00
m_SCA 2.72E+03	5.39E+00	2,70E+03	6.57E-01	3.28E+03	2,36E+02
RCBA 2,74E+03	1.64E+01	2,73E+03	4.65E+01	4.04E+03	3.85E+02
CBA 2,73E+03	1.41E+01	2,73E+03	6.76E+01	3,99E+03	4,51E+02
CDLOBA 2.73E+03	1.21E+01	2,74E+03	9.25E+01	3.87E+03	3,99E+02
F28		F29		F30	
Algorytm AVG	GODZINY	AVG	GODZINY	AVG	GODZINY
HGS 3,00 E + 03	0,00E + 00	2,86E + 05	1,53E+06	5.43E+03	2,92E+03
IWOA 5.18E+03	6.98E+02	1.08E+07	7.09E+06	1.19E + 05	1,00 E + 05
OBWOA 5.44E+03	1.21E+03	1.22E+07	8.07E+06	3.69E+05	2.17E+05
ACWOA 4.11E+03	1,51E+03	4.27E+07	3.78E+07	1.05E+06	7.13E+05
EXP 5.83E + 03	2,63E+02	2.94E+07	1.24E+07	7,63E+05	1.94E+05
CGSCA 3.00E+03	0,00E + 00	3.40E+06	7.18E+06	2,78E+05	2,61E+05
m_SCA 4.27E+03	3.10E+02	7.16E+06	9.73E+06	1.09E+05	6.47E+04
RCBA 5.70E+03	9,81E + 02	3.62E+07	5.22E+07	4.18E+04	1.01E+05
CBA 5.78E+03	9,81E + 02	6.70E+07	5.33E+07	6.34E+04	9.45E + 04
CDLOBA 5.53E+03	8.42E+02	2,26E + 07	2.60E+07	6.61E+04	1.08E+05

Algorytm +/-=	Średnia pozycja
HGS ~	2,37 1
IWOA 27/3/0	4,9 4
OBWOA 28/1/1	6.47 7
ACWOA 27/1/2	7.20 9
WYgasa 26/0/4	7,53 10
CGSCA 23/1/6	6.57 8
m_SCA 26/2/2	4,47 2
RCBA 19.08.03	4,80 3
CBA 19.05.06	5.40 6
CDLOBA 20/8/2	4,93 5

Rysunek 8 przedstawia krzywe zbieżności algorytmów. Na początku iteracji prędkość konwergencji HGS jest bardzo duża. Wraz ze wzrostem czasów iteracji prędkość konwergencji zwalnia, ale nadal jako pierwsza znajduje optymalne rozwiązanie z dużą dokładnością. F6, F8-12 i F16 pokazują, że HGS ma wyraźną przewagę nad prostymi funkcjami multimodalnymi. F29-30 pokazuje, że HGS może znaleźć lepsze rozwiązanie funkcji składu przy znacznie szybszej zbieżności niż inne odpowiedniki. W fazie wyszukiwania I i LH mogą dynamicznie rozszerzać zakres indywidualnego wyszukiwania za pomocą iteracji, aby zapewnić, że algorytm może przeszukiwać przestrzeń rozwiązań tak bardzo, jak to możliwe i szybko się zbiegać. Na etapie wydobywania, po znalezieniu możliwego rejonu optymalnego rozwiązania, można zmniejszyć zakres poszukiwań, aby osiągnąć cel wykopu i zapewnić wysoką precyzję rozwiązania. Połączenie tych dwóch faz może skutecznie zrównoważyć fazy poszukiwań i wykopalisk.



Rysunek 8 Porównania między HGS a zaawansowanymi MA.

3.4 Porównania z wariantami DE

W tym rozdziale porównano HGS z niektórymi ulepszonymi wersjami DE, w tym MPEDE (G. Wu, Mallipeddi, Suganthan, Wang i Chen, 2015), SPS_L_SHADE_EIG (Guo, Tsai, Yang i Hsu, 2015), LSHADE_cnEpSi (Awad, Ali, i Suganthan, 2017), SHADE (Tanabe i Fukunaga, 2014), SADE (Qin, Huang i Suganthan, 2009), LSHADE (Tanabe i Fukunaga, 2014), JDE (Brest, Greiner, Boskovic, Mernik i Zumer, 2006) i DE (Storn & Price, 1997) na 21 funkcjach, które zostały wybrane spośród pierwszych 13 z 23 funkcji porównawczych i ostatnich 8 funkcji złożonych funkcji CEC2014. Wszystkie funkcje można podzielić na trzy kategorie: jednomodowe (F1-F7), multimodalne (F8-F13) i złożone (F14-F21). W tym eksperymencie wielkość populacji N została ustawiona na 30, wymiar problemu optymalizacji D został przyjęty jako 30, maksymalna liczba ocen MaxFES została przyjęta jako 300000 razy, a każdy algorytm został wykonany 30 razy losowo.

Tabela 8 przedstawia porównanie HGS z ulepszoną wersją DE. Wyniki pokazują, że algorytm HGS zajmuje pierwsze miejsce wśród dziesięciu algorytmów i pierwsze wśród 15 funkcji, stanowiąc 71,4% ogólnej liczby funkcji. Od tego momentu widać, że HGS prezentuje się znakomicie

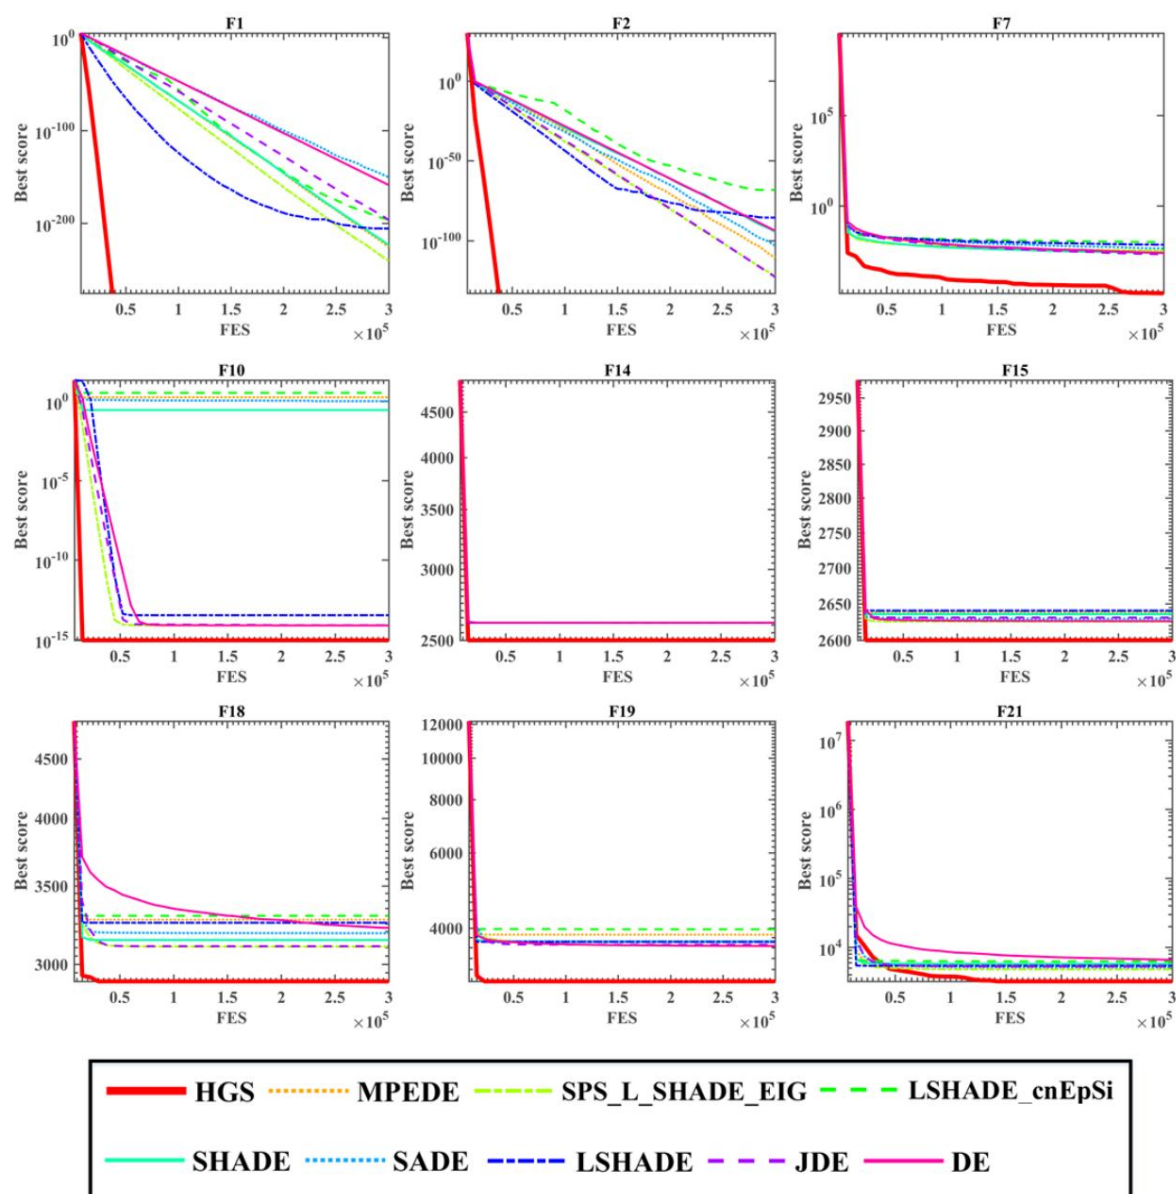
wydajność ze średnią wartością zaledwie 2,33. Wyniki te wskazują, że zdolność wyszukiwania HGS jest skuteczna i pozwala uniknąć popadania w lokalne optimum.

Tabela 8 Wyniki porównania z tradycyjnymi wariantami DE

Algorytm	F1		F2		F3	
	AVG	GODZINY	AVG	GODZINY	AVG	GODZINY
HGS	0,00E + 00	0,00E + 00	0,00E + 00	0,00E + 00	0,00E + 00	0,00E + 00
MPED	1.86E-226	0,00E + 00	1.43E-111	6.59E-111	1.08E-35	4.20E-35
SPS_L_SHADE_EIG 2.86E-241		0,00E + 00	5.81E-123	2.19E-122	1.84E-38	8.22E-38
LSHADE_cnEpSi	5.09E-197	0,00E + 00	5.56E-69	3.04E-68	2,92E-49	1,32E-48
CIEŃ	2.08E-224	0,00E + 00	4.20E-95	2.02E-94	4.83E-52	2.62E-51
SADE	3.10E-151	1.68E-150	7,73E-104	4.23E-103	4.33E-06	8.07E-06
LSHADE	1,79E-206	0,00E + 00	2.48E-86	9.48E-86	8.06E-45	2.10E-44
JDE	2,66E-197	0,00E + 00	1,78E-123	3.83E-123	2.47E-12	4.73E-12
Z	1.41E-159	2.59E-159	1,53E-94	1.68E-94	1.49E+03	8.15E+02
Algorytm	F4		F5		F6	
	AVG	GODZINY	AVG	GODZINY	AVG	GODZINY
HGS	0,00E + 00	0,00E + 00	1.11E+01	8.39E+00	6.06E-10	8.67E-10
MPED	3.48E-05	1.02E-04	9.30E-01	1.71E+00	3.60E-33	4,51E-33
SPS_L_SHADE_EIG 6.13E-09		1.17E-08	6.64E-01	1,51E+00	0,00E + 00	0,00E + 00
LSHADE_cnEpSi	3.18E-04	9.16E-04	9.30E-01	1.71E+00	1,26E-32	1,73E-32
CIEŃ	9.30E-18	3.76E-17	7.97E-01	1,62E+00	4.11E-34	1.07E-33
SADE	1.19E-05	3.28E-05	2.19E + 01	2.44E+01	1.95E-33	3.29E-33
LSHADE	1.33E-04	1.95E-04	9.30E-01	1.71E+00	2.05E-33	3,74E-33
JDE	1,78E+01	4.95E+00	5.32E-01	1.38E+00	2.05E-33	3,06E-33
Z	3.47E-14	1.46E-13	3.27E+01	2.07E+01	0,00E + 00	0,00E + 00
Algorytm	F7		F8		F9	
	AVG	GODZINY	AVG	GODZINY	AVG	GODZINY
HGS	1.44E-05	2.50E-05	-1,26E + 04	1.25E-03	0,00E + 00	0,00E + 00
MPED	2.72E-03	1.34E-03	-1,18E+04	3.62E+02	8.23E+00	5.45E + 00
SPS_L_SHADE_EIG 3.27E-03		1.56E-03	-1,25E+04	8.07E+01	3.32E-02	1.82E-01
LSHADE_cnEpSi	9.89E-03	8.74E-03	-1,28E+04	2,91E+02	3.65E-01	8.05E-01
CIEŃ	2.50E-03	1.29E-03	-1,22E+04	1,52E+02	6.63E-14	3.02E-14
SADE	4.31E-03	2.08E-03	-1,26E + 04	3,00 E + 01	1.09E+00	9.90E-01
LSHADE	6.99E-03	3.96E-03	-1,89E+03	4,55E+01	3,58E+00	1,00 E + 01
JDE	2.08E-03	8.28E-04	-1,25E+04	1.11E+02	6.63E-02	2,52E-01
Z	2.44E-03	5.34E-04	-1,25E+04	1.21E+02	6.63E-02	2,52E-01
Algorytm	F10		F11		F12	
	AVG	GODZINY	AVG	GODZINY	AVG	GODZINY
HGS	8.88E-16	0,00E + 00	0,00E + 00	0,00E + 00	2.50E-14	5.92E-14
MPED	1,76E+00	9.89E-01	1.50E-02	1.97E-02	1.94E-01	3.32E-01
SPS_L_SHADE_EIG 7.76E-15		9.01E-16	9.04E-04	2.78E-03	1,57E-32	5.57E-48
LSHADE_cnEpSi	3.37E+00	8.40E-01	1.88E-02	2.00E-02	1.31E-01	3.16E-01
CIEŃ	2.77E-01	4.73E-01	6.40E-03	1.03E-02	3.80E-02	1.07E-01
SADE	1.01E+00	8.08E-01	1.91E-02	2.80E-02	1.73E-02	7.74E-02
LSHADE	3.37E-14	3.58E-15	1.31E-02	1.91E-02	1,61E+00	2.17E+00
JDE	7.88E-15	3.43E-15	8.23E-03	1.99E-02	3.46E-03	1.89E-02
Z	7,64E-15	1.08E-15	0,00E + 00	0,00E + 00	1,57E-32	5.57E-48
Algorytm	F13		F14		F15	
	AVG	GODZINY	AVG	GODZINY	AVG	GODZINY

HGS	1.36E-12	4.00E-12	2.50E+03	0,00E + 00	2.60E+03	0,00E + 00
MPED	2.09E-01	7.85E-01	2,62E+03	1.21E-12	2,64E+03	8.00E + 00
SPS_L_SHADE_EIG 1,35E-32		5.57E-48	2,62E+03	1.48E-12	2,63E+03	1.20E+00
LSHADE_cnEpSi	1.45E + 00	3,58E+00	2,61E+03	1.28E-01	2,64E+03	5.43E+00
CIEŃ	1.80E-03	4.94E-03	2,62E+03	2.09E-12	2,64E+03	6.70E+00
SADE	3.66E-04	2.01E-03	2,62E+03	1.34E-12	2,63E+03	4,53E+00
LSHADE	2.93E-03	4.94E-03	2,62E+03	1.98E-12	2,64E+03	6.58E+00
JDE	1,55E-32	4.86E-33	2,62E+03	1,52E-12	2,63E+03	5.92E+00
Z	1.35E-32	5.57E-48	2,62E+03	1.39E-12	2,63E+03	3.09E+00
	F 16		F17		F18	
Algorytm	AVG	GODZINY	AVG	GODZINY	AVG	GODZINY
HGS	2,70E+03	0,00E + 00	2,76E+03	5,00E + 01	2,90E+03	0,00E + 00
MPED	2,71E+03	4,94E+00	2,72E+03	4,29E+01	3,27E+03	1,38E+02
SPS_L_SHADE_EIG 2.70E+03		2,56E+00	2,71E+03	3,45E + 01	3,11E+03	4,25E+01
LSHADE_cnEpSi	2,71E+03	3,34E+00	2,73E+03	4,48E+01	3,30E+03	1,19E + 02
CIEŃ	2,71E+03	2,96E+00	2,71E+03	3,44E+01	3,15E+03	7,33E+01
SADE	2,71E+03	1,80E+00	2,73E+03	4,78E+01	3,19E + 03	7,07E+01
LSHADE	2,71E+03	2,99E+00	2,71E+03	3,04E+01	3,26E + 03	9,41E+01
JDE	2,71E+03	1,94E+00	2,70E+03	1,82E+01	3,11E+03	5,81E + 01
Z	2,71E+03	8,27E-01	2,70E+03	4,72E-02	3,22E+03	7,34E+01
	F19		F20		F21	
Algorytm	AVG	GODZINY	AVG	GODZINY	AVG	GODZINY
HGS	3,00 E + 03	0,00E + 00	3.10E+03	0,00E + 00	3.20E+03	0,00E + 00
MPED	3.86E + 03	1.89E+02	5.67E+05	3.09E+06	5.52E+03	1.09E+03
SPS_L_SHADE_EIG 3.71E+03		1.11E+02	6.40E+05	2.44E+06	4.77E+03	1.07E+03
LSHADE_cnEpSi	3.97E+03	3.03E+02	1.30E+06	3.99E+06	6.23E+03	1.59E+03
CIEŃ	3.71E+03	1.18E+02	7.07E+05	2.71E+06	5.73E+03	9.44E+02
SADE	3.72E+03	4.13E+01	4.06E+03	2.21E+02	5.10E+03	5.14E + 02
LSHADE	3.71E+03	1.09E+02	3.71E+03	1.48E+02	5.38E+03	1.06E+03
JDE	3.66E+03	4,52E+01	3.67E+03	3.72E+01	5.27E+03	9.90E+02
Z	3.63E+03	2.16E+01	6.59E+03	1.01E+04	6.56E+03	1,32E+03
Algorytm	+/-/=	Średnia pozycja				
HGS	~	2,33	1			
MPED	16/3/2	6,76	8			
SPS_L_SHADE_EIG 13/5/3 16/4/1		3,05	2			
LSHADE_cnEpSi		7,10	9			
CIEŃ	17/3/1	4,57	5			
SADE	18/2/1	5,95	6			
LSHADE	17/3/1	6,00	7			
JDE	16/4/1	3,95	3			
Z	15/4/2	4,29	4			

Na podstawie analizy przedstawionej na rysunku 9 możemy zaobserwować, że współczynnik zbieżności HGS w F1, F2 i F11 jest szybki, dokładność rozwiązania jest bardzo wysoka, a optymalne rozwiązanie znajduje się na wczesnym etapie iteracji. Na podstawie wykresów zbieżności F10, F14, F15, F18 i F19 można stwierdzić, że chociaż wszystkie algorytmy mają dużą prędkość zbieżności na początkowym etapie, dokładność zbieżności nie jest tak wysoka jak HGS. W F7 i F21 HGS ma wysoką dokładność zbieżności i może znaleźć globalne optimum.



Rysunek 9 Porównania między wariantami HGS i DE.

3.5 Analiza wrażliwości parametrów

W tym rozdziale przeanalizujemy parametry zaangażowane w algorytmy: wielkość populacji (N), maksymalną liczbę iteracji ($MaxIter$), parametr (α), ponadto i próg głodu (St). Te parametry wpływają na działanie HGS. Podczas testowania ustawiliśmy N na 100 i ustawiliśmy $MaxIter$ na 1000. Parametr α ustawiliśmy na 0.01, a St na 0.08. Parametr α ustawiliśmy na 0.01, 0.05, 0.1, 0.5, 1, 5, 10, 100, 1000 i 10000. Parametr St ustawiliśmy na 0.01, 0.05, 0.1, 0.5, 1, 5, 10, 100, 1000 i 10000. Podczas testowania i odpowiednio 1000 i pozostają, my niezmienione. Każdy algorytm był testowany 30 razy. Wszystkie eksperymenty przeprowadzono na 23 cenionych funkcjach wzorcowych.

Wyniki porównania różnych wartości parametru znajdują się w Tabeli 9. Z tabeli widzimy, że ma to istotny wpływ na działanie algorytmu. W eksperymencie, kiedy był

0,08, wydajność jest najlepsza. Również maksymalna różnica między wartościami średnimi może sięgać 2,66. Średnia wartość 0,01 jest około 1,88 razy większa niż 0,08.


W tabeli 10 przedstawiono porównanie różnych wartości · Spośród czterech wartości w tym eksperymencie, zajął pierwsze miejsce, gdy miał 10000. Niemniej jednak wpływ jest mniej przesadzony niż wpływ ·

Z powyższych wyników możemy wyciągnąć następujące wnioski: wartości L i LH mają pewien wpływ na zdolność wyszukiwania i dokładność rozwiązania HGS. Równowaga między dwoma etapami eksploracji i eksploracji jest ściśle związana z tymi dwoma parametrami. Czytelnicy mogą ustawić wartości dla obu zmiennych zgodnie z określonymi warunkami.

Tabela 9 Ranking wyników z różnymi wartościami parametru									
Zabawa	=0,01 =0,02 =0,03 =0,04 =0,05 =0,06 =0,07 =0,08 =0,09 =0,1								
ARV 5,70	4,96	4,96	3,26	3,13	3,91	3,2	3,04	3,17	4,43
Pozycja 10	8	8	5	2	6	4	1	3	7

Tabela 10 Ranking wyników z różnymi wartościami parametru				
Zabawa	= 10	= 100	= 1000	= 10000
ARV 2.17		2,04	2,06	2.00
Ranga 4		2	3	1

Podczas testowania wpływu i na HGS używamy F13 w 23 funkcjach benchmarku jako przykładów testowych. Zauważ, że został ustawiony odpowiednio na 5, 10, 30, 50, 100 i 200 i został zainicjowany na 50,100, 200, 500, 1000 i 2000. Wyniki testu można zaobserwować wizualnie na rysunku 10. Wzrost i będzie poprawić dokładność rozwiązania HGS, ale po osiągnięciu pewnego poziomu efekt ten będzie minimalny. Biorąc pod uwagę długi czas, gdy wartość jest zbyt duża, a niezadowalające wyniki eksperymentalne są zbyt małe, użytkownik może ustawić ją zgodnie z rzeczywistymi potrzebami eksperymentu.



Rysunek 10 Wpływ i (pokazuje to Max_iter na powyższym wykresie)

3.6 Eksperymenty dotyczące problemów projektowania inżynierskiego

Powszechnie wiadomo, że problemy praktyczne wiążą się z wieloma ograniczeniami. W radzeniu sobie ze scenariuszami inżynierskimi istnieje jedna główna różnica w porównaniu z przypadkami globalnych wzorców i istnieje obawa, jak uwzględnić ograniczenia i ograniczenia zmiennych oraz ich wpływ na minimalizację/maksymalizację funkcji celu (Yun Liu, et al., 2020; Lv i Qiao, 2020; Ridha i in.; G. Zhu, Wang, Sun, Ge i Zhang, 2020). Dlatego dalej oceniliśmy wydajność HGS, stosując ją do problemów inżynierskich. Rozważano kilka metod radzenia sobie z ograniczeniami, w tym karę śmierci, wyżarzanie, statyczne, dynamiczne, koewolucyjne i adaptacyjne (S. Li i in., 2020). Gdy wyszukiwanie osób narusza jakiegokolwiek ograniczenia, metoda przypisuje im dużą wartość funkcji celu. W optymalizacji algorytmu heurystycznego metoda ta pomoże automatycznie wyeliminować niewykonalne rozwiązania, dzięki czemu nie jest konieczne obliczanie niewykonalności tego schematu. Najważniejszymi zaletami kary śmierci są prostota i oszczędność czasu (S. Li i in., 2020).

W tej pracy HGS został przetestowany na czterech ograniczeniach technicznych: belce spawanej, belce dwuteowej i hamulcu sprzęgła wielotarczowego.

3.6.1 Problem projektowania belek spawanych

Zadanie projektowania belek spawanych ma na celu znalezienie najniższego zużycia belek spawanych przy czterech ograniczeniach: naprężenia ścinającego (τ), naprężenia zginającego (σ), obciążenia wybowoczeniowego (δ) i ugięcia (δ) (J. Liu, Wu, Wu i

Wang, 2015). Problem dotyczy czterech zmiennych: grubości spoiny (h); długość złącza spawanego (l); szerokość belki (b); grubość belki (t). Model matematyczny wygląda następująco:

Rozważać $\mathbf{x} = [x_1, x_2, x_3, x_4] = [h, l, b, t]$

Minimalizuj ($f(\mathbf{x}) = 1.10471 Z^{21} + 0.04811 l^{11} + 3.4 (14.0 + x_4)$)

zastrzeżeniem $1(\mathbf{x}) = (\mathbf{x})^T \mathbf{A} \mathbf{x} \geq 0$

$$2(\mathbf{x}) = (\mathbf{x})^T \mathbf{B} \mathbf{x} \geq 0$$

$$3(\mathbf{x}) = (\mathbf{x})^T \mathbf{C} \mathbf{x} \geq 0$$

$$4(\mathbf{x}) = 5(\mathbf{x}^1) = \mathbf{x}^4 \geq 0$$

$$(\mathbf{x}) \geq 0$$

$$6(\mathbf{x}) = 0.125 \mathbf{x}^1 \geq 0$$

$$7(\mathbf{x}) = 1.10471 Z^{21} + 0.04811 l^{11} + 3.4 (14.0 + x_4) \geq 5.0 \geq 0$$

Zmienny zakres $0.1 \leq x_1 \leq 2, 0.1 \leq x_2 \leq 10, 0.1 \leq x_3 \leq 10, 0.1 \leq x_4 \leq 2$

gdzie $(\mathbf{x}) = \mathbf{x}^T \mathbf{A} \mathbf{x} = \frac{2}{2} + 2 \frac{1}{2} + \frac{1}{2} + \frac{1}{2} = \frac{1}{2} + \frac{1}{2} = 1$

$$= \frac{2}{2} + \frac{1}{2} = 1.5$$

$$= 2 \left\{ \frac{2}{2} + \frac{1}{2} \right\}$$

$$(\mathbf{x}) = \frac{6}{243}, (\mathbf{x}) = \frac{6}{3^4}$$

$$(\mathbf{x}) = \frac{4.013 \times 10^{-6}}{2} (1 \pm \frac{3}{2} \pm \frac{4}{4})$$

$$= 60001, = 14, = 0.25 ..$$

$$= 30 \times 10^6, 6 = 12 \times 10$$

$$= 13600, = 30000$$

W tym temacie HGS porównano z HS (Lee & Geem, 2005) i CBO (Kaveh & Mahdavi, 2014).

Wyniki w tabeli 11 pokazują, że HGS ma najlepszą wydajność i rozwiązanie. Głównym powodem jest zadowalająca skuteczność tej metody w harmonizowaniu różnorodności rozwiązań, a następnie skupieniu się na lokalizacji wysokiej jakości zbiorów zmiennych w ograniczonej przestrzeni cech.

Tabela 11 Wyniki problemu projektowania belek spawanych w porównaniu z innymi metodami

Algorytm	Optymalne wartości dla zmiennych				Koszt optymalny
	h	L	T	b	
HGS	0,2015	3,328	9,0441	0,2056	1,70012
HS (Lee i Geem, 2005)	0,2442	6,2231	8,2915	0,2433	2,3807
CBO (Kaveh i Mahdavi, 2014)	0,2434	6,2552	8,2915	0,2444	2,38411

3.6.2 Problem projektowania belek dwuteowych

Celem tego problemu jest zmniejszenie pionowego ugięcia belek dwuteowych na podstawie powiązanych parametrów, w tym długość, wysokość i dwie grubości. Model matematyczny problemu przedstawia się następująco:

Rozważać $= [1, 2, 3, 4] = [h]$

$$\text{Cel } () = \frac{5000}{\frac{(h-2)^3}{12} + \frac{3}{6} + 2\left(\frac{h-2}{2}\right)^2}$$

Z zastrzeżeniem $g() = 2b + (h-2) \geq 0$

Zmienny zakres $10 \leq h_1 \leq 50$

$$10 \leq h_2 \leq 80$$

$$0,9 \leq h_3 \leq 5$$

$$0,9 \leq h_4 \leq 5$$

Tabela 12 przedstawia porównania między HGS i ARSM (GG Wang, 2003), IARSM (GG Wang, 2003), CS (Gandomi, Yang i Alavi, 2013) oraz SOS (Cheng i Prayogo, 2014) w problemie belki dwuteowej.

Z tabeli widzimy, że HGS minimalizuje pionowe ugięcie belki dwuteowej bardziej niż pozostałe cztery algorytmy, wykazując jego doskonałą skuteczność w rozwiązaniu tego problemu inżynierskiego.

Tabela 12 Wyniki problemu projektowania belek dwuteowych w porównaniu z innymi metodami

Algorytm	Optymalne wartości dla zmiennych				Optymalny koszt
	b	h			
HGS	50	80	0,9	2,321792	0,013074
ARSM(GG Wang, 2003)	48,42	79,99	0,90	2,40	0,0157
IARSM(GG Wang, 2003)	48,4200	79,99900	0,9000	2,4000	0,1310
CS (Gandomi i in., 2013)	50	80	0,9	2,321675	0,0130747
SOS (Cheng i Prayogo, 2014)	50	80	0,9	2,32179	0,0130741

3.6.3 Hamulec sprzęgła wielotarczowego

Celem tego problemu minimalizacji, sklasyfikowanego jako problem optymalizacji dyskretnej, jest wykorzystanie pięciu dyskretnych zmiennych projektowych w celu zminimalizowania jakości hamulców ze sprzęgłem wielotarczowym. Pięć zmiennych to

siła uruchamiająca, promień wewnętrzny i zewnętrzny, liczba 27 powierzchni ciernych, grubość tarcz. Model matematyczny tego problemu wygląda następująco:

$$f(x) = \pi(z_0^2 + x^2) + 1) \rho$$

zastrzeżeniem:

$$g_1(x) = z_0^2 + x^2 - 0$$

$$g_2(x) = (z_0 + 1)(x + 1) - 0$$

$$g_3(x) = z_0^2 - 0$$

$$g_4(x) = z_0^2 - 0$$

$$g_5(x) = z_0^2 - 0$$

$$g_6(x) = z_0^2 - 0$$

$$g_7(x) = h_0^2 - 0$$

$$g_8(x) = 0$$

$$h_0 = \frac{2}{3} \cdot \frac{z_0^3 - 2}{z_0^2 - 3} = \frac{2}{(z_0^2 - 2)} = \frac{2}{90(z_0^2 - 2)} = \frac{2}{30(h + 1)}$$

$$z_0 = 20 \quad z_0^2 = 55 \quad z_0^3 = 1 \quad z_0^4 = 1000 \quad z_0^5 = 15 = 0,5 \quad z_0^6 = 1,5 =$$

$$40 \quad z_0^7 = 3 \quad z_0^8 = 250 \quad z_0^9 = 10 \quad z_0^{10} = 30 \quad z_0^{11} = 60 \quad z_0^{12} = 80$$

$$z_0^{13} = 90 \quad z_0^{14} = 110 \quad z_0^{15} = 1,5 \quad z_0^{16} = 3 \quad z_0^{17} = 600 \quad z_0^{18} = 1000 \quad z_0^{19} = 2 \quad z_0^{20} = 9$$

Aby zminimalizować jakość hamulców ze sprzęgłem wielotarczowym, HGS porównano z WCA (Eskandar, Sadollah, Bahreininejad i Hamdi, 2012), PVS (Rao, Savsani i Vakharia, 2011) oraz TLBO (Savsani & Savsani, 2016). Szczegóły wyników porównania można znaleźć w Tabeli 13. Z tabeli widać, że jakość HGS jest prawie równa lub lepsza od innych algorytmów, co pokazuje, że HGS ma lepsze istotna zdolność optymalizacji i może znaleźć więcej rozwiązań wysokiej jakości.

Tabela 13 Wyniki działania hamulca sprzęgła wielotarczowego w porównaniu z innymi metodami

Algorytm	Koszt optymalny					
HGS	70	90	1	1000	3	0,313657
WCA (Eskandar i in., 2012)	70	90	1	910	3	0,313656
PVS (Rao i in., 2011)	70	90	1	980	3	0,31366
TLBO (Savsani i Savsani, 2016)	70	90	1	810	3	0,313656

4 Wnioski i perspektywy na przyszłość

Niniejsze badanie przedstawia nowatorski model populacyjny do rozwiązywania problemów optymalizacji w oparciu o cechy zwierząt społecznych w poszukiwaniu pożywienia. Dokładniej, w każdej iteracji algorytm szuka wokół optymalnej lokalizacji w ten sam sposób, w jaki zwierzęta żerują, gdzie waga lub głód są wartościami,

naśladować wpływ głodu na indywidualną aktywność zwierzęcia. Analizę jakościową algorytmu przeprowadzono za pomocą czterech wskaźników, w tym historii wyszukiwania, trajektorii pierwszego wymiaru, średniej dopasowania i krzywej zbieżności. Proponowane wyszukiwanie gier głodowych (Hunger Games Search, HGS) zostało zweryfikowane na podstawie obszernego zbioru 23 funkcji porównawczych i funkcji IEEE CEC2014. Do oceny istotności statystycznej między HGS a innymi dobrze znanymi MA zastosowano test rang Wilcozona i test Freidmana. Wyniki eksperymentalne pokazują, że HGS ma wydajną zdolność wyszukiwania w porównaniu z innymi algorytmami i może szybko znaleźć i opracować docelową przestrzeń rozwiązań. Ogólnie rzecz biorąc, HGS jest bardzo dobry w równoważeniu eksploracji i eksploatacji. Jednocześnie, aby potwierdzić przydatność HGS do praktycznych problemów, rozważono cztery problemy inżynierskie, w tym belkę spawaną, belkę dwuteową i hamulec sprzęgła wielotarczowego. Na podstawie wyników eksperymentalnych HGS może zaspokoić efekt optymalizacji problemów inżynierii produkcji i znacznie obniżyć koszty produkcji.

W tym artykule zastosowaliśmy najprostsze zasady tworzenia HGS, aby ułatwić rozbudowę i integrację z istniejącymi metodami sztucznej inteligencji. Istnieje wiele okien dla przyszłych kierunków tego nowego wydajnego algorytmu HGS. Po pierwsze, naukowcy mogą zbadać skuteczność tego kodu HGS o otwartym kodzie źródłowym w rozwiązywaniu rzeczywistych problemów związanych z optymalizacją parametrów modeli uczenia maszynowego, binarnym wyborem funkcji i segmentacją obrazu. Kolejnym oknem jest jak zwiększyć wydajność podstawowej wersji zaproponowanej w tych badaniach. Możliwe szanse i przyszłe propozycje to zastosowanie uczenia opartego na opozycji (OBL), uczenia się ortogonalnego (OL), chaotycznych sygnałów zamiast zmiennych losowych, zastosowanie ewolucyjnej dynamiki populacji (EPD), zalety mutacji i krzyżowania w eksploracji i eksploatacji rdzeni metoda, strategie oparte na mutacjach zespołowych, rola unoszenia opłat, zastosowanie poszukiwań zachłannych, metody koewolucyjne, obliczenia kwantowe, obliczenia równoległe, schematy oparte na rankingach, schematy losowych rezerw, struktury wielopopulacyjne, operacje wymiarowe i ich różny połączenie⁸. Wreszcie, proponowana funkcja Hunger Games Search jest podejściem jedno-celowym w aktualnie wydanej wersji, a kolejnym zadaniem może być opracowanie binarnych, wielo- i wielo-obiektywnych wariantów opracowanej wyszukiwarki Hunger Games Search, aby radzić sobie z większą różnorodnością wielozadaniowych, binarnych i wielo-obiektywnych problemów.

Podziękowanie

Badania te są wspierane przez Chińską Narodową Fundację Nauk Przyrodniczych (62076185, U1809209). Dziękujemy za uwagi anonimowych recenzentów i szanowanego redaktora, które podniosły jakość tych badań. Dziękujemy również Seyedal Mirjalili za przejrzanie i edycję pierwszej wersji rękopisu.

załącznik A

Tabele A.1-A.4 Opis odpowiednich wartości p czterech eksperymentów

Tabela A.1 Wartość p testu Wilcozona uzyskana z porównania z tradycyjnymi algorytmami na 23 benchmarku

⁸ Literatura i wskazówki dotyczące większości tych mechanizmów są publicznie dostępne pod [adresem https://aliasgharheidari.com/Publications.html](https://aliasgharheidari.com/Publications.html) oraz https://www.researchgate.net/profile/Ali_Asgar_Heidari

Funkcje

Funkcja SCA		W	WIELKA MFO WOA GOA DA				WITAJ	
F1	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F2	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F3	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F4	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F5	1.73E-06	1.92E-06	1.73E-06	1.92E-06	1.73E-06	1.73E-06	1.73E-06	2.88E-06
F6	1.73E-06	1.92E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	8.47E-06
F7	1.73E-06	1.73E-06	1.36E-04	1.73E-06	3.32E-04	1.73E-06	1.73E-06	1.73E-06
F8	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F9	1.73E-06	1.73E-06	3.91E-03	1.73E-06	1,00E+00	1,73E-06	1.73E-06	1.73E-06
F10	1.73E-06	1.73E-06	5.98E-07	1.73E-06	2.30E-05	1.73E-06	1.73E-06	1.73E-06
F11	1.73E-06	1.73E-06	6.25E-02	1.73E-06	1,00E+00	1,73E-06	1.73E-06	1.73E-06
F12	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F13	1.73E-06	3.61E-03	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F14	2.77E-03	7.27E-01	7.71E-04	6.65E-02	1.20E-03	1.07E-01	2.06E-02	3.72E-02
F15	1.32E-02	2.30E-02	7,66E-01	6.42E-03	9.92E-01	5.71E-04	2.60E-05	2.70E-02
F 16	1.73E-06	5.05E-06	1,73E-06	1,00E+00	1,73E-06	2.55E-06	1.96E-04	2,52E-06
F17	1.73E-06	1.22E-04	1,73E-06	1,00E+00	1,73E-06	1.71E-06	5.96E-05	5.76E-05
F18	1.73E-06	1.70E-06	1.73E-06	3.11E-01	1.73E-06	1.73E-06	3.15E-06	1.73E-06
F19	1.73E-06	1.80E-06	1,73E-06	1,00E+00	1,73E-06	1.73E-06	1.73E-06	1.35E-06
F20	1.73E-06	2.56E-02	1.31E-01	4.80E-03	2.45E-01	1.99E-01	2,54E-01	3.71E-01
F21	1.73E-06	1.02E-05	3.11E-05	4.88E-04	1.97E-05	1.13E-05	1.73E-06	1.02E-05
F22	1.73E-06	1.36E-05	1.73E-06	3.91E-03	1.73E-06	1.73E-06	1.73E-06	5.22E-06
F23	1.73E-06	1.73E-06	1.73E-06	3.91E-03	1.73E-06	1.73E-06	1.73E-06	1.73E-06

Tabela A.1 (ciąg dalszy) Wartość p testu Wilcoxona uzyskana z porównania z tradycyjnymi algorytmami na 23 funkcje wzorcowe

Funkcja MVO		BBO	PSO	Z	FA	BA	FPA
F1	1.73E-06	1.69E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F2	1.73E-06	1.56E-02	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F3	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F4	1.73E-06	1.72E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F5	1.73E-06	1.92E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F6	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F7	1.73E-06	3.33E-02	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F8	1.73E-06	1.73E-06	1.73E-06	3.88E-06	1.73E-06	1.73E-06	1.73E-06
F9	1.73E-06	1,00 E + 00	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F10	1.73E-06	1,52E-04	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F11	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F12	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F13	1.73E-06	1.92E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F14	2.77E-03	9.97E-04	2.77E-03	9.38E-02	2.77E-03	7.71E-04	2.77E-03
F15	4.39E-03	1.72E-06	4.73E-06	8.13E-01	5.58E-01	7.69E-06	2.26E-03
F 16	1.73E-06	4.32E-08	1.73E-06	1,00 E + 00	1.73E-06	1.73E-06	1.73E-06
F17	1.73E-06	4.32E-08	1.73E-06	1,00 E + 00	1.73E-06	1.73E-06	3.13E-02
F18	1.73E-06	5.80E-07	1.73E-06	2.91E-03	1.73E-06	1.73E-06	1.73E-06
F19	1.73E-06	4.32E-08	1.73E-06	1,00 E + 00	1.73E-06	1.73E-06	1.73E-06
F20	6.73E-01	9.51E-07	1.73E-06	2.48E-04	7.81E-01	1.73E-06	8.73E-03
F21	1.73E-06	7.36E-06	1.73E-06	3.22E-02	1.73E-06	1.73E-06	3.11E-05
F22	1.73E-06	6.03E-07	1.73E-06	1.95E-02	3.11E-05	1.73E-06	1.73E-06

F23	1.73E-06	3.34E-07	1.73E-06	1,00 E + 00	1.73E-06	1.73E-06	1.73E-06
-----	----------	----------	----------	-------------	----------	----------	----------

Tabela A.2 Wartość p testu Wilcoxona uzyskana z porównania z zaawansowanymi algorytmami na 23 benchmarku

Funkcje

Zabawa	IWOA	OBWOA	ACWOA	SCADE	CGSCA	m_SCA	RCBA	CBA	CDLOBA
F1	1.73E-06	1,00 E + 00	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F2	1.73E-06	3.96E-01	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F3	1.73E-06	1.73E-06	3.39E-01	8.29E-01	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F4	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F5	1.73E-06	1.73E-06	1.73E-06	5.79E-05	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F6	1.73E-06	1.73E-06	1.73E-06	1.49E-05	1.73E-06	1.73E-06	1.73E-06	5.45E-02	1.73E-06
F7	2.58E-03	5.19E-02	1.71E-03	6.44E-01	7.19E-01	1.31E-01	1.73E-06	1.73E-06	1.73E-06
F8	1.13E-05	1.80E-05	2.45E-01	2.83E-04	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F9	1,00 E + 00	1,00 E + 00	1,00 E + 00	1,00 E + 00	1,00 E + 00	1,00 E + 00	1.73E-06	1.73E-06	1.73E-06
F10	3.81E-05	2.44E-04	1.22E-04	1,00 E + 00	1,00 E + 00	1.51E-06	1.73E-06	1.73E-06	1.73E-06
F11	5.00E-01	1,00 E + 00	1,00 E + 00	1,00 E + 00	1,00 E + 00	1,00 E + 00	1.73E-06	1.73E-06	1.73E-06
F12	1.73E-06	1.73E-06	1.73E-06	1.92E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F13	1.24E-05	1.73E-06	2.84E-05	3.72E-05	1.73E-06	1.73E-06	2.16E-05	1.73E-06	1.73E-06
F14	2.22E-04	1.60E-04	2.61E-04	3.59E-04	3.59E-04	3.59E-04	1.97E-05	2.41E-04	3.59E-04
F15	6.58E-01	3.93E-01	1.24E-05	7.69E-06	4.72E-02	2.70E-02	1.59E-03	2.37E-05	3.52E-06
F 16	2.56E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F17	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F18	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F19	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F20	1.16E-01	2.71E-01	5.32E-03	3.59E-04	1.73E-06	2.11E-03	2.06E-01	1.92E-01	1.73E-06
F21	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F22	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F23	6.89E-05	3.59E-04	3.59E-04	3.59E-04	1.73E-06	2.83E-04	1.15E-04	8.47E-06	7.69E-06

Tabela A.3 Wartość P testu Wilcoxona uzyskana z HGS w porównaniu z innymi tradycyjnymi algorytmami IEEE CEC2014

Funkcje

Funkcjonować	SCA	W	ŚWIETNIE	MFO	WOA	GOA
F1	1.73E-06	4.45E-05	1.73E-06	1.92E-06	1.73E-06	2.13E-06
F2	1.73E-06	3.41E-05	1.73E-06	1.73E-06	1.73E-06	2.22E-04
F3	3.88E-06	1.73E-06	1.80E-05	1.73E-06	1.92E-06	1.73E-06
F4	1.73E-06	2.85E-02	1.92E-06	2.13E-06	1.73E-06	5.17E-01
F5	1.73E-06	1.71E-01	1.73E-06	2.22E-04	1.73E-06	1.31E-01
F6	1.73E-06	3,52E-06	1.96E-03	1.60E-04	1.73E-06	1.85E-02
F7	1.73E-06	1.73E-06	2.60E-06	1.92E-06	1.92E-06	1.85E-02
F8	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F9	1.73E-06	5.17E-01	8.19E-05	1.36E-04	1.92E-06	2.43E-02
F10	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F11	1.73E-06	3.41E-05	1.47E-01	3.88E-06	1.73E-06	1.49E-05
F12	1.73E-06	5.75E-06	4.73E-06	3.72E-05	1.73E-06	2.35E-06
F13	1.73E-06	3.38E-03	2.77E-03	4.45E-05	2.60E-05	1.20E-03
F14	1.73E-06	1.02E-05	1.40E-02	3.52E-06	3.71E-01	1.24E-05
F15	1.73E-06	3.16E-02	2.35E-06	1.92E-06	1.73E-06	7.52E-02
F 16	1.73E-06	1.06E-04	2.70E-02	2.35E-06	1.73E-06	6.98E-06

F17	1.73E-06	1.59E-01	4.39E-03	6.04E-03	1.73E-06	1.65E-01
F18	1.73E-06	1.92E-01	6.34E-06	2.29E-01	1.73E-06	1.78E-01
F19	1.92E-06	3.71E-01	3.00E-02	2.85E-02	2.60E-05	3.39E-01
F20	3.68E-02	6.87E-02	4.53E-01	8.94E-04	2.88E-06	2.96E-03
F21	4.73E-06	1.04E-02	4.78E-01	6.73E-01	5.22E-06	8.94E-04
F22	4.29E-06	1.40E-02	1.49E-05	4.65E-01	5.71E-02	9.84E-03
F23	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F24	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F25	1.73E-06	1.73E-06	1.73E-06	1.73E-06	2.93E-04	1.73E-06
F26	2.06E-01	2.13E-06	8.45E-01	1.71E-01	1.11E-02	2.05E-04
F27	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F28	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F29	1.73E-06	1.25E-04	3.06E-04	3.32E-04	1.73E-06	2.58E-03
F30	1.73E-06	1.73E-06	1.73E-06	2.35E-06	1.73E-06	1.73E-06

Tabela A.3 (ciąg dalszy) Wartość p testu Wilcoxona uzyskana z HGS w porównaniu z innymi tradycyjnymi algorytmami

Funkcje IEEE CEC2014

Funkcja TAK		WITAJ	PSO	Z	BA	FPA
F1	1.73E-06	1.40E-02	2.61E-04	1.73E-06	8.29E-01	3.39E-01
F2	1.73E-06	4.45E-05	1.73E-06	2.60E-06	6.32E-05	1.73E-06
F3	1.73E-06	1.92E-06	3.11E-05	5.75E-06	1.73E-06	1.60E-04
F4	1.73E-06	2.18E-02	1.04E-03	9.84E-03	1.11E-01	1.73E-06
F5	1.73E-06	1.06E-01	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F6	1.73E-06	1.24E-05	3.18E-06	1.73E-06	1.73E-06	1.73E-06
F7	1.73E-06	1.73E-06	2.96E-03	1.73E-06	1.75E-02	1.73E-06
F8	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F9	1.73E-06	4.53E-01	1.73E-06	9.63E-04	1.92E-06	3.18E-06
F10	1.73E-06	1.73E-06	1.73E-06	1.02E-05	1.73E-06	1.73E-06
F11	1.73E-06	8.47E-06	1.92E-06	1.73E-06	2.35E-06	1.73E-06
F12	1.73E-06	2.60E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F13	4.20E-04	2.35E-06	1.64E-05	3,52E-06	3.41E-05	1.92E-06
F14	1.92E-06	2.35E-06	5.22E-06	7.69E-06	3.88E-06	8.73E-03
F15	1.73E-06	4.05E-01	4.20E-04	2.85E-02	3.18E-06	1.73E-06
F 16	1.73E-06	2.37E-05	1.73E-06	2.88E-06	1.73E-06	1.73E-06
F17	2.60E-06	2.71E-01	1.59E-03	4.29E-06	8.19E-05	1.73E-06
F18	1.73E-06	6.16E-04	1.73E-06	1.73E-06	1.73E-06	2.62E-01
F19	5.79E-05	1.71E-01	3.71E-01	1.20E-01	2.71E-01	3.71E-01
F20	4.29E-06	4.49E-02	1.38E-03	1.64E-05	5.71E-02	4.29E-06
F21	1.60E-04	1.66E-02	1.48E-04	3.09E-01	3.72E-05	1.73E-06
F22	5.31E-05	3.82E-01	9.75E-01	3.41E-05	1.97E-05	2.77E-03
F23	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F24	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F25	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F26	2.13E-01	1.92E-01	3.11E-05	1.92E-06	4.45E-05	8.47E-06
F27	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F28	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06
F29	1.73E-06	7.43E-05	8.45E-01	5.04E-01	2.88E-06	2.26E-03
F30	1.73E-06	1.73E-06	7.69E-06	3,52E-06	1.73E-06	2.13E-06

Tabela A.4 Wartość P testu Wilcoxon z uzyskana z porównania z zaawansowanymi algorytmami IEEE CEC2014

Funkcje

	Zabawa	IWOA	OBWOA	ACWOA	SCADE	CGSCA	m_SCA	RCBA	CBA	CDLOBA
F1	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.29E-03	5.19E-02	2.58E-03
F2	2.37E-05	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.48E-02	4.53E-01	2.07E-02
F3	5.22E-06	2.88E-06	2.35E-06	3.18E-06	2.88E-06	1.60E-04	2.13E-06	1.73E-06	1.73E-06	1.92E-06
F4	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	3.16E-02	3.16E-02	1.75E-02	
F5	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.92E-06	1.59E-03	1.73E-06	
F6	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.92E-06	1.73E-06	1.73E-06	1.73E-06	
F7	2.11E-03	2.13E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	6.58E-01	8.47E-06	1.73E-06	
F8	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	
F9	1.92E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	3.88E-04	1.73E-06	2.88E-06	1.73E-06	
F10	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	
F11	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	2.35E-06	3.18E-06	1.73E-06	2.60E-06	
F12	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	5.75E-06	
F13	1.80E-05	2.29E-01	1.73E-06	1.73E-06	1.73E-06	2.84E-05	3.06E-04	5.31E-05	8.47E-06	
F14	1.38E-03	7.69E-06	1.73E-06	1.73E-06	1.73E-06	1.92E-06	2.88E-06	4.29E-06	1.02E-05	
F15	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	
F16	3.52E-06	7.69E-06	1.36E-05	1.73E-06	1.73E-06	1.24E-05	1.73E-06	1.73E-06	1.73E-06	
F17	1.36E-05	4.73E-06	1.73E-06	1.73E-06	1.73E-06	1.57E-02	1.15E-04	6.64E-04	3.18E-06	
F18	4.29E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	1.73E-06	2.11E-03	4.17E-01	6.29E-01	
F19	8.94E-04	1.64E-05	2.88E-06	1.73E-06	2.35E-06	8.19E-05	3.00E-02	1.99E-01	1.59E-03	
F20	8.94E-04	4.29E-06	4.29E-06	5.29E-04	6.89E-05	1.92E-01	6.14E-01	1.83E-03	4.90E-04	
F21	7.69E-06	3.52E-06	1.73E-06	1.73E-06	1.92E-06	6.14E-01	4.28E-02	7.86E-02	8.19E-05	
F22	3.50E-02	4.11E-03	5.75E-06	5.22E-06	6.34E-06	3.61E-03	2.35E-06	8.47E-06	1.49E-05	
F23	5.61E-06	1.73E-06	2.50E-01	1,00 E + 00	1,00 E + 00	1.73E-06	1.73E-06	1.73E-06	1.73E-06	
F24	1.73E-06	2.85E-06	4.07E-02	6.96E-01	2.46E-03	1.73E-06	1.73E-06	1.73E-06	1.73E-06	
F25	1.96E-04	3.13E-02	1,00 E + 00	1,00 E + 00	1,00 E + 00	3.79E-06	1.73E-06	1.73E-06	1.73E-06	
F26	1.91E-04	1.22E-03	7.88E-03	2.06E-01	2.06E-01	3.16E-02	1.06E-01	5.45E-02	8.22E-02	
F27	1.73E-06	1.73E-06	1.73E-06	4.01E-05	1,00 E + 00	1.73E-06	1.73E-06	1.73E-06	1.73E-06	
F28	2.56E-06	8.30E-06	2.44E-04	1.73E-06	1,00 E + 00	1.73E-06	1.73E-06	1.73E-06	1.73E-06	
F29	3.51E-06	2.88E-06	1.11E-05	1.73E-06	3.96E-01	1.92E-06	1.73E-06	1.73E-06	3.88E-06	
F30	1.73E-06	1.73E-06	1.92E-06	1.73E-06	1.83E-04	1.73E-06	1.92E-06	1.92E-06	1.73E-06	

Bibliografia

Abd Elaziz, M., Heidari, AA, Fujita, H. i Moayedi, H. (2020). Konkurencyjny Harris Hawks oparty na łańcuchu
Optymalizator do globalnej optymalizacji i wielopoziomowych problemów z progowaniem obrazu. Zastosowany miękki
Przetwarzanie danych 106347.

Adarsh, BR, Raghunathan, T., Jayabarathi, T. i Yang, X.-S. (2016). Wysyłka ekonomiczna za pomocą chaotycznych
algorytm (t. 96).

Awad, NH, Ali, MZ i Suganthan, PN (2017). Zbiorcza sinusoidalna różniczkowa macierz kowariancji
adaptacja z sąsiedztwem euklidesowym do rozwiązywania problemów porównawczych CEC2017. w 2017
Kongres Obliczeń Ewolucyjnych (CEC) (s. 372-379).

Betley, JN, Xu, S., Cao, ZFH, Gong, R., Magnus, CJ, Yu, Y. i Sternson, SM (2015). Neurony na głód

- i pragnienie przekazują sygnał uczący o ujemnej wartościowości. *Natura*, 521, 180-185.
- Brest J., Greiner S., Boskovic B., Mernik M. i Zumer V. (2006). Samodostosowujące się parametry sterowania w ewolucja różniczkowa: studium porównawcze nad numerycznymi problemami wzorcowymi. *Transakcje IEEE o obliczeniach ewolucyjnych*, 10, 646-657.
- Burnett, CJ, Li, C., Webber, E., Tsaousidou, E., Xue, Stephen Y., Brüning, Jens C., & Krashes, Michael J. (2016). Motywacyjna Państwowa Konkurencja Głodowa. *Neuron*, 92, 187-201.
- Cai, C., Gao, X., Teng, Q., Kiran, R., Liu, J., Wei, Q. i Shi, Y. (2020). Prasowanie izostatyczne na gorąco stopu zbliżonego do α -Ti: Optymalizacja temperatury, ewolucja mikrostruktury i ocena wydajności mechanicznej. *Nauka o materiałach i inżynieria: A*, 140426.
- Cai, C., Wu, X., Liu, W., Zhu, W., Chen, H., Qiu, JCD, Sun, C.-N., Liu, J., Wei, Q. i Shi, W. (2020). Selektowne topienie laserowe stopu tytanu Ti-6Al-2Zr-1Mo-1V bliskiego α : Optymalizacja parametrów, obróbka cieplna i parametry mechaniczne. *Dziennik Inżynieria materiałowa & Technologia*.
- Cannon, WB i Washburn, A. (1912). Wyjaśnienie głodu. *American Journal of Fizjologia-Dziedzictwo Treść*, 29, 441-454.
- Cao, B., Dong, W., Lv, Z., Gu, Y., Singh, S. i Kumar, P. (2020). Hybrydowa wielkość wieloobiektywnej mikrośiatki Optymalizacja z rozmytą decyzją. *Transakcje IEEE w systemach rozmytych*.
- Cao, B., Fan, S., Zhao, J., Yang, P., Muhammad, K. i Tanveer, M. (2020). Wielocelowy ulepszony kwantowo optymalizacja na dużą skalę poprzez równoległość. *Obliczenia roju i ewolucji*, 57, 100697.
- Cao, B., Wang, X., Zhang, W., Song, H. i Lv, Z. (2020). Wieloobiektywny model optymalizacji przemysłu Internet rzeczy oparty na prywatnym blockchainie. *Sieć IEEE*, 34, 78-83.
- Cao, B., Zhao, J., Gu, Y., Fan, S. i Yang, P. (2019). Świadoma bezpieczeństwa przemysłowa sieć czujników bezprzewodowych optymalizacja wdrażania. *Transakcje IEEE dotyczące informatyki przemysłowej*, 16, 5309-5316.
- Cao, B., Zhao, J., Gu, Y., Ling, Y. i Ma, X. (2020). Stosowanie grupowania różniczkowego opartego na wykresie dla wielocelowa optymalizacja na dużą skalę. *Obliczenia roju i ewolucyjne*, 53, 100626.
- Cao, B., Zhao, J., Yang, P., Gu, Y., Muhammad, K., Rodrigues, JJ i de Albuquerque, HCV (2019). Wielozakładowa optymalizacja topologii 3D w bezprzewodowej sieci centrów danych nowej generacji. *Transakcje IEEE dotyczące informatyki przemysłowej*, 16, 3597-3605.
- Chen, H., Chen, A., Xu, L., Xie, H., Qiao, H., Lin, Q. i Cai, K. (2020). Architektura CNN z głębokim uczeniem zastosowana w inteligentnej analizie zanieczyszczenia wody w bliskiej podczerwieni dla rolniczych zasobów irygacyjnych. *Gospodarka wodna w rolnictwie*, 240, 106303.
- Chen, H., Fan, DL, Fang, L., Huang, W., Huang, J., Cao, C., Yang, L., He, Y., & Zeng, L. (2020). Algorytm optymalizacji roju cząstek z operatorem mutacji do redukcji szumów filtra cząstek w diagnostyce uszkodzeń mechanicznych. *Międzynarodowy Dziennik Rozpoznawanie wzorców i sztuczna inteligencja*, 2058012.
- Chen, H., Heidari, AA, Chen, H., Wang, M., Pan, Z. i Gandomi, AH (2020). Zróżnicowanie wielopopulacyjne wspomagana ewolucją optymalizacja Harris hawks: ramy i studia przypadków. *Przyszłe pokolenie Systemy komputerowe*, 111, 175-198.
- Chen, H., Heidari, AA, Zhao, X., Zhang, L. i Chen, H. (2020). Zaawansowany system multi oparty na uczeniu ortogonalnym optymalizacja cosinusów roju: ramy i studia przypadków. *Systemy eksperckie z aplikacjami*, 144, 113113.
- Chen, H., Li, S., Heidari, AA, Wang, P., Li, J., Yang, Y., Wang, M. i Huang, C. (2020). Wydajne multi Optymalizatory oparte na muszkach owocowych w placówkach populacyjnych: Struktura i postępy w maszynach wektorów pomocniczych. *Systemy eksperckie z aplikacjami*, 142.
- Chen, H., Wang, M. i Zhao, X. (2020). Wielostrategowy ulepszony algorytm sinus cosinus dla global optymalizacja i ograniczone praktyczne problemy inżynierskie. *Matematyka stosowana i*

- Obliczenie, 369 , 124872 (<https://doi.org/10.121016/j.amc.122019.124872>).
- Chen, H., Xu, Y., Wang, M. i Zhao, X. (2019). Zrównoważony algorytm optymalizacji wielorybów dla ograniczeń inżynierskie problemy projektowe. Stosowane modelowanie matematyczne, 71 , 45-59.
- Chen, H., Yang, C., Heidari, AA i Zhao, X. (2019). Wydajny, podwójnie adaptacyjny, losowy zapasowy wzmocniony Algorytm optymalizacji wielorybów. Systemy eksperckie z aplikacjami , 113018.
- Chen, Y., He, L., Guan, Y., Lu, H. i Li, J. (2017). Ocena cyklu życia emisji gazów cieplarnianych i optymalizacja zużycia wody na potrzeby planowania łańcucha dostaw gazu łupkowego w oparciu o podejście wielopoziomowe: Studium przypadku w łupkach Barnett, Marcellus, Fayetteville i Haynesville. Konwersja energii i Zarządzanie, 134 , 382-398.
- Cheng, MY i Prayogo, D. (2014). Wyszukiwanie organizmów symbiotycznych: nowa optymalizacja metaheurystyczna algorytm. Komputery i konstrukcje, 139 , 98-112.
- Clutton-Brock, T. (2009). Współpraca między niespokrewnionymi w społecznościach zwierzęcych. Natura, 462 , 51-57.
- Deng, Y., Zhang, T., Sharma, BK i Nie, H. (2019). Optymalizacja i badania mechanizmów rozrywania komórek i odzyskiwania fosforu z mikroalg za pomocą hydrowęgla modyfikowanego magnezem we wspomaganym systemie hydrotermalnym. Nauka o Całkowite środowisko, 646 , 1140-1154.
- Derrac, J., Garcia, S., Molina, D. i Herrera, F. (2011). Praktyczny samouczek dotyczący metodologii porównawczego testy statystyczne jako a algorytmu inteligencji ewolucyjnej i roju (Tom 1).
- Dorigo, M. i Blum, C. (2005). Teoria optymalizacji kolonii mrówek: Ankieta (t. 344).
- E Miller, N., J. Bailey, C. i AF Stevenson, J. (1950). Zmniejszony „głód”, ale w rezultacie zwiększone spożycie żywności ze zmian podwzgórza. Science (Nowy Jork, NY), 112 , 256-259.
- Elsayed abd el aziz, M. i Oliva, D. (2018). Estymacja parametrów modeli diod ogniw słonecznych przez an ulepszony algorytm optymalizacji wielorybów oparty na opozycji (t. 171).
- Eskandar, H., Sadollah, A., Bahreininejad, A. i Hamdi, M. (2012). Algorytm obiegu wody - Nowatorska metoda optymalizacji metaheurystycznej do rozwiązywania problemów optymalizacji inżynierii z ograniczeniami. Komputery i konstrukcje, 110-111 , 151-166.
- Fan, Y., Wang, P., Heidari, AA, Wang, M., Zhao, X., Chen, H. i Li, C. (2020). Zracjonalizowana muszka owocowa Optymalizacja za pomocą algorytmu sinus cosinus: kompleksowa analiza. Systemy eksperckie z Aplikacje , 113486.
- Friedman, MI, Ulrich, P. i Mattes, R. (1999). Przenośna miara subiektywnych odczuć głodu. Apetyt, 32 , 395-404.
- Fu, X., Fortino, G., Li, W., Pace, P. i Yang, Y. (2019). Sieć oportunistyczna wspomagana przez WSN dla małych opóźnień przekazywanie wiadomości w rzadkich ustawieniach. Systemy komputerowe przyszłości, 91 , 223-237.
- Fu, X., Fortino, G., Pace, P., Aloï, G. i Li, W. (2020). Protokół routingu wielościeżkowego z fuzją środowiska dla bezprzewodowe sieci czujników. Fuzja informacji, 53 , 4-19.
- Fu, X., Pace, P., Aloï, G., Yang, L. i Fortino, G. (2020). Optymalizacja topologii przed kaskadowymi awariami w bezprzewodowych sieciach czujnikowych przy użyciu algorytmu memetycznego. Sieć komputerowa , 107327.
- Gagnon, I., April, A. i Abran, A. (2020). Krytyczna analiza algorytmu nietoperza. Raporty inżynierskie, 2 , e12212.
- Gandomi, AH, Yang, XS i Alavi, AH (2013). Algorytm wyszukiwania kukułki: podejście metaheurystyczne do rozwiązywać problemy optymalizacji konstrukcji. Inżynieria z komputerami, 29 , 17-35.
- Garcia, S., Fernandez, A., Luengo, J. i Herrera, F. (2010). Zaawansowane testy nieparametryczne dla wielorakiej porównania w projektowaniu eksperymentów inteligencji obliczeniowej i eksploracji danych: Eksperymentalna analiza mocy (t. 180).

- Gotceitas, V. i Godin, J.-G. (1991). Żerowanie w warunkach zagrożenia drapieżnictwem młodego łososia atlantyckiego (*Salmo salar* L.): skutki statusu społecznego i głodu. *Ekologia behawioralna i socjobiologia*, 29, 255-261.
- Guo, S., Tsai, JS, Yang, C. i Hsu, P. (2015). Podejście do samooptrymalizacji dla L-SHADE włączone z krzyżowaniem opartym na wektorach własnych i skutecznym systemie wyboru rodziców w CEC 2015 zestaw wzorców. w 2015 Kongres IEEE na temat obliczeń ewolucyjnych (CEC) (s. 1003-1010).
- Gupta, S. i Deep, K. (2018). Hybrydowy, samodostosowujący się algorytm sinus cosinus z uczeniem opartym na opozycji (t. 119).
- Hansen, N., Müller, SD i Koumoutsakos, P. (2003). Zmniejszenie złożoności czasowej derandomizowanych strategii ewolucji z adaptacją macierzy kowariancji (CMA-ES). *Obliczenia ewolucyjne*, 11, 1-18.
- Heidari, AA, Mirjalili, S., Faris, H., Aljarah, I., Mafarja, M. i Chen, H. (2019). Optymalizacja jastrzębi Harrisa: Algorytm i aplikacje (t. 97).
- Holandia, JH (1992). Algorytmy genetyczne. *Amerykański naukowiec*, 267, 66-72.
- Huang, H., Feng, X. a., Zhou, S., Jiang, J., Chen, H., Li, Y. i Li, C. (2019). Nowy algorytm optymalizacji muszek owocowych ulepszył maszynę wektorów nośnych do diagnozowania raka piersi w oparciu o funkcje wysokiego poziomu. *BMC Bioinformatyka*, 20.
- Huang, H., Heidari, AA, Xu, Y., Wang, M., Liang, G., Chen, H. i Cai, X. (2020). Zracjonalizowany sinus cosinus Optymalizacja z efektywnymi wzorcami wyszukiwania. *Dostęp IEEE*, 8, 61471-61490.
- I. Friedman, M. i Stricker, E. (1976). Fizjologiczna psychologia głodu: perspektywa fizjologiczna. *Przegląd psychologiczny*, 83, 409-431.
- Jarvandi, S., Booth, D. i Thibault, L. (2007). Hiperhomeostaticzne uczenie się głodu antycypacyjnego u szczurów. *Fizjologia i zachowanie*, 92, 541-547.
- Karaboga, D. i Basturk, B. (2007). Potężny i wydajny algorytm optymalizacji funkcji numerycznych: Algorytm sztucznej kolonii pszczół (ABC) (t. 39).
- Kaveh, A. i Mahdavi, VR (2014). Optymalizacja ciał zderzeniowych: nowa metoda metaheurystyczna. *Komputery i konstrukcje*, 139, 18-27.
- Kennedy, J. i Eberhart, R. (1995). Optymalizacja roju cząstek. w Międzynarodowa konferencja IEEE na temat neuronów Sieci — materiały konferencyjne (t. 4, s. 1942-1948).
- Khashan, N., El-Hosseini, M., Y. Haikal, A. i Badawy, M. (2018). Stabilność dwunożnego robota na podstawie Puszka parametryczny algorytm optymalizacji wielorybów (t. 31).
- Koza, JR i Ryż, JP (1992). Automatyczne programowanie robotów z wykorzystaniem programowania genetycznego. w Postępowanie Dziesiąta Ogólnopolska Konferencja na temat Sztucznej Inteligencji (s. 194-201).
- Kumar N., Hussain I., Singh B. i Panigrahi B. (2017). Pojedynczy czujnik MPPT z Częściowo zacieniony PV System dla Ładowanie baterii przez Korzystanie z optymalizacji Cauchy'ego i Gaussa sinus cosinus (Tom PP).
- Lee, KS i Geem, ZW (2005). Nowy algorytm metaheurystyczny do ciągłej optymalizacji inżynierii: Teoria i praktyka poszukiwania harmonii. *Metody komputerowe w Mechanika Stosowana i Inżynieria*, 194, 3902-3933.
- Li, S., Chen, H., Wang, M., Heidari, AA i Mirjalili, S. (2020). Algorytm śluzowatej formy: nowa metoda na optymalizacja stochastyczna. *Systemy komputerowe przyszłości*, 111, 300-323.
- Li, X., Zhu, Y. i Wang, J. (2019). Wysoce wydajne usługi oparte na lokalizacji z zachowaniem prywatności dzięki Enhanced Jednorazowy filtr ślepy. *Transakcje IEEE na temat wschodzących tematów w Przetwarzanie danych*, 1-1.
- Liang, H., Liu, Y., Shen, Y., Li, F. i Man, Y. (2018). A Hybrydowy Jeden Algorytm dla Ekonomiczna wysyłka z Losowa siła wiatru (Tom PP).
- Liu, E., Lv, L., Yi, Y. i Xie, P. (2019). Badania nad modelem optymalizacji pracy ustalonej gazu ziemnego

- rurociąg z uwzględnieniem połączonej pracy chłodziń powietrza i kompresorów. [dostęp IEEE](#), 7, 83251-83265.
- Liu, J., Wu, C., Wu, G. i Wang, X. (2015). Nowatorski algorytm wyszukiwania różnicowego i zastosowania do struktury projekt. *Stosowana matematyka i obliczenia*, 268, 246-269.
- Liu, Y., Chong, G., Heidari, AA, Chen, H., Liang, G., Ye, X., Cai, Z. i Wang, M. (2020). Krzyżówka pozioma i pionowa optymalizatora Harris hawk z simpleksem Nelder-Mead do estymacji parametrów fotowoltaiki (<https://doi.org/113210.111016/j.enconman.112020.113211>). *Konwersja i zarządzanie energią*, 223, 113211.
- Liu, Y., Yang, C. i Sun, Q. (2020). Schematy ekstrakcji obrazów oparte na progach w środowisku Big Data w Inteligentne zarządzanie ruchem. *Transakcje IEEE dotyczące inteligentnych systemów transportowych*.
- Long, Q., Wu, C. i Wang, X. (2015). Układ rozwiązywania równań niegładkich na podstawie podgradientu metoda. *Stosowana matematyka i obliczenia*, 251, 284-299.
- Luo, J., Chen, H., Heidari, AA, Xu, Y., Zhang, Q. i Li, C. (2019). Wieloryb zmutowany wzmocniony wieloma strategiami inspirowane podejścia do optymalizacji. *Stosowane modelowanie matematyczne*, 73, 109-123.
- Luo, J., Chen, H., zhang, Q., Xu, Y., Huang, H. i Zhao, X. (2018). Ulepszona optymalizacja dla konika polnego algorytm z zastosowaniem do przewidywania stresu finansowego. *668. Stosowane modelowanie matematyczne*, 64, 654-.
- Lv, Z. i Qiao, L. (2020). Głęboka sieć przekonań i obliczenia kognitywne oparte na liniowym perceptronie dla roboty współpracujące. *Zastosowane miękkie przetwarzanie*, 106300.
- Mirjalili, S. (2015a). Optymalizator Ant Lew (t. 83).
- Mirjalili, S. (2015b). Algorytm ważki: Nowa technika optymalizacji metaheurystycznej do rozwiązywania pojedynczych obiektywne, dyskretne i wielocelowe problemy.
- Mirjalili, S. (2015). Algorytm optymalizacji płomienia ćmy: nowy, inspirowany naturą paradygmat heurystyczny. *Systemy oparte na wiedzy*, 89, 228-249.
- Mirjalili, S. (2016). SCA: A Algorytm sinus cosinus dla Rozwiązywanie problemów z optymalizacją (t. 96).
- Mirjalili, S., Aljarah, I., Mafarja, M., Heidari, AA i Faris, H. (2020). Gray Wolf Optimizer: teoria, przegląd literatury i zastosowanie w problemach obliczeniowej dynamiki płynów. W S. Mirjalili, J. Song Dong i A. Lewis (red.), (str. 87- Optymalizatory inspirowane naturą: teorie, recenzje literatury i zastosowania 105). Cham: Wydawnictwo Springer International.
- Mirjalili, S., Gandomi, AH, Mirjalili, SZ, Saremi, S., Faris, H. i Mirjalili, SM (2017). Algorytm Salp Swarm: Inspirowany biologią optymalizator do rozwiązywania problemów *Postęp w Oprogramowanie inżynierskie*, 114 projektowych. 163-191.
- Mirjalili, S. i Lewis, A. (2016). Algorytm optymalizacji wielorybów. *Postęp w Oprogramowanie inżynierskie*, 95, 51-67.
- Mirjalili S., Mirjalili S. i Hatamlou A. (2015). Optymalizator wielu wierszy: a inspirowany naturą algorytm dla globalnych optymalizacja (t. 27).
- Mirjalili S., Mirjalili SM i Lewis A. (2014). Optymalizator szarego wilka. *Postęp w Oprogramowanie inżynierskie*, 69, 46-61.
- Nenavath, H. i Jatoth, RK (2018). Hybrydyzacja algorytmu sinus cosinus z ewolucją różniczkową dla global optymalizacja i śledzenie obiektów. *Applied Soft Computing Journal*, 62, 1019-1043.
- Ni, T., Chang, H., Song, T., Xu, Q., Huang, Z., Liang, H., Yan, A. i Wen, X. (2020). Rozproszone testowanie połączeń w oparciu o kurczenie impulsów w układzie 2.5D IC. *Transakcje IEEE w obwodach i systemy II: Ekspresowe figi*, 67, 2657-2661.
- Niu, P., Niu, S. i Chang, L. (2019). Wada algorytmu optymalizacji Gray Wolf i jego weryfikacja

- metoda. Systemy oparte na wiedzy, 171 , 37-43.
- O'Brien, WJ, Browman, HI i Evans, BI (1990). Strategie poszukiwawcze zwierząt żerujących. amerykański naukowiec, 78 , 152-160.
- Qin, AK, Huang, VL i Suganthan, PN (2009). Algorytm różnicowej ewolucji ze strategią Adaptacja do globalnej optymalizacji numerycznej. Transakcje IEEE dotyczące obliczeń ewolucyjnych, 13 , 398-417.
- Qu, S., Han, Y., Wu, Z. i Raza, H. (2020). Modelowanie konsensusu z asymetrycznym kosztem opartym na danych Solidna optymalizacja. Decyzja grupowa i negocjacje , 1-38.
- Ran, W., Liu, S. i Zhang, Z. (2020). Dynamiczny system komisjonowania oparty na ankietach z uwzględnieniem priorytetów Zamówienia. Złożoność, 2020 , 4595316.
- Rao, RV, Savsani, VJ i Vakharia, DP (2011). Optymalizacja oparta na nauczaniu-uczeniu się: nowa metoda w przypadku problemów z optymalizacją konstrukcji mechanicznych z ograniczeniami. Komputerowe wspomaganie projektowania CAD, 43 , 303-315.
- Real, LA (1991). Zachowania związane z wyborem zwierząt a ewolucja architektury poznawczej. Nauka, 253 , 980-986.
- Reppucci, CJ i Veenema, AH (2020). Test preferencji społecznych a żywieniowych: paradygmat behawioralny dla 101119. badanie konkurencyjnych zachowań motywowanych u gryzoni. MetodyX, 7 ,
- Ridha, HM, Gomes, C., Hizam, H., Ahmadipour, M., Heidari, AA, & Chen, H. Optymalizacja wielocelowa oraz wielokryterialne metody podejmowania decyzji w celu optymalnego projektowania samodzielnego systemu fotowoltaicznego: kompleksowy przegląd. Recenzje energii odnawialnej i zrównoważonej, 135 , 110202.
- Saremi S., Mirjalili S. i Lewis A. (2017). 105). Algorytm optymalizacji Grasshopper: teoria i zastosowanie (Tom.
- Savsani, P. i Savsani, V. (2016). Przeszukiwanie pojazdu (PVS): Nowatorski algorytm metaheurystyczny. Stosowany Modelowanie matematyczne, 40 , 3951-3978.
- Shi, K., Tang, Y., Zhong, S., Yin, C., Huang, X. i Wang, W. (2018). Niewrażliwa kontrola asynchroniczna dla niepewne chaotyczne systemy sieciowe Lurie z procesem stochastycznym Bernoulliego. Międzynarodowy Dziennik Solidna i nieliniowa kontrola, 28 , 1693-1714.
- Shi, K., Wang, J., Tang, Y. i Zhong, S. (2020). Niezawodne asynchroniczne filtrowanie próbkowanych danych sieci neuronowych TS z rozmytą niepewnością opóźnionych w stochastycznych topologiach przełączanych. Zestawy i systemy rozmyte, 381 , 1-25.
- Shi, K., Wang, J., Zhong, S., Tang, Y. i Cheng, J. (2020). Niekrucho filtrowanie pamięci TS rozmyte opóźnione 40- sieci neuronowe oparte na przełączanej rozmytej kontroli danych próbkowanych. Zestawy i systemy rozmyte, 394 , 64.
- Simon, D. (2008). Optymalizacja oparta na biogeografii. Transakcje IEEE dotyczące obliczeń ewolucyjnych, 12 , 702-713.
- Song, J., Zhong, Q., Wang, W., Su, C., Tan, Z. i Liu, Y. (2020). FPD: elastyczne dane chroniące prywatność Program Wydawniczy dla Inteligentnego Rolnictwa. Dziennik czujników IEEE .
- Song, S., Wang, P., Heidari, AA, Wang, M., Zhao, X., Chen, H., He, W. i Xu, S. (2020). Dimension zdecydował się na optymalizację Harris hawk z mutacją Gaussa: Analiza równowagi i wzorce różnorodności. Systemy oparte na wiedzy , 106425 (<https://doi.org/10.6410.101016/j.knosys.102020.106425>).
- Storn, R. i Price, K. (1997). Ewolucja różniczkowa — prosta i wydajna heurystyka dla globalnej optymalizacji w przestrzeniach ciągłych. Dziennik Optymalizacja globalna, 11 , 341-359.
- Sun, G., Yang, B., Yang, Z. i Xu, G. (2019). Adaptacyjna ewolucja różnicowa z połączoną strategią dla globalna optymalizacja numeryczna. Soft Computing , 1-20.

Sutton, AK i Krashes, MJ (2020). Integracja głodu z rywalizującymi motywacjami. *Trendy w Endokrynologia & Metabolizm*, 31 , 495-507.

Tanabe, R. i Fukunaga, A. (2014). Poprawa Skuteczność wyszukiwania CIEŃ przy użyciu populacji liniowej Redukcja rozmiaru .

Tubishat, M., Abushariah, M., Idris, N. i Aljarah, I. (2018). Ulepszony algorytm optymalizacji wielorybów dla wybór funkcji w Analiza sentymentu arabskiego .

Tzanetos, A. i Dunias, G. (2020). Algorytmy optymalizacyjne inspirowane naturą lub po prostu wariacje metaheurystyka? Przegląd sztucznej inteligencji , 1-22.

Wang, G.-G., Deb, S. i Cui, Z. (2019). Optymalizacja motyla monarchy. *Technologie i aplikacje neuronowe*, 31 , 1995-2014.

Wang, GG (2003). Adaptacyjna metoda powierzchni odpowiedzi wykorzystująca odziedziczone punkty projektowe hipersześcianu łącińskiego. *Dziennik Projekt Mechaniczny, Transakcje ASME*, 125 , 210-220.

Wang, X., Chen, H., Heidari, AA, Zhang, X., Xu, J., Xu, Y. i Huang, H. (2020). Wielopopulacja po optymalizacji muszki owocówki opartej na zachowaniu: dowód zbieżności łańcucha Markowa i wszechstronna analiza. (<https://doi.org/10.6410.101016/j.knosys.102020.106437>). *Oparte na wiedzy Systemy*, 210 , 106437

Wang, X., Liu, Y. i Choo, KR (2020). Odporny na awarie schemat agregacji wielu podzbiorów dla inteligentnej sieci. *Transakcje IEEE w zakresie informatyki przemysłowej* , 1-1.

Wolpert, D. i Macready, W. (1997). Brak darmowych twierdzeń o lunchu do optymalizacji (Tom 1).

Wu, C., Wang, X., Chen, M. i Kim, MJ (2019). Pozycjonowanie RFID w oparciu o różnicową siłę odbieranego sygnału do śledzenia sprzętu budowlanego. *Zaawansowana informatyka inżynierska*, 42 , 100960.

Wu, G., Mallipeddi, R., Suganthan, P., Wang, R. i Chen, H. (2015). Ewolucja różnicowa z Multi Populacyjny zespół strategii mutacji. 10.1016/j.ins.2015.1009.1009. *Nauki informacyjne* ,

Xiong, Z., Xiao, N., Xu, F., Zhang, X., Xu, Q., Zhang, K. i Ye, C. (2020). Równoważny system zachęt do przekazywania danych oparty na wymianie dla sieci świadomych społecznie. *Dziennik Systemy przetwarzania sygnałów* , 1-15.

Xu, M., Li, T., Wang, Z., Deng, X., Yang, R. i Guan, Z. (2018). Zmniejszenie złożoności HEVC: głębokie uczenie zbliżyć się. *Transakcje IEEE dotyczące przetwarzania obrazu*, 27 , 5044-5059.

Yan, J., Pu, W., Zhou, S., Liu, H. i Bao, Z. (2020). Współpraca w zakresie wykrywania i alokacji mocy do śledzenia celu w wielu systemach radarowych. *Fuzja informacji*, 55 , 173-183.

Yan, J., Pu, W., Zhou, S., Liu, H. i Greco, MS (2020). Optymalna alokacja zasobów dla asynchronicznego Śledzenie wielu celów w heterogenicznych sieciach radarowych. *Transakcje IEEE na Signal Przetwarzanie*, 68 , 4055-4068.

Yang, L. i Chen, H. (2019). Diagnostyka usterek skrzyni biegów na podstawie RBF-PF i optymalizacji roju cząstek falkowa sieć neuronowa. *Obliczenia neuronowe i aplikacje*, 31 , 4463-4478.

Yang, S., Deng, B., Wang, J., Li, H., Lu, M., Che, Y., Wei, X. i Loparo, KA (2019). Skalowalne cyfrowe architektura neuromorficzna dla wielkoskalowej, biofizycznie znaczącej sieci neuronowej z wieloma neurony przedziałowe. *Transakcje IEEE w sieciach neuronowych i systemach uczenia się*, 31 , 148-162.

Yang, X.-S. (2010). A Nowy metaheurystyczny algorytm inspirowany nietoperzami (t. 284).

Yang, X.-S. i Deb, S. (2009). Wyszukiwanie kukulek za pośrednictwem lotów Lévy. w 2009 Światowy kongres na temat przyrody i obliczenia inspirowane biologicznie (NaBIC) (str. 210-214): IEEE.

Yang, X.-S., Karamanoglu, M. i Xingshi, H. (2014). Algorytm zapyłania kwiatów: Nowatorskie podejście do optymalizacja wielocelowa (t. 46).

Yang, XS (2009). Algorytmy Firefly do optymalizacji multimodalnej. w Notatki do wykładóww Informatyka (w tym podseria Notatki do wykładu w Sztuczna inteligencja i notatki do wykładów w Bioinformatyka) (t. 5792 LNCS, s. 169-178).

Yao, X., Liu, Y., & Lin, G. (1999) Szybsze programowanie ewolucyjne. Transakcje IEEE na ewolucję Obliczanie, 3 , 82-102.

Yong, J., He, F., Li, H. i Zhou, W. (2018). A Powieść Jeden Algorytm oparty na współpracy i dynamice Nauka Przeciwna populacja .

Yu, C., Heidari, AA i Chen, H. (2020). Kwantowy, symulowany, ulepszony płomień ćmy z wyżarzaniem Metoda optymalizacji. Stosowane modelowanie matematyczne .

Yu, H., Zhao, N., Wang, P., Chen, H. i Li, C. (2020). Zsynchronizowany optymalizator nietoperzy wzbogacony o chaos. Stosowany Modelowanie matematyczne, 77 , 1201-1215.

Yue, H., Wang, H., Chen, H., Cai, K. i Jin, Y. (2020). Automatyczne wykrywanie defektów piór przy użyciu grupy Lie oraz rozmyte kryterium Fishera dla produkcji lotek. Systemy mechaniczne i przetwarzanie sygnałów, 141 , 106690.

Zeng, H.-B., Liu, X.-G. i Wang, W. (2019). Uogólniona nierówność całkowa oparta na swobodnej macierzy dla stabilności analiza zmiennych w czasie układów opóźniających. Matematyka stosowana i obliczenia, 354 , 1-8.

Zhang, H., Wang, Z., Chen, W., Heidari, AA, Wang, M., Zhao, X., Liang, G., Chen, H. i Zhang, X. Rój salp napędzany mutacją algorytm z mechanizmem restartu: Analiza ramowa i fundamentalna. Systemy eksperckie z aplikacjami, 165 , 113897.

Zhang, X., Xu, Y., Yu, C., Heidari, AA, Li, S., Chen, H. i Li, C. (2020). Gaussa mutacyjna chaotyczna muszka owocowa wbudowana optymalizacja i dobór funkcji. Systemy eksperckie z aplikacjami, 141 , 112976.

Zhang, Y., Liu, R., Asghar Heidari, A., Wang, X., Chen, Y., Wang, M. i Chen, H. (2020). W kierunku rozszerzonego jądra ekstremalnych modeli uczenia się do przewidywania bankructwa: zachowanie algorytmiczne i kompleksowa analiza. Neurokomputer , <https://doi.org/10.1016/j.neucom.2020.1010.1038>.

Zhao, D., Liu, L., Yu, F., Heidari, AA, Wang, M., Liang, G., Muhammad, K. i Chen, H. (2020). Chaotyczna losowa optymalizacja kolonii mrówek zapasowych dla wieloprogowej segmentacji obrazu 2D Kapur entropia. Systemy oparte na wiedzy , 106510.

Zhao, D., Liu, L., Yu, F., Heidari, AA, Wang, M., Oliva, D., Muhammad, K. i Chen, H. (2020). Kolonia mrówek Optymalizacja z poziomym i pionowym przeszukiwaniem krzyżowym: podstawowe wizje wieloprogowej segmentacji obrazu. Systemy eksperckie z aplikacjami , 114122.

Zhu, G., Wang, S., Sun, L., Ge, W. i Zhang, X. (2020). Wyjściowe sprzężenie zwrotne Adaptacyjne dynamiczne przesuwanie powierzchni Kontrola trybu dla quadrotorowych UAV z ograniczeniami błędów śledzenia. Złożoność, 2020 .

Zhu, Q. (2019). Badanie systemu świadomości sytuacji w ruchu drogowym na podstawie obrazu Big Data. IEEE Inteligentne systemy, 35 , 18-26.